

# 基于动态博弈的群智感知激励机制研究

\*\*\*

2020 年 6 月

UDC分类号: 540

作者姓名	***
学院名称	***
指导教师	***
答辩委员会主席	***
申请学位	工学博士
学科专业	***
学位授予单位	***
论文答辩日期	2020 年 6 月

# **Dynamic Game based Incentive Mechanisms for Crowdsensing**

Candidate Name:	***
School or Department:	***
Faculty Mentor:	***
Chair, Thesis Committee:	***
Degree Applied:	Doctor of Philosophy
Major:	***
Degree by:	***
The Date of Defence:	June, 2020



# 基于动态博弈的群智感知激励机制研究

\*\*\*



## 研究成果声明

本人郑重声明：所提交的学位论文是我本人在指导教师的指导下进行的研究工作获得的研究成果。尽我所知，文中除特别标注和致谢的地方外，学位论文中不包含其他人已经发表或撰写过的研究成果，也不包含为获得北京理工大学或其它教育机构的学位或证书所使用过的材料。与我一同工作的合作者对此研究工作所做的任何贡献均已在学位论文中作了明确的说明并表示了谢意。

特此申明。

作者签名：\_\_\_\_\_ 签字日期：\_\_\_\_\_

## 关于学位论文使用权的说明

本人完全了解北京理工大学有关保管、使用学位论文的规定，其中包括：① 学校有权保管、并向有关部门送交学位论文的原件与复印件；② 学校可以采用影印、缩印或其它复制手段复制并保存学位论文；③ 学校可允许学位论文被查阅或借阅；④ 学校可以学术交流为目的，复制赠送和交换学位论文；⑤ 学校可以公布学位论文的全部或部分内容（保密学位论文在解密后遵守此规定）。

作者签名：\_\_\_\_\_ 导师签名：\_\_\_\_\_

签字日期：\_\_\_\_\_ 签字日期：\_\_\_\_\_





## 摘要

信息技术的蓬勃发展使得“数据”影响到人们日常生活的方方面面，并成为驱动国家社会发展的重要源泉。现阶段，需要获取海量数据的物联网应用大都依靠传感技术，然而基于传统无线传感器网络的感知方式存在感知效率低、生命周期短、能源供给不足等问题。近十年来，随着智能手机的快速更新换代，内置多种多样的传感器赋予了智能手机强大的感知能力，这催生了一种新型的感知模式来替代传统感知模式——群智感知。群智感知是以众包作为运营模式的感知系统，由平台调协用户完成请求者的感知任务。用户作为基本的感知单元参与到群智感知会存在感知代价，如消耗用户智能手机的电量、占用手机的计算资源和存储资源、泄漏用户的隐私信息。在没有足够奖励的情况下，用户难以主动参与到群智感知中，这样会极大地影响感知系统的可持续性。目前，设计一个好的激励机制在群智感知相关研究当中还属于一个开放性问题，在各个场景下面临着不同的技术挑战。本文从第三方应用协助的用户招募、盈利性与公平性的长期保障和多平台的共存关系三个切入点展开激励机制设计问题的研究，以最大化激励用户参与为目标，并取得如下成果：

1. **第三方应用协助的用户招募激励机制。**针对用户参与率不足的问题，我们引入第三方应用的协助到群智感知的激励机制设计当中，并使用三阶段斯坦克伯格博弈来建模激励机制的设计问题。我们系统分析了三阶段斯坦克伯格博弈的均衡策略，在第一阶段第三方应用先确定最优兴趣点标记价格；在第二阶段平台在兴趣点标记价格的基础上，同时确定最优任务标记集和最优任务奖励；在第三阶段，用户选择最优任务来执行。最后，我们通过实验仿真来评估第三方应用协助对激励机制的作用，实验结果验证了该激励机制在定价奖励上的合理性和在协助招募用户上的高效性。
2. **盈利性和公平性保障的长期激励机制。**针对用户流失和平台收益不足问题，我们设计了长期激励机制来保证公平选择用户，同时保障平台盈利。我们使用三阶段斯坦克伯格博弈来建模该激励机制并推导了均衡策略。在第一阶段，我们结合了 Zinkevich 在线梯度学习方法和李雅普诺夫优化来设计一种在线任务定价算法，达到了平台收益和感知系统效益（任务被更多用户的执行）的性能折中  $[\mathcal{O}(1/\nu), \mathcal{O}(\nu)]$ ；在第二阶段我们提出一种完全多项式近似算法（FPTAS）为

每个用户计算出一组  $(1 - \varepsilon)$ -近优任务集作为该用户的兴趣集；在第三阶段，我们提出一种基于集合多覆盖近似算法和李雅普诺夫优化技术的在线用户选择算法，平台根据用户汇报的兴趣集信息来选择用户，达到了用户公平性保障和平台征募奖励最小化的性能折中  $[\mathcal{O}(1/V), \mathcal{O}(V)]$ 。最后，我们对该激励机制进行仿真实验来验证其在定价的合理性和用户选择的公平性与有效性。

3. **面向多平台共存的激励机制。**针对多平台群智感知系统，我们提炼了设计面向多平台激励机制复杂的共存交互挑战，并把多平台共存关系划分为竞争关系和合作关系。我们使用多主导者-多跟随者的斯坦克伯格博弈建模多平台竞争场景的激励机制。通过推导斯坦克伯格博弈的均衡策略，每个平台可以根据计算出的最优奖励进行任务定价，每个用户可以选择最好的平台去执行感知任务。我们使用合作博弈中的纳什议价模型建模多平台合作场景的激励机制，通过先证明一对多纳什议价模型的 NP 难解性，进而提出启发式议价解决方案。推导纳什议价解揭示了平台间如何合作共享感知数据以及以多少奖励进行合作。最后，我们通过实验仿真来评估该激励机制在激励多平台共存上的性能，验证了多平台策略交互的有效性。

**关键词：** 物联网；群智感知；激励机制；动态博弈；斯坦克伯格博弈

## Abstract

The rapid development of Information Communication Technology (ICT) has revolutionized the every aspect of human's society via data, which drives the flourishing economy for the country. Nowadays, the way to access the sensing data by Internet of Things (IoT) is significantly established on the promotion of Sensing Technology, which generates multi-modal data for further usage. The traditional way of generating sensing data is to deploy amount of sensing nodes in the Point-of-Interesting (PoI) and form Wireless Sensor Network (WSN). However, it is shown that WSN suffers from low efficiency, short life span, and insufficient power due to the wireless transmission and ad hoc manner. The last decade has witnessed the achievement in smart phone, which is equipped with a set of cheap but powerful embedded sensors. As a result, the smart phone is endowed with powerful sensing ability. Bringing the smart phones into sensing activity has given rise to a new sensing paradigm – **Crowdsensing**. Actually, Crowdsensing is application of **Crowdsourcing**, which outsources the sensing tasks to mobile users. The Crowdsensing system coordinates the data demand of the set of requesters and the data supply of the crowd of mobile users through a platform resided in the cloud. We can see that the mobile user is to the Crowdsensing what sensing node is to WSN in the sensing process, where the mobile user is regarded as sensing unit, a.k.a Human Processing Unit (HPU). As a HPU, it must incur some cost for mobile user, such as consuming the battery, occupy the computing power, and potentially leaking the users' privacy (i.e., location, GPS trace). Therefore, the users are not willing to participate in performing sensing tasks unless they are enough rewarded. How to design a framework to determine proper rewards and derive perfect worker recruitment involves incentive mechanism, which plays significant role in the Crowdsensing. In this thesis, we study the incentive mechanism by considering the following factors: the PoI-tagging App's collaboration for participant recruitment, profitability and fairness guaranteeing for the platform and user with long-term incentive, and multiple platforms' coexistence. The main contributions are summarized as follows:

1. **PoI-tagging App's collaboration on participant recruitment for incentive mechanism.** For insufficient participation issue, we take PoI-tagging App's collaboration

(e.g., augmented/virtual reality POI-tagging App, Pokemon Go) into participant recruitment and design the corresponding incentive mechanism using three-stage Stackelberg game. We analyze the Stackelberg Equilibrium where the App first determines the POI-tagging price to maximize its payoff at Stage I, the platform subsequently decides how to determine tasks rewards and select tasks to be tagged at Stage II, and finally the normal user and App user strategize how to select the best task to perform at Stage III. We conduct simulations to verify the effect of such collaboration, present the performance of the incentive mechanism on pricing rewards and recruiting participants.

2. **Sustainable monetization and achievable fairness for long-term incentive mechanism.** For the issues of user dropout and platform's balance from Crowdsensing system, we propose a long-term incentive mechanism to guarantee the fairness of user selection procedure and ensure the platform's monetization from coordinating the data demand and supply between requesters and users. We design the incentive mechanism using three-stage Stackelberg game and analyze the Stackelberg Equilibrium each round. At Stage I, we design an online tasks' pricing algorithm by integrating Zinkevich's online gradient learning approach and drift-plus-penalty technique. It allows the platform make tradeoff between crowdsensing utility maximization and profits-seeking within  $[\mathcal{O}(1/\nu), \mathcal{O}(\nu)]$ . At Stage II, we capture the variety of users' computing capability and propose an FPTAS for them to calculate the  $(1 - \varepsilon)$ -optimal task set as interest and report their interest information to the platform. At Stage III, we design an online worker selection algorithm by combining approximation algorithm of set multi-cover with Lyapunov optimization, which achieves the fairness-reward tradeoff within  $[\mathcal{O}(1/V), \mathcal{O}(V)]$ . Finally, we conduct simulations to verify the effectiveness and performance of the proposed incentive mechanism in this scenario.
3. **Incentive mechanism for multiple platforms' coexistence.** Under the scenario of multiple platforms' Crowdsensing, we recognize the challenges of designing the incentive mechanism and divide the coexistence of multiple platforms into competition and cooperation. In the competitive case, we design the incentive mechanism using multiple-leaders multiple-followers Stackelberg game. The derived Stackelberg Equilibrium indicates that platforms decide prices decisions on optimal rewards to attract

more participants, while the users choose the best platform to work. In the cooperative case, we design the incentive mechanism for multiple platforms' cooperation using Nash Bargaining theory. We prove the NP-hardness of exact bargaining and then propose heuristic bargaining. The derived Bargaining solution indicates how and in what prices the platform to cooperate with each other by sharing their collected sensing data for secondary utilization. We conduct simulations to evaluate the performance of the designed incentive mechanisms under multiple platforms' coexistence and verify the strategic interactions of the multiple platforms.

**Key Words:** Internet of Things (IoT); Crowdsensing; Incentive Mechanism; Dynamic Game Theory; Stackelberg Game



## 主要符号对照表

$\mathcal{N}, N$	用户集和用户数目
$M, M$	任务集和任务数目
$c_{ij}, c_{ij}^t$	用户 $i$ 执行任务 $j$ 的感知代价
$p_j^t$	请求者 $j$ 在第 $t$ 轮支付的单位费用
$r_j^t$	平台在第 $t$ 轮为任务 $j$ 所做的定价决策变量
$\mathbf{r}_t$	第 $t$ 轮的奖励定价决策向量
$V$	公平性折中参数
$\nu$	盈利性折中参数
$\mathbf{Z}(t)$	平台在时槽 $t$ 的预算队列
$\mathbf{Q}(t)$	用户在时槽 $t$ 的公平性虚拟队列
$x_{j \leftarrow i}$	用户 $i$ 执行平台 $j$ 的任务所做的工作量值的大小
$p_{k \leftarrow j}$	达成议价合作时平台 $j$ 向平台 $k$ 所支付其共享感知数据的费用
$b_k^j$	指示平台 $j$ 和平台 $k$ 是否达成议价合作的布尔变量
$\mathcal{S}_i^t$	用户 $i$ 的兴趣集
$P_{app}$	第三方应用的兴趣点标记价格
$L(\mathbf{Z}(t))$	关于队列 $\mathbf{Z}(t)$ 在时槽 $t$ 的李雅普诺夫函数值
$\Delta(\mathbf{Q}(t))$	关于队列 $\mathbf{Q}(t)$ 在时槽 $t$ 的李雅普诺夫漂移值
$D_i$	用户 $i$ 离开群智感知系统的概率
$\eta_i$	分配给用户 $i$ 的最大任务数量
$B$	平台最大的奖励预算
$k_j^t$	需要挑选来执行第 $t$ 轮任务 $j$ 的用户数量
$\theta_j$	执行任务 $j$ 需要消耗的资源数目





## 目录

摘要 .....	I
Abstract .....	III
主要符号对照表 .....	VII
第 1 章 绪论 .....	1
1.1 研究背景与意义 .....	1
1.2 研究问题与现状 .....	5
1.3 研究内容与贡献 .....	10
1.4 论文结构 .....	13
第 2 章 相关理论与研究工作 .....	15
2.1 博弈论与优化理论 .....	15
2.1.1 博弈论简介 .....	15
2.1.2 斯坦克伯格博弈 .....	16
2.1.3 凸优化 .....	17
2.1.4 李雅普诺夫优化 .....	19
2.2 群智感知的激励机制相关工作 .....	22
2.2.1 基于斯坦克伯格博弈的激励机制 .....	23
2.2.2 基于拍卖模型的激励机制 .....	25
2.2.3 基于外部性的激励机制 .....	27
2.2.4 基于纳什议价模型的激励机制 .....	28
2.2.5 基于契约模型的激励机制 .....	29
2.3 本章小节 .....	30
第 3 章 第三方应用协助的用户征募激励机制 .....	31
3.1 引言 .....	31
3.2 模型、定义和问题描述 .....	35
3.2.1 用户模型 .....	35

3.2.2	平台模型 .....	36
3.2.3	第三方应用模型 .....	36
3.2.4	各方效益函数的定义 .....	37
3.2.5	基于三阶段斯坦克伯格博弈的激励机制设计问题描述 .....	39
3.3	激励机制设计 .....	40
3.3.1	阶段三：用户-任务匹配策略 .....	40
3.3.2	阶段二：感知平台的确定奖励和选择任务标记协同优化策略 .....	44
3.3.3	阶段一：第三方应用的兴趣点标记价格最优定价策略 .....	47
3.4	仿真实验 .....	49
3.4.1	关于感知平台的策略性能评估 .....	49
3.4.2	关于第三方应用的策略性能评估 .....	52
3.5	本章小结 .....	53
第 4 章	平台盈利性和用户公平性保证的长期激励机制 .....	55
4.1	引言 .....	55
4.2	模型和定义 .....	59
4.2.1	任务模型 .....	59
4.2.2	平台模型 .....	60
4.2.3	用户模型 .....	61
4.2.4	问题描述 .....	62
4.2.5	该激励机制在边缘-云架构上的实现 .....	64
4.3	激励机制设计 .....	65
4.3.1	阶段三：在线用户挑选 .....	65
4.3.2	阶段二：用户对任务的兴趣揭露 .....	71
4.3.3	阶段一：在线定价 .....	73
4.4	仿真实验与分析 .....	77
4.4.1	阶段三的实验评估 .....	78
4.4.2	阶段二的实验评估 .....	80
4.4.3	阶段一的实验评估 .....	80

4.4.4 基于轨迹数据集上部署激励机制的实验评估 .....	82
4.5 本章小结 .....	83
第 5 章 面向多平台共存的激励机制 .....	85
5.1 引言 .....	85
5.2 系统模型定义和问题描述 .....	88
5.2.1 系统概述 .....	88
5.2.2 用户模型 .....	90
5.2.3 平台模型 .....	90
5.2.4 问题描述 .....	93
5.3 平台间竞争场景的激励机制 .....	93
5.3.1 阶段二：用户选择平台和确定最优工作量策略 .....	93
5.3.2 阶段一：平台奖励定价策略 .....	96
5.4 平台间合作场景的激励机制 .....	98
5.4.1 精准议价 .....	98
5.4.2 启发式议价 .....	103
5.4.3 所有平台的合作策略 .....	104
5.5 仿真实验 .....	105
5.5.1 实验设置 .....	105
5.5.2 实验结果 .....	106
5.6 本章小节 .....	108
第 6 章 结论与展望 .....	109
6.1 工作总结 .....	109
6.2 研究展望 .....	111
参考文献 .....	115
攻读学位期间发表论文与研究成果清单 .....	127

## 插图

图 1.1 近十年来我国手机网民规模及占比统计 .....	2
图 1.2 群智感知整体系统结构 .....	6
图 1.3 群智感知请求者、平台和用户的交互过程 .....	7
图 1.4 论文主要研究内容 .....	10
图 2.1 群智感知中斯坦克伯格博弈的过程 .....	16
图 2.2 群智感知中基于博弈论的激励机制的分类 .....	23
图 3.1 PTASIM 激励机制示意图 .....	33
图 3.2 算法 1 的贪婪算法 GreedyPPM 和基准程序（随机算法 RandomizedPPM 和暴力枚举算法 EXPPM）的性能比较 .....	50
图 3.3 贪婪算法 GreedyPPM 和随机算法 RandomizedPPM 在标记的任务数从 0 到 50 个时关于问题 PPM 的目标函数值（奖励代价）的变化曲线 .....	50
图 3.4 在不同参数（App 活动的内在效益 $V$ 、兴趣点标记价格 $P_{app}$ 和网络拥 堵效应系数 $\delta$ ）影响下，平台挑选任务作为被标记活动兴趣点的数目 .....	51
图 3.5 平台的奖励定价策略 $\rho_{t_i}$ 对用户参与率的影响 .....	51
图 3.6 第三方应用的标记价格定价策略 $P_{app}$ 与其效益函数的性能评估 .....	52
图 3.7 平台的标记需求曲线和第三方应用标记定价曲线关系 .....	52
图 4.1 算法 3 和基准方案在所获得的奖励代价目标函数上的性能比较 .....	79
图 4.2 算法 3 在 $V = 20$ 和 $V = 100$ 时虚拟队列 $Q(t)$ 总长度的性能比较 .....	79
图 4.3 算法 3 在 $V = 20$ 和 $V = 100$ 时所有用户的挑选率性能比较 .....	79
图 4.4 阶段二所提出 FPTAS 的性能 .....	80
图 4.5 算法 5 在 $\nu = 10$ 和 $\nu = 50$ 两种场景下所达到的时间平均效益目标函数 的性能比较 .....	81
图 4.6 算法 5 在 $\nu = 10$ 和 $\nu = 50$ 时预算队列 $\widetilde{Z}(t)$ 总长度的性能比较 .....	81
图 4.7 在 $\nu = 10$ 和 $\nu = 50$ 下所有任务的奖励定价决策曲线和请求者给平台的 支付费用曲线 .....	81

图 4.8 算法 3 分别在 $V = 20, 100, 1000$ 以及算法 5 分别在 $\nu = 10, 20, 210$ , 激励机制所对任务所定的奖励性能比较, 总时槽为 1000 .....	82
图 4.9 算法 3 在 $V = 20, 100, 1000$ , 各自所使用的虚拟队列总长度, 对应着公平性约束的保障程度, 总时槽为 1000 .....	82
图 4.10 算法 5 在 $\nu = 10, 20, 210$ , 各自所使用的预算队列总长度, 对应着平台可以盈利的程度, 总时槽为 1000 .....	83
图 5.1 多平台场景下的群智感知激励机制 .....	89
图 5.2 平台的奖励 $r_j$ 对工作量上限 $B_i^U$ 和感知代价 $c_{j \leftarrow i}$ 不同用户的最优工作量策略 $x_{j \leftarrow i}^*$ 的影响 .....	106
图 5.3 最优工作量策略 $x_{j \leftarrow i}^*$ 关于平台奖励 $r_j$ 和感知代价 $c_{j \leftarrow i}^*$ 的等值曲线图 .....	106
图 5.4 奖励定价策略 $r_j^*$ 在不同预算 $B_j^P$ 关于服务价值系数 $\lambda_j$ 的影响 .....	106
图 5.5 平台奖励和用户参与数目在一定预算 $B_j^P$ 下关于奖励定价决策的变化曲线 .....	106
图 5.6 奖励定价策略 $r_j^*$ 在不同预算 $B_j^P$ 关于服务价值系数 $\lambda_j$ 的影响 .....	107
图 5.7 合作场景下某一平台议价的结果 .....	107

**表格**

表 3.1 第 3 章所设计的激励机制常用数学符号表 ..... 35

表 3.2 第 3 章的实验参数设置 ..... 49

表 4.1 第 4 章所设计的激励机制常用数学符号表 ..... 59

表 4.2 第 4 章的实验参数设置 ..... 78

表 5.1 第 5 章多平台激励机制设计中的主要数学符号表 ..... 88

表 5.2 第 5 章仿真实验关键参数 ..... 105

# 第1章 绪论

## 1.1 研究背景与意义

伴随着我国“十三五”规划的实施，其中的信息化战略对国民经济产生了重大的影响，同时改变了社会生活的各个方面，为人们生活带来极大的便利。诚然，实现信息化的发展，离不开数据的支撑。比如，天气预报需要气候数据，人脸识别需要人脸数据，智能物流需要物品数据，智慧交通需要路况数据，脏物监测需要环境数据，人员追踪需要定位数据等等。对这些数据深入挖掘，可以得到有价值的信息，进而为解决社会问题提供更有参考意义的决策方案。近年来，人工智能和大数据挖掘技术的发展，使得从这些数据中挖掘有用的信息成为了可能。然而，这一切都是建立在大规模数据支撑的基础之上，如果不能收集这些数据，就无法得到隐藏在数据之中有用的信息。

随着传感技术、云计算和边缘计算的发展，以物联网为代表的获取数据方式通过需要在需要获取数据的地方部署一定量的传感器来收集数据，并将所收集的数据传输到以云服务器或者边缘服务作为数据中心的汇聚节点进行深入的处理和分析。这种通过部署传感器组成的网络来获取感知数据又称作无线传感器网络。无线传感器网络通过在固定区域部署大量传感器节点来进行感知，并以自组织的方式进行传输，以配备电池或者采集环境能量的方式进行能量供给。显然这种感知模式存在缺陷：

- 单个传感器节点的感知范围有限。为了扩大感知范围则需要部署更多的感知节点，这无疑造成了更大的部署成本和管理成本。
- 部署的传感器属于专用传感器，得到的数据单一，无法满足多模态数据挖掘需求。
- 每个传感器都需要电池供能，这造成了所组成的无线传感网存在生命周期短的问题，无法进行持续感知，感知效率低下。尽管可以配备采集能量的电池（如太阳能电池）让节点从环境中采集能量，但是受到气候不稳定等环境因素的制约而使得无法稳定地获取感知数据。

幸运的是，近十年智能终端方面所获得的进展为解决无线传感网的感知局限性提供了机遇。如今的智能终端，诸如智能手机和各种可穿戴设备（智能手表、谷歌眼镜、




图 1.1 近十年来我国手机网民规模及占比统计

小米手环) 都配备了各种各样功能强大的传感器, 例如, 加速度计、陀螺仪、磁力计、GPS、摄像头、麦克风等等。这些传感器可以产生与携带者及其周边相关的多模态数据, 并通过智能终端上的无线网络接口传输感知数据。此外, 随着 4G 蜂窝技术的大规模使用, 以及 5G 蜂窝技术的商用化, 我国的移动设备市场规模越来越庞大。据统计, 截至 2020 年, 全球使用的移动智能手机总数达到了 35 亿台, 并预计在 2021 年达到 38 亿台。如图 1.1 所示, 截止 2019 年 6 月, CNNIC 发布的第 44 次《中国互联网络发展状况统计报告》揭示了在我国 8.54 亿的网民规模中, 移动用户占据 99.1%, 高达 8.47 亿。因此, 如果利用大规模移动用户替代部署在传感网中的传感器节点, 来参与感知活动, 则将形成全球最大规模的感知网络。所获得的感知数据覆盖范围更大, 粒度更细, 种类更多。事实上, 这种新型感知形式又称为**群智感知**, 近年来得到了工业界和学术界极大的关注。

群智感知<sup>[1-3]</sup>的思想是来自于众包<sup>[4]</sup>, 它是由《连线》杂志在 2006 年提出的一种新型问题解决的模式: 把任务外包给互联网大众用户来执行, 进而解决问题或发现创意。这些任务是单个计算机无法快速执行的任务, 比如对图像打标签、《纽约时报》古老报纸的数字化、寻找域外文明的 SETI@home 系统等等。对于人类来说这些任务是可以轻易的完成, 而计算机则需要耗费大量的算力和算时才能得出结果。因此, 众包平台往往征募大量的互联网用户来完成大规模任务, 当用户完成任务时候, 把任务的



结果提交给平台，并从平台那里得到一定量的奖励。这个思想可以用于物联网感知领域，把大规模感知任务众包给大量的移动用户，来替代传统无线传感器网络而成为群智感知。群智感知弥补了传统无线感知网络的局限性，具有自己的特点和优势：

- 广泛性：得益于移动智能手机的大规模普及和智能手机上配备强大的多类型传感器，很多携带智能手机的大量用户已经无死角覆盖了各个区域。因此，我们可以征募用户来进行感知而不需要在现场部署专用传感器。携带智能手机的移动用户有机会参与到感知任务中，形成了以人为中心的感知模式。大量用户的参与将增加数据的可获得性。
- 经济性：在群智感知中，我们只需要对参与感知的用户支付奖励即可，无需像无线传感网一样考虑部署成本和管理开销。这将大大地减少了获取海量数据的成本。
- 灵活性：与无线传感网不同，群智感知不用考虑节点的能量供给问题，不需事先部署大量节点，降低了维护的复杂性。群智感知平台只需发布任务，征募用户参与感知，感知系统的可扩展性强。

毫无疑问，群智感知成功的关键因素在于大量用户参与到感知任务当中。然而，执行感知任务会消耗用户移动设备的计算资源、存储资源和电量，一定程度上降低了用户使用他们自己移动设备的用户体验。当获取到感知数据后，用户需要花费通信流量传输数据给平台，对用户来说造成了一定的通信成本，尤其在即将到来的 5G 通信时代，数据流量更加昂贵。此外，执行某些感知任务需要用户暴露隐私数据（如用户位置和移动轨迹信息），这又进一步降低用户执行感知任务的意愿。因此，有必要奖励参与群智感知的用户，如何设计奖励方案则属于群智感知中的关键研究问题（即激励机制设计问题），近年来受到了学术界的极大关注。

从另外一个方面讲，移动用户作为其移动智能设备的拥有者，具有较强的自主控制权，用户可以随时随地参与感知任务，又可以随时随地离开感知平台。同时，每个用户的执行成本不一样，意识到执行感知任务能得到奖励，他们的理性行为会使得他们单独决定自己的参与策略来最大化自己的效益，其自私的行为会影响到感知任务的执行效果，进而影响了感知系统的性能。这个难题将挑战着激励机制的设计。利用博弈论（Game Theory）的理论结果，我们可以抽象激励机制设计问题为一个博弈模型，通过博弈模型来描述感知平台与移动用户之间的策略交互，最后求出博弈模型中的

均衡策略，作为激励机制的设计方案。然而，这些博弈模型往往假设博弈规则是给定的，进而在这些博弈规则下求解均衡策略。而符合期望效果的博弈规则是无法事先预知的。在这种情况下，我们需要借助于博弈论的另一个分支，机制设计（Mechanism Design），它是借助工程学的方法来设计博弈规则，进而达到预期的均衡策略。由于与博弈论的分析过程相反，机制设计往往也称作“逆向博弈论”。本文将使用机制设计的基本原理来设计激励机制，帮助感知平台，引导自私理性的移动用户协同平台，参与执行感知任务，达到感知系统的整体最优性能。

激励机制首先需要考虑如何保证在自己预算有限的情况下，吸引更多用户的参与。为了达到这点，只需对奖励进行合理定价，让参与用户的效益为正的。然而，在某些情况，单靠感知平台征募到的用户较少，达不到对感知数据的需求量。而此时有一些第三方应用拥有大量的用户，并且这些第三方应用可以通过某些手段来引导它的用户执行一些任务。那么感知平台借助这些第三方应用的协助往往能达到很好的激励效果。事实上，这些第三方应用广泛存在，比如一些火热的 AR/VR 游戏（Pokemon Go 等）可以引导它们的游戏用户到某些地点玩游戏，或者支付宝 App 引导用户到某个地点完成扫福活动。但是，考虑到第三方应用的协助，会增加交互的复杂度，进而需要重新设计激励机制。

其次，群智感知系统的持续发展要依赖于两个因素，1) 平台在为请求者提供数据服务中获利；2) 对用户长期激励以防止用户流失。对于第一个目标来说，平台通过为每个到达的任务制定一个合理的奖励，保证奖励能吸引足够多用户的同时，平台的收益不能为负。在每一轮用户征募当中，用户需要被公平地挑选为参与者，否则，一些不被经常挑选的用户将会离开感知系统。只有保障用户的正效益值和公平性，激励机制才能长期激励用户参与执行感知任务。然而达到这两个目标需要解决两个冲突的约束：1) 平台利润的最大化和征募用户数量的冲突；2) 征募用户的奖励最小化和保证用户选择公平性的冲突。设计激励机制来解决这两个挑战对于保证群智感知系统的良性持续发展至关重要。

最后，随着群智感知的发展，其带来的更多效益使得多个感知服务提供商将大量部署自己的感知平台，激励用户为其提供感知数据，从而形成了多平台群智感知。在这种情况下，平台之间将产生竞争关系。事实上，大部分已获得的感知数据可以通过共享来达到其价值的最大化，所以平台之间有潜在的合作动力。考虑到平台之间的竞争合作关系，感知系统的交互也变得更加复杂，有平台与用户之间的策略交互，也有

平台与平台之间的策略交互。因此，如何设计面向多感知平台共存的激励机制极其重要。

本文将从以上三个角度出发，考虑各种场景所具有的挑战，研究不同的激励机制，高效激励用户参与执行感知任务，最终提升感知系统的整体性能。我们还使用大量的仿真实验来验证所设计激励机制的有效性和可行性。通过严密的理论和丰富的实践，形成了一套合适的激励机制，即保证感知系统的整体目标，又保障用户的个人收益公平性，从而达到群智感知系统各方的互利双赢局面。因此，本文的研究内容为实现高可靠群智感知系统而达到万物智联（AIoT）的目标提供有建设意义的理论与技术支持。

## 1.2 研究问题与现状

群智感知（Crowdsensing）起源于众包思想。众包（Crowdsourcing）<sup>[4]</sup>概念的提出，使得企业可以通过互联网组织参与者，以更高的效率和更低成本，完成工程量巨大、参与门槛较低的任务。其中，较为著名的众包案例是《纽约时报》利用 reCAPTCHA 系统，在几个月的时间内，完成了该报社所存 130 年资料的数字化工作。随着移动终端设备和无线通信技术的广泛普及，移动设备因集成了加速度计、陀螺仪、磁力计、罗盘仪、GPS、摄像头、麦克风等多类型传感器和强大的处理器而具有强大的感知计算能力。这些进展使得从各类型移动设备（智能手机、可穿戴设备和平板电脑）中获取感知数据成为可能。伴随着物联网时代日益强烈的“感知”需求，基于众包思想的新型感知模式应运而生——群智感知<sup>[1-3,5-7]</sup>。如图1.2所示，在群智感知中，大量普通移动用户使用移动设备作为基础感知单元<sup>1</sup>，通过相互协作，实现感知任务分发与感知数据收集，最终完成大规模的、复杂的社会感知任务。由于与人们日常生活工作密不可分的，这种以人为计算感知的模式往往获得大规模丰富多样的多模态感知数据，而且群智感知利用了无处不在的移动用户携带其自身移动设备来收集感知数据，避免了部署专用传感器，节约了部署成本。从这个角度看，具备灵活性和可扩展性的群智感知颠覆了传统以部署传感器为主的无线传感网。

如图1.3所示，群智感知系统中有三个主要参与群体进行交互：

- 服务请求者：它们对感知服务的存在需求并在各个时槽中生成感知任务提交给平台，同时向平台支付订阅感知服务的费用。

<sup>1</sup>参与者也可以是配备多种传感器的移动车辆。




图 1.2 群智感知整体系统结构

- 用户：它们作为感知任务的实际执行者，具有感知和计算能力。一般地，群智感知系统中存在大量的移动用户为平台工作。
- 平台：它作为协调服务请求者和移动用户的中间角色，从请求者接收任务，通过为任务制定奖励来激励用户参与执行任务。

请求者、平台和用户按照以下顺序进行交互：1) 请求者向平台发起任务请求，并宣布支付的费用；2) 平台为任务定价奖励，并向用户发布任务和奖励；3) 用户汇报兴趣集（用户从当前任务选择一组愿意执行的任务汇报给平台）；4) 平台收到兴趣集信息后选择一组用户来执行当前任务；5) 被选中的用户执行任务，收集并上传感知数据；6) 平台整合收集到的感知数据后提交任务结果给请求者；7) 请求者收到任务结果后向平台支付费用；8) 平台收到请求者的费用后向执行任务的用户支付奖励。

从网络设计的角度来看，群智感知系统一般可分为感知层、网络层和应用层。感

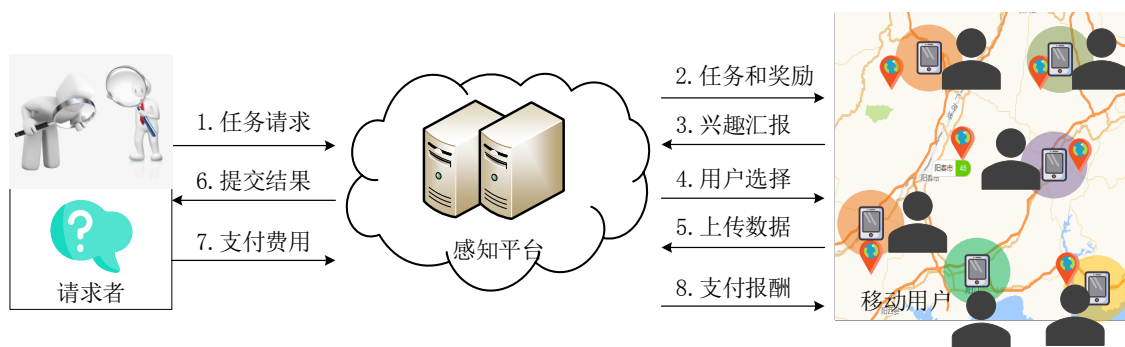


图 1.3 群智感知请求者、平台和用户的交互过程

知层主要由携带移动感知设备的用户组成，通过其移动设备配备的传感器进行感知，当把群智感知扩展到车联网时，感知单元包括车辆。而网络层主要指平台与用户之间和平台与请求者之间的网络连接，这些网络连接包括传统的有线网和各种无线网（蜂窝网、Wi-Fi 网络、D2D 网络），当使用 D2D 网络来设计群智感知系统的网络架构时，该类型的群智感知称作为机会式群智感知<sup>[8]</sup>。应用层是指平台获取感知数据后，利用大数据挖掘技术对感知数据进行分析融合，以满足请求者的感知服务请求。

相比于无线传感网，群智感知具有广泛的应用前景，基于群智感知技术的应用已有很多，比如：(1) 智能交通：ParkSense<sup>[9]</sup> 通过检测移动设备的 Wi-Fi 信号接入变化特性来确定是否出现新的停车位。Mobile Millennium<sup>[10]</sup> 通过移动设备的 GPS 来收集交通信息并实现实时交通流量检测。(2) 环境监测：Ear-phone<sup>[11]</sup> 利用手机麦克风测量环境噪音，构造城市环境的噪音地图。CreekWatch<sup>[12]</sup> 通过收集水质、废弃物的照片和文本信息，实现环境监测。(3) 城市管理：GigaSight<sup>[13]</sup> 通过分析用户上传的视频和图片信息，帮助警务人员进行案件侦破，如寻找丢失儿童等。Sensorly<sup>[14]</sup> 通过汇集 Wi-Fi 信号和蜂窝网络速度，构建城市网络覆盖图。(4) 位置服务：Jigsaw<sup>[15]</sup> 从大量移动用户拍摄的图片中提取地标物体的位置、大小、方位信息，并从内置惯性传感器获取数据，分析得到相邻地标物体的空间关系。结合用户移动轨迹和位置图像，构建室内空间完整的平面图。

因此，群智感知为社会生活提供了新的前景，同时对群智感知的研究符合《中共中央关于制定国民经济与社会发展第十三个五年规划的建议》中发展物联网技术和应用、实施国家大数据战略的总体要求。鉴于群智感知的广大前景和强大潜力，学术界和工业界已开始对其展开广泛的研究。IBM 托马斯·J. 沃森研究中心和美国达茅斯学院先后在 IEEE Communications Magazine 杂志上陈述了群智感知的现状、挑战和

未来发展方向<sup>[5,6]</sup>。国内清华大学刘云浩教授<sup>[1]</sup>和西北工业大学的於志文教授<sup>[16]</sup>也分别进一步阐述了群智感知的概念和对物联网的意义。与此同时,许多国际期刊杂志(如 IEEE Communications Magazine、IEE IoT Journal 和 ACM Transaction on Intelligent Systems and Technology 等等)都推出了群智感知的专刊,多个国际学术会议(IEEE INFOCOM、IEEE ICDCS、ACM MOBICOM、ACM UBICOMP、ACM MOBISYS 和 ACM MOBIHOC 等)都收入了一定量的群智感知论文。关于群智感知的基本研究问题大体上可以分为:

1. **用户选择和任务分配。**群智感知涉及到大量的用户,这些用户具有多元性、多样性和自主性;另一方面感知任务对环境 and 完成要求具有差异性、依赖性和不确定性。此外,感知任务和移动用户都具有时空特性,如何选择合适的用户来执行感知任务或把任务分配给合适的用户是群智感知的关键研究问题之一。很多研究将感知任务按照某种或某几个特性进行划分,然后制定灵活的用户选择和任务分配策略。McSense<sup>[17]</sup> 算法根据不同物理区域感知密度和感知资源的特点,给用户分配与其工作能力相匹配的感知任务。Tong 等人<sup>[18]</sup> 根据群智感知任务的空间分布,设计了一种全局的在线微任务分配模式,结合带权二分图的最优匹配算法,提出一种高效的在线任务分配算法。TaskMe<sup>[19]</sup> 系统考虑用户和任务的数量关系,结合最大流最小代价和多目标优化理论,设计了两种基于用户地理位置的多任务分配策略。Karger 等人<sup>[20]</sup> 考虑用户完成任务的信誉程度,提出一种用户信誉评估模型,通过信誉和代价两个方面选择合适的用户,在维持任务质量满足要求的前提下,达到代价最小化的优化目标。Li 等人<sup>[21]</sup> 在保证一定任务覆盖率的同时,设计相应的策略选择合理的用户数量与用户集合来最小化群智感知任务的开销;并设计基于在线学习的用户选择方法<sup>[22]</sup>,在选择用户的同时学习用户的感知能力。
2. **激励机制设计。**用户参与执行感知任务时不可避免地消耗其携带设备的电池能量,同时占用计算资源和存储资源,传输感知数据给平台又引入额外的通信费用,甚至执行感知任务需要分享实时位置从而暴露隐私。这些因素增加了广大用户参与群智感知系统的门槛,降低用户参与的热情。而群智感知的早期工作依赖于用户志愿参与的假设,这大大阻碍了群智感知应用在实际情况中的落地。没有奖励来补偿用户的感知代价则无法吸引大量用户参与群智感知。因此,设计合理的激励机制对于群智感知系统来说至关重要,它可以让用户在为群智感



知贡献感知数据的同时获得实际收益，激励更多用户参与执行感知任务，达成“人人为我，我为人人”的双赢局面，实现群智感知系统的良性循环和可持续发展目标。然而设计激励机制在不同场景下存在不同的挑战和难题，平台需要考虑激励的有限预算。群智感知激励机制的理论研究主要集中在拍卖原理、斯坦克尔伯格博弈和多臂老虎机问题等几个方向。RADP-VPC<sup>[23]</sup> 算法基于逆向拍卖的原理，在多轮拍卖中选出每轮出价最低的  $m$  个用户，并且给本轮未出线的用户在下一轮的竞争中增加额外报酬，以此来激励更多的用户参与到竞争当中。在此基础上，GIA<sup>[24]</sup> 算法增加考虑了用户的位置信息、完成任务的覆盖范围和平台的预算，计算单位成本下边缘收益最大的用户。除了拍卖机制以外，Duan 等人<sup>[25]</sup> 提出基于斯坦克尔伯格博弈以平台收益最大化为目标的激励机制。虽然斯坦克尔伯格博弈提供了理论基础，但是其假设用户的代价是已知的，没有考虑用户可能虚假报价的情况。针对这一问题，Yang 等人<sup>[26,27]</sup> 提出把用户完成任务的时间当作代价以此来解决任务代价未知的问题。此外基于多臂老虎机模型的 BP-UCB<sup>[28]</sup> 定价策略把用户公开个人隐私信息当作一种用户成本，在满足预算约束的同时，优先选择报价接近真实成本的用户。关于激励机制的更多相关工作将在第二章详细探讨。

3. **感知数据质量管理和控制。** 保证感知数据质量贯穿了群智感知整个过程，是群智感知所面临的重要挑战之一。而影响感知数据质量的因素很多：1) 用户汇报虚报感知成本，提交虚假数据以获得更多奖励；2) 感知数据质量与用户设备的数据采集误差息息相关，而传感器精度直接决定感知数据误差；3) 不满足时空特性的用户提交了不符合质量要求的感知数据；4) 自组织的网络连接影响数据收集的质量。而质量控制可以采用传统众包中征募多个参与人执行同一感知任务来获取多份感知数据，进而过滤低质量数据。SMART<sup>[29]</sup> 算法对选择结果进一步优化，将可能使优化目标更好的用户替换已选用户集中的部分用户以此来提高任务完成质量。MAA<sup>[30]</sup> 算法同时把用户对不同任务的偏好度、报价、位置及位置的准确度、用户的可信度、完成任务的时间等多种因素，综合量化为一个衡量用户质量的指标，虽然这是一个可行而全面的模型的，但是其算法复杂度过高，此外该算法还需要获取很多用户信息，很可能对用户造成额外负担从而影响其参与度。Koutsopoulos 等人<sup>[31]</sup> 则单一地直接定义一个质量值来衡量用户对某一任务的完成度。QUEST<sup>[32]</sup> 算法以最大化平台收益为目标，把用户服务质

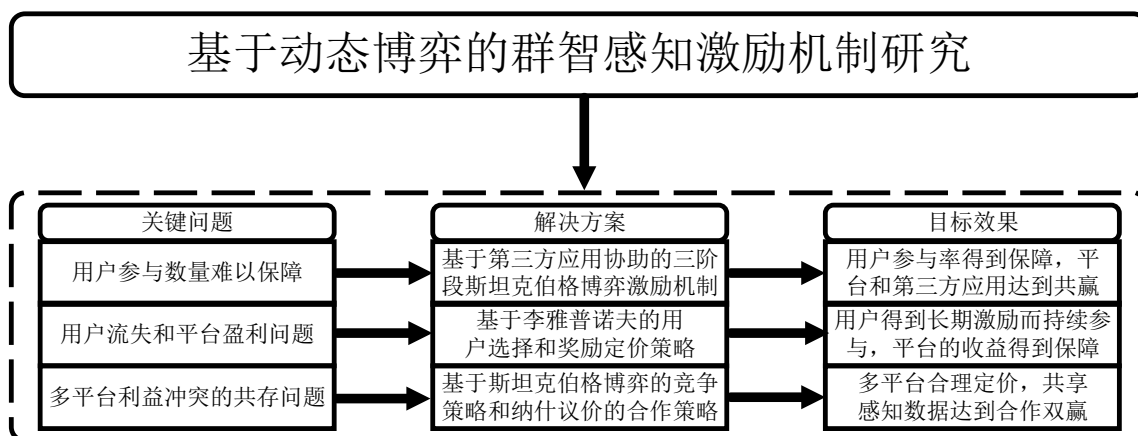


图 1.4 论文主要研究内容

量当作一种未知的用户隐私信息，但是其假设用户是专业人士，有一定的局限性。

根据上面描述，我们发现群智感知的研究问题相互之间关系紧密，例如激励机制需要伴随着用户选择，在有效合理的用户选择和任务分配的基础上，激励用户保持较高的活跃度可以保障感知任务的可持续性。此外，相关实验数据表明，用户激励能够提高群智任务完成的质量<sup>[33,34]</sup>。除了上述三个研究问题外，与群智感知相关的研究问题还包括参与者隐私信息保护<sup>[35]</sup>、基于群智感知的新型应用<sup>[36]</sup>和面向群智感知的数据挖掘技术<sup>[37]</sup>。在本文，我们主要研究群智感知中的激励机制设计问题，辅之以用户选择和质量保证方法，结合博弈论等基础知识，提炼不同角度和场景的设计挑战，设计合适的激励机制满足相应的目标。

### 1.3 研究内容与贡献

本文以“协助-公平-共存-实证”为主线，从不同角度研究了群智感知中基于动态博弈的激励机制设计问题。图1.4从“关键问题-解决方案-目标效果”等方面展示了主要的研究内容。首先，对于平台无法为某些请求者持续稳定地征募足够多的用户数量问题（诸如用户分布不均匀、在线用户少、用户对任务的兴趣度不大等原因），我们借助于第三方应用的协助，利用其强大的用户黏着度来协助感知平台征募用户执行感知任务。但是为群智感知系统引入第三方应用则多增加了一层策略交互，为此我们使用三阶段斯坦克伯格博弈建模这种场景下的激励机制设计问题。通过所设计的激励机制，任务的用户参与率得到保障，同时平台和第三方应用通过合作达到了双赢的效



果。随后,对于保障平台收益问题和防止用户流失问题,我们需要确保平台在分配任务中的奖励定价不超过请求者支付的费用,同时在用户选择中保证用户的挑选率不低于预设的阈值(公平性约束)。而达到这个目标牵涉到解决两个冲突的目标和约束,如 1) 平台利润的最大化和征募用户数量的冲突; 2) 征募用户的奖励最小化和保证用户公平性约束的冲突。为了协同优化这两个冲突的目标和约束,我们结合李雅普诺夫优化技术和三阶段斯坦克伯格博弈来建模这种场景下的激励机制设计问题。通过该激励机制,用户因得到长期激励而持续参与群智感知,同时平台在分配任务的过程中收益得到保障。最后,我们在多平台场景下研究复杂的策略交互问题,把平台间的共存交互关系分成竞争和合作两种情况,并分别设计了两种情况对应的激励机制。我们分别使用多主导者-多跟随者斯坦克伯格博弈和纳什议价合作博弈来建模竞争情况和合作情况下的群智感知系统中用户与平台和平台间的策略交互。最终在竞争情况下平台和用户根据均衡策略进行科学合理地决策,以及平台间通过合作共享获得感知数据来提升感知系统整体效益,从而达到双赢效果。具体的研究内容和贡献点概括如下:

### **(1) 第三方应用协助的用户征募激励机制**

群智感知中,平台需要为任务征募足够多的用户来执行感知任务。由于不可阻挡的因素(如用户分布不均匀、在线用户少、用户对任务的兴趣度不大),平台有时难以持续征募到足够多的用户数量。随着第三方应用(如流行的虚拟/增强现实 App 等)的流行,其强大的用户黏着度来协助感知平台征募用户执行感知任务。然而,这种合作存在复杂的利益关系,一方面,第三方应用存在操作代价,比如标记任务的感知区域为活动的兴趣点,以及设置操作界面等等。另一方面,突然强制让第三方应用的用户来执行感知任务会降低他们使用 App 的体验。因此,我们设计了激励机制来解决该场景下用户、平台和第三方应用之间复杂的策略交互关系。我们将第三方应用的协助引入到群智感知的激励机制设计当中,并使用三阶段斯坦克伯格博弈来建模这种第三方应用协助下的激励机制设计问题。我们系统分析了三阶段斯坦克伯格博弈的均衡策略,在第一阶段第三方应用先确定最优标记兴趣点的价格来,在第二阶段感知平台在标记价格的基础上,选择最优的任务集作为兴趣点让第三方应用标记,从而增加任务的参与者,在第三阶段,普通用户和 App 用户选择最优的任务来执行。最后,我们通过实验仿真来评估第三方应用协助对激励机制的作用,以及揭示该激励机制的性能。

### **(2) 盈利性和公平性保障的长期激励机制**

群智感知系统的持续发展需要保障平台的收益和防止用户的流失。达到这两个目

标需要设计合适的激励机制对任务合理定价，同时满足用户挑选的公平性，使得每个用户有机会参与执行感知任务而获利，从而达到长期激励的效果。我们提炼在这种场景下设计激励机制的挑战：该场景存在以下挑战：1) 群智感知系统存在动态性，需要进行多轮激励决策；2) 用户是动态到达的，而又因电量不足等其他因素而短暂离开平台；3) 请求者任务需求具有不确定性，激励机制面需要对任务进行快速响应的在线奖励定价。我们使用三阶段斯坦克伯格来建模该激励机制，所提出的激励机制要考虑到如何保证用户公平地被选为工作者，从而保障了用户长期参与到群智感知，此外，还需要满足用户的个体理性性质来揭露自己对任务子集的兴趣，即选择一个最优任务自己提交给平台，最后该激励机制还需要确保平台在长期上是盈利的（正的时间平均收益），以此确保群智感知系统的可持续发展。我们系统分析了每轮策略交互中的斯坦克伯格均衡点。在第一阶段，我们结合了 Zinkevich 在线梯度学习方法和李雅普诺夫优化的 **drift-plus-penalty** 技术设计了一种任务在线奖励定价算法，达到了平台收益和感知系统效益（任务被更多用户的执行）的性能折中  $[\mathcal{O}(1/\nu), \mathcal{O}(\nu)]$ ；在第二阶段我们提出了一种完全多项式近似算法（FPTAS）为每个计算能力不同的用户计算出一组  $(1 - \epsilon)$ -近优任务集作为兴趣信息提交给平台；在第三阶段我们提出一种基于集合多覆盖近似算法和李雅普诺夫优化技术的在线用户选择算法，平台根据用户汇报的兴趣集信息来选择用户，达到了用户公平性保障和平台征募奖励最小化的性能折中  $[\mathcal{O}(1/V), \mathcal{O}(V)]$ 。最后，我们对该激励机制进行仿真实验来验证其有效性和性能。

### (3) 面向多平台共存的激励机制

随着群智感知的发展，其产生海量数据所带来的巨大经济利益很有可能催生多个平台。多平台如何共存完成任务的分发和感知数据的收集是激励机制设计的重要研究内容。然而，现有的工作只假设了单一平台来协调任务请求者和移动用户，无法解决多平台共存场景所带来的挑战。为此，我们提出了面向多平台共存的激励机制来解决该场景下的复杂策略交互问题。当平台之间共存关系是竞争关系时候，我们把激励机制建模为多主导者多跟随者斯坦克伯格博弈。根据推导的博弈均衡策略，每个平台可以根据计算出的最优奖励进行任务定价，每个用户可以选择最好的平台去执行感知任务。当平台之间共存关系是合作关系时候，我们使用合作博弈中的纳什议价模型来建模多平台合作场景的激励机制，通过先证明一对多纳什议价模型的 NP 难解性，进而提出启发式议价解决方案。推导纳什议价解揭示了平台间如何合作共享感知数据以及以多少奖励进行合作，使得感知数据得到二次利用。所提的多平台共存激励机制不仅

能解决平台和参与者之间的策略交互，而且可以解决平台之间的策略交互。最后，我们通过实验仿真来评估面向多平台共存的激励机制性能，实验结果显示了平台通过合作共享感知数据提升了感知系统的收益。

## 1.4 论文结构

围绕面向群智感知的激励机制设计问题，本文从第三方应用协助的用户招募、盈利性与公平性的长期保障、质量信息未知的在线用户选择和多平台共存的策略交互关系等四个角度出发，对如何设计合适的激励机制展开研究。后续章节的内容编排如下：

第2章介绍了本文所使用的基本理论工具，包括博弈论、斯坦克伯格博弈、凸优化、多臂老虎机模型和李雅普诺夫优化技术。我们还调研和总结了与群智感知激励机制设计问题的相关工作，通过对比相关工作，我们总结本文所研究激励机制的不同和贡献点。

第3章研究了如何利用第三方应用的协助设计激励机制，使得平台的所有任务得到充足的用户参与，以持续稳定地提供感知服务。我们使用三阶段斯坦克伯格博弈来建模这种第三方应用协助下的激励机制设计问题，进而推导了博弈均衡策略以指示该群智感知场景下各方决策者最大化效益的同时保证群智感知系统的整体性能。

第4章解决了多时槽公平性和盈利性保证的动态群智感知长期激励机制设计问题。结合斯坦克伯格博弈来建模平台和用户的三阶段策略交互问题，并利用李雅普诺夫优化来解决由于考虑公平性和盈利性所产生与平台效益最大化冲突的问题。所推导的博弈均衡策略揭示了群智感知系统长期可持续运营的激励方案。

第5章提出了面向多平台共存的激励机制，分别使用多主导者-多跟随者斯坦克伯格博弈和纳什议价合作博弈来建模竞争情况和合作情况下群智感知激励机制的设计问题。通过推导博弈均衡和纳什议价解来表征激励机制的基本原理和激励方案。

第6章总结了本文的研究内容和主要贡献，并对未来的研究方向作出展望。



## 第2章 相关理论与研究工作

在本章，我们介绍与本文研究相关的理论工具，包括博弈论、斯坦克伯格博弈、多臂老虎机模型、凸优化、子模优化和李雅普诺夫优化技术，方便理解后文的方法部分内容。此外，我们还介绍群智感知进行综述介绍，引出激励机制设计的相关工作，通过对比相关工作，我们总结本文所研究激励机制的不同和贡献点。

### 2.1 博弈论与优化理论

#### 2.1.1 博弈论简介

在本文，我们主要使用博弈论（Game Theory）<sup>[38-40]</sup> 作为基本理论工具来研究激励机制中平台和用户之间的策略交互问题。而博弈论本身研究多决策者之间的交互关系，以寻求达互相最优的行为策略。博弈论可以看成是多目标优化的扩展，每个决策者的效益函数都是一个目标函数，效益函数不单单受所属决策者的策略影响，也取决于其他决策者的策略。一个博弈可以由三元组所组成：决策者集合  $\mathcal{N}$ ，策略组合空间  $S = S_1 \times S_2, \dots, S_N$  和效益函数组  $\mathcal{U} = (u_1(s), u_2(s), \dots, u_N(s))$ 。其中  $s_i \in S_i$  是决策者  $i$  在策略空间  $S_i$  上的一个策略  $s_i$ ， $u_i(s)$  是所有决策者的策略组合为  $s \in S$  时决策者  $i$  的效益函数。而在所有策略组合中，存在一组策略组合，使得每一决策者都无动机单方面偏离当前策略而最大化自己的效益函数，这种策略组合成为纳什均衡，正式定义为：

**定义 2.1** (纳什均衡). 对于任意决策者  $i$  以及任意策略  $s'_i \neq s_i^*$ ，在给定其他决策者  $-i$  的策略组合  $s_{-i}^*$ ，该参与者  $i$  的效益函数满足：

$$u_i(s_i^*, s_{-i}^*) \geq u_i(s'_i, s_{-i}^*). \quad (2.1)$$

由式2.1可以看出，纳什均衡下的策略组合  $s^*$  具有稳定性，因此可以表征一个博弈的解。从另外一个角度来看，博弈论是在给定博弈规则（反映于效益函数和策略组合）下，求解纳什均衡。而要想特定策略组合成为纳什均衡，需要反过来设计博弈规则，关于如何设计博弈规则的技术称作机制设计（Mechanism Design），也叫作逆向博弈论。机制设计是设计激励机制的主要理论工具，在群智感知中，我们希望平台制定

合适的奖励（定价策略）和用户参与执行感知任务的行为成为平台和用户策略交互博弈的均衡策略。平台的定价策略是预算范围内的任一奖励值，而用户的参与策略是执行任务的工作量（感知时间、存储资源、计算资源和通信资源）。平台的效益在于任务完成的数量或质量，用户的效益在于获得奖励的多少。

### 2.1.2 斯坦克伯格博弈

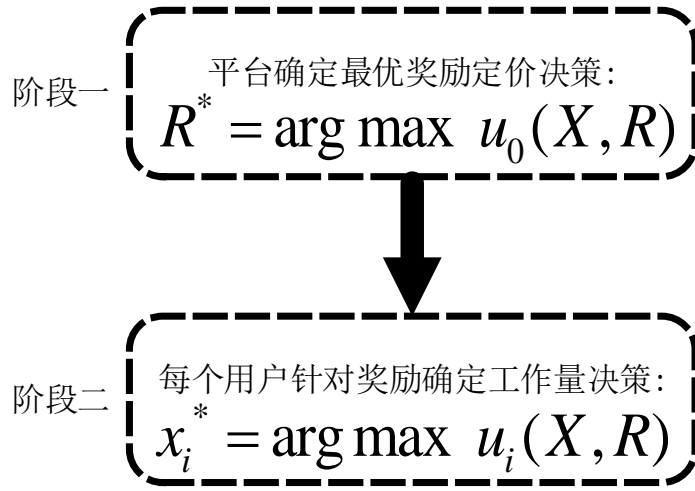


图 2.1 群智感知中斯坦克伯格博弈的过程

斯坦克伯格博弈 (Stackelberg game) 是一种不同决策者多阶段相继决策的阶段博弈，属于完全信息下的动态博弈。在激励机制设计<sup>[26]</sup>和边缘计算资源调度<sup>[41]</sup>等决策问题应用广泛。以群智感知为例，假设有  $N$  个用户，对于用户  $i$  来说，其策略是选择工作量  $x_i$  去执行感知任务以获得奖励，其效益函数是  $u_i(x_i)$ 。而对于平台来说，其策略是确定奖励  $R$  以激励更多用户参与执行感知任务，其效益函数是  $u_0(R)$ 。如图2.1所示，基于斯坦克伯格博弈的激励机制有两个阶段：1) 在第一阶段，平台确定最优的奖励  $R^*$  来激励用户参与执行感知任务的同时最大化其效益函数  $u_0(R^*)$ ；2) 针对平台宣布的奖励定价决策  $R^*$ ，每个用户  $i$  确定最优的工作量  $x_i^*$  来参与执行感知任务，最大化其效益  $u_i(x_i^*)$ 。

在每一阶段决策者使用最优策略来达到相应效益的最大化，所有阶段最优策略组合叫做斯坦克伯格均衡（纳什均衡在阶段博弈的扩展）。推导斯坦克伯格均衡通常使用后向推断法。即先假设前一阶段的策略已知来推导当前阶段的最优策略，然后带入

前一阶段，从而得到各个阶段最优的斯坦克伯格均衡。使用斯坦克伯格博弈来设计激励机制时需要注意斯坦克伯格均衡的存在性和唯一性，满足这两个条件需要从确定决策者效益函数着手。

### 2.1.3 凸优化

由于具有全局最优解的性质，凸优化在设计算法中扮演着重要角色。而把一个问题形式化凸优化时，这个问题可以被高效地求解，因为求解凸优化问题存在高效的算法，如求解凸优化的 KKT 条件和内点法。因此，使用凸优化技术的难点在于判断求解问题是否属于凸优化问题。凸优化技术的另外一个优点是在于得到一个问题的解的界限（上下界），因为不管一个问题是否为凸优化问题，其对偶问题一定是凸优化问题<sup>[42]</sup>。而通过求解凸优化问题的 KKT 条件，我们可以得到关于问题的闭式解，这对算法的设计具有重大意义。在群智感知中，我们可以假设用户的感知代价为凸的，进而可以形式化用户效益最大化问题为凸优化问题，由此可以得到激励机制设计的最优策略方案。

为了便于描述凸优化问题，我们先给出以下定义：

**定义 2.2.** 集合  $C$  被称作凸集，如果对于任意  $x_1, x_2 \in C$  和任意  $\theta$  ( $0 \leq \theta \leq 1$ )，满足：

$$\theta x_1 + (1 - \theta)x_2 \in C. \quad (2.2)$$

**定义 2.3.** 函数  $f : \mathbb{R}^n \rightarrow \mathbb{R}$  是凸的，如果定义域  $\text{dom} f$  是凸集，且对于任意  $x, y \in \text{dom} f$  和任意  $0 \leq \theta \leq 1$ ，有：

$$f(\theta x + (1 - \theta)y) \leq \theta f(x) + (1 - \theta)f(y). \quad (2.3)$$

**定义 2.4.** 函数  $f : \mathbb{R}^n \rightarrow \mathbb{R}^m$  是放射的，如果它是一个线性函数和一个常数的和，即具有  $f(x) = Ax + b$  的形式，其中  $A \in \mathbb{R}^{m \times n}$ ,  $b \in \mathbb{R}^m$ 。

凸优化问题一般形式化如下：

$$(COPT) \quad \begin{aligned} & \min f_0(x) \\ & s.t. \quad \begin{cases} f_i(x) \leq 0, i = 1, \dots, m, \\ a_j^T x = b_j, j = 1, \dots, p, \end{cases} \end{aligned}$$

其中,  $x \in \mathbb{R}^n$ , 问题 COPT 还需要满足以下要求:

- 可行集  $\mathcal{D} = \bigcap_{i=0}^m \text{dom} f_i$  是凸的;
- 目标函数  $f_0$  是凸的;
- 不等式约束函数  $f_i$  ( $i = 1, \dots, m$ ) 是凸的;
- 等式约束函数是放射的。

求解问题 COPT 的 KKT 最优性条件可以得到该问题最优解的闭式解, 下面我们举信道功率分配的例子来说明如何求解 KKT 条件得到凸优化问题的最优闭式解。假设需要将功率分配给  $n$  个信道。变量  $x_i$  表示分配给第  $i$  个信道的发射功率,  $\log(\alpha_i + x_i)$  表征信道  $i$  的通信能力或通信速率, 因此, 将值为一的总功率分配给不同的信道, 使得总通信速率最大的问题可以形式化为以下凸优化问题:

$$(PAOPT) \quad \begin{aligned} \min \quad & - \sum_{i=1}^n \log(\alpha_i + x_i) \\ \text{s.t.} \quad & \begin{cases} x \succeq \mathbf{0}, \\ \mathbf{1}^T x = 1. \end{cases} \end{aligned}$$

对不等式约束  $x^* \succeq \mathbf{0}$  引入拉格朗日乘子  $\lambda^* \in \mathbb{R}^n$ , 对等式约束  $\mathbf{1}^T x^* = 1$  引入一个拉格朗日乘子  $\nu^* \in \mathbb{R}$ , 我们得到如下 KKT 条件:

$$\begin{cases} x^* \succeq \mathbf{0}, \\ \mathbf{1}^T x^* = 1, \\ \lambda^* \succeq \mathbf{0}, \\ \lambda_i^* x_i^* = 0, i = 1, \dots, n, \\ -\frac{1}{\alpha_i + x_i^*} - \lambda_i^* + \nu^* = 0, i = 1, \dots, n. \end{cases} \quad (2.4)$$

可以直接求解这些方程得到  $x^*$ ,  $\lambda^*$  和  $\nu^*$ 。注意到  $\lambda^*$  在最后一个方程里是一个松弛变



量，所以可以消去，得到：

$$\begin{cases} x^* \succeq \mathbf{0}, \\ \mathbf{1}^T x^* = 1, \\ x_i^* (\nu^* - \frac{1}{\alpha_i + x_i^*}) = 0, i = 1, \dots, n, \\ \nu^* \geq \frac{1}{\alpha_i + x_i^*}, i = 1, \dots, n. \end{cases} \quad (2.5)$$

如果  $\nu^* < \frac{1}{\alpha_i}$ ，只有当  $x_i^* > 0$  时最后一个条件才成立，而由第三个条件可知  $\nu^* = \frac{1}{\alpha_i + x_i^*}$ 。求解  $x_i^*$ ，我们得到结论：当  $\nu^* < \frac{1}{\alpha_i}$ ，有  $x_i^* = \frac{1}{\nu^*} - \alpha_i$ 。如果  $\nu^* \geq \frac{1}{\alpha_i}$ ，那么  $x_i^* > 0$  不成立，这是因为如果  $x_i^* > 0$ ，那么  $\nu^* \geq \frac{1}{\alpha_i} > \frac{1}{\alpha_i + x_i^*}$ ，违背了第三个互补松弛条件。因此，如果  $\nu^* \geq \frac{1}{\alpha_i}$ ，那么  $x_i^* = 0$  成立。总结上述分析，可得  $x_i^*$  的闭式解：

$$x_i^* = \begin{cases} \frac{1}{\nu^*} - \alpha_i & \nu^* < \frac{1}{\alpha_i}, \\ 0 & \nu^* \geq \frac{1}{\alpha_i}. \end{cases}$$

上式可简写为  $x_i^* = \max\{0, \frac{1}{\nu^*} - \alpha_i\}$ 。为了求解拉格朗日乘子  $\nu^*$  的值，将  $x_i^*$  的闭式解打入条件  $\mathbf{1}^T x^* = 1$ ，得到：

$$\sum_{i=1}^n \max\{0, \frac{1}{\nu^*} - \alpha_i\} = 1. \quad (2.6)$$

由于方程左端是关于  $\frac{1}{\nu^*}$  的分段增函数，分割点为  $\alpha_i$ ，因此，式2.6中的方程存在唯一确定的解。

关于凸优化技术的具体细节，感兴趣的读者可参考文献<sup>[42]</sup>。

#### 2.1.4 李雅普诺夫优化

李雅普诺夫优化<sup>[43]</sup>技术一般用于解决带有时间平均目标函数和时间平均约束的随机规划问题（stochastic programs）。不同于线性规划和凸规划，随机规划是关于多轮决策且牵涉随机变量的动态问题，而线性规划和凸优化问题只建模单轮决策的静态问题。此外，随机变量还可能组成一个队列，优化目标函数的同时需要维持队列的稳定性。由于目标函数和约束条件存在随机量，随机规划的目标函数在某一时槽可能得不到最优化，约束条件在某一时槽可能无法同时满足（即存在冲突条件）。因此，随机规划问题在某一时槽的解是使得时间所有平均约束条件得到满足，随机规划关联的队

列得到稳定，并让目标函数尽可能得到最优化。这个求解过程可由一个算法来实现，而且需要在当前随机变量的值下进行决策。在群智感知的激励机制设计问题中，所牵涉到的随机量包括用户的当前电量、感知质量、任务的随机到达率以及对应的支付费用等等。

队列概念在求解随机规划问题扮演者重要角色，需要注意的是，这里提到的队列是一种抽象概念的队列，队列里面的元素为随机量的累加值，称为队列长度（backlog），当前随机量的值“入队列”，会增加队列长度，而决策变量会使一部分队列的量“出队列”，会减少队列长度。我们可以把所有随机规划问题的时间平均约束条件转换成虚拟队列，并建立时间平均约束条件和虚拟队列在某种角度上的等价关系。这样，随机规划问题就变成了最优化时间平均目标函数的同时，使得问题对应的所有得到稳定性得到满足。考虑一个多时槽决策问题，假设存在  $N$  个队列，其当前队列长度记作  $Q_i(t)$  ( $i \in \{1, 2, \dots, N\}, t = 1, 2, \dots$ )，并记  $\mathbf{Q}(t) = (Q_1(t), Q_2(t), \dots, Q_N(t))$ 。我们定义队列系统的稳定性如下：

**定义 2.5.** 一个队列系统  $\mathbf{Q}(t)$  是强稳定的当且仅当以下条件成立：

$$\limsup_{t \rightarrow \infty} \sum_{\tau=0}^t \mathbb{E} \left[ \sum_{i=1}^N Q_i(\tau) \right] < \infty. \quad (2.7)$$

类似于向量范数反映向量的大小，我们定义一个标量函数来衡量队列总长度大小：

$$L(\mathbf{Q}(t)) = \frac{1}{2} \sum_{i=1}^N \omega_i Q_i^2(t), \quad (2.8)$$

这里的  $\omega_i$  表示队列  $Q_i(t)$  的权重。为了公平处理每一个队列，对于每一个队列  $i$ ，我们设  $\omega_i = 1$ 。式 (2.8) 的函数  $L(\mathbf{Q}(t)) \geq 0$  称作李雅普诺夫函数（Lyapunov function）<sup>[43]</sup>，它有以下三个特性：1) 当  $L(\mathbf{Q}(t)) = 0$  时，这意味着时槽  $t$  的所有虚拟队列都为空；2) 在时槽  $t, L(\mathbf{Q}(t))$  的值越小，则所有虚拟队列长度就越小；3) 在时槽  $t, L(\mathbf{Q}(t))$  的值越大，则至少存在一个虚拟队列，其队列长度很大。

下面的引理粗略地揭示了满足时间平均约束条件和稳定对应虚拟队列的关系：

**引理 2.1.** 一个决策算法满足随机规划问题中的时间平均约束条件当且仅当对于的虚拟队列在算法决策过程中维持队列的稳定性。

我们把两个连续时槽的李雅普诺夫函数的改变量称作李雅普诺夫漂移（Lyapunov

drift), 数学上的正式定义是  $\Delta(\mathbf{Q}(t)) \triangleq \mathbb{E}[L(\mathbf{Q}(t+1)) - L(\mathbf{Q}(t)) | \mathbf{Q}(t)]$ 。直观上, 如果决策算法在每轮  $t$  都贪婪最小化李雅普诺夫漂移  $\Delta(\mathbf{Q}(t))$ , 那么所有队列的长度都趋向变小, 从而使得队列系统  $\mathbf{Q}(t)$  稳定。下面定理揭示了队列系统稳定的充分条件:

**定理 2.1** (李雅普诺夫漂移). 考虑队列系统  $\mathbf{Q}(t)$ , 其李雅普诺夫函数由式2.8给出, 并且满足  $\omega_i = 1$  ( $i \in \{1, 2, \dots, N\}$ ) 且  $\mathbb{E}[L(\mathbf{Q}(t))] < \infty$ 。假设存在常数  $B > 0$  和  $\epsilon > 0$ , 使得下面漂移条件对于所有时槽  $\tau \in \{0, 1, 2, \dots\}$  和所有可能的队列长度值  $\mathbf{Q}(t)$ :

$$\Delta(\mathbf{Q}(t)) \leq B - \epsilon \sum_{i=1}^N |Q_i(t)|, \quad (2.9)$$

成立, 则如果  $\epsilon > 0$ , 则所有队列稳定且下式成立:

$$\limsup_{t \rightarrow \infty} \frac{1}{t} \sum_{\tau=0}^{t-1} \sum_{i=1}^N \mathbb{E}[|Q_i(\tau)|] \leq \frac{B}{\epsilon}. \quad (2.10)$$

然而, 单单最小化李雅普诺夫漂移  $\Delta(\mathbf{Q}(t))$  只能使得随机规划的约束得到满足, 而时间平均目标函数未必得到最优化。为了协同优化李雅普诺夫漂移  $\Delta(\mathbf{Q}(t))$  和时间平均目标函数, 我们需要用控制参数  $V$  关联时间平均目标函数作为“惩罚”项, 加到李雅普诺夫漂移  $\Delta(\mathbf{Q}(t))$ , 即  $\Delta(\mathbf{Q}(t)) + V \text{penalty}(t)$ , 其中  $V \geq 0$  作为来“惩罚”项的权重, 表示在最优化李雅普诺夫漂移 (稳定队列以满足时间平均约束条件) 和时间平均目标函数之间进行折中我们把这个技术称作漂移加惩罚技术, **drift-plus-penalty**。假设我们要最小化一随机过程  $y(t)$ , 其最小值为  $y_{\min}$  (即  $\mathbb{E}[y(t)] \geq y_{\min}$ )。我们希望过程  $y(t)$  的时间平均值小于等于 (接近) 一目标值  $y^*$ 。过程  $y(t)$  一般表示随时间  $t$  所采取的决策所造成的损失或效益, 如功率消耗、包丢失率和群智感知中平台的奖励代价。在以下定理中总结随机规划问题的李雅普诺夫优化技术的理论结果:

**定理 2.2** (李雅普诺夫优化). 考虑一个随机规划问题, 最小化一随机过程  $y(t)$ , 满足  $\mathbb{E}[y(t)] \geq y_{\min}$ , 随机规划存在队列系统  $\mathbf{Q}(t)$ , 其李雅普诺夫函数由式2.8给出, 并且满足  $\omega_i = 1$  ( $i \in \{1, 2, \dots, N\}$ ) 且  $\mathbb{E}[L(\mathbf{Q}(t))] < \infty$ 。我们期望  $y(t)$  随时间进行决策的过程中接近于目标值  $y^*$ 。假设存在常数  $B > 0$ ,  $V$ ,  $\epsilon$ , 使得下面漂移条件对于所有时槽  $\tau \in \{0, 1, 2, \dots\}$  和所有可能的队列长度值  $\mathbf{Q}(t)$ :

$$\Delta(\mathbf{Q}(t)) + V \mathbb{E}[y(t) | \mathbf{Q}(t)] \leq B + V y^* - \epsilon \sum_{i=1}^N |Q_i(t)|, \quad (2.11)$$

成立，则如果  $\epsilon > 0$ ，则所有队列稳定。如果  $V > 0$ ， $\epsilon > 0$ ，则下面两个不等式成立：

$$\limsup_{t \rightarrow \infty} \frac{1}{t} \sum_{\tau=0}^{t-1} \mathbb{E}[y(\tau)] \leq y^* + \frac{B}{V}, \quad (2.12)$$

$$\limsup_{t \rightarrow \infty} \frac{1}{t} \sum_{\tau=0}^{t-1} \sum_{i=1}^N \mathbb{E}[|Q_i(t)|] \leq \frac{B + V(y^* - y_{\min})}{\epsilon}. \quad (2.13)$$

从式2.12和2.13可以解读到李雅普诺夫优化技术的思想：对于任意参数  $V > 0$ ，如果我们设计一个决策算法在每个时槽满足式2.11的漂移条件，那么时间平均目标函数满足式2.12的关系，因此，时间平均目标函数要么小于目标值  $y^*$ ，要么超过目标值  $y^*$  不多于  $\mathcal{O}(1/V)$ ，这个偏差随着参数  $V$  的增加而减小。然而式2.13表明，增加参数  $V$  会使得所有队列的时间平均长度变大，而这个增加不超过  $\mathcal{O}(V)$ 。因此，李雅普诺夫优化技术存在性能-队列长度的折中区间  $[\mathcal{O}(1/V), \mathcal{O}(V)]$ 。值得注意的是， $[\mathcal{O}(1/V), \mathcal{O}(V)]$  性能折中不一定是最优的。在单队列信道衰退的无线系统中的能量调度算法达到了  $[\mathcal{O}(1/V), \mathcal{O}(\sqrt{V})]$  能量-延迟折中<sup>[44]</sup>。随后，文献<sup>[45-47]</sup> 使用了指数形式的李雅普诺夫函数和增强漂移变向方法（aggressive drift steering）拓展了上述的性能折中，取得了  $[\mathcal{O}(1/V), \mathcal{O}(\log(V))]$  的结果。

总得来说，使用李雅普诺夫优化技术来设计算法优化随机规划的过程如下：

- 1) 选取控制参数  $V$ ，推导出漂移加惩罚项作为每一个时槽的决策准则；
- 2) 每一时槽中，贪婪地选择一个决策变量来最优化（最小化或最大化）漂移加惩罚项；
- 3) 依据更新方程更新队列长度。

关于李雅普诺夫优化技术的具体细节，感兴趣的读者可参考文献<sup>[43]</sup>。

## 2.2 群智感知的激励机制相关工作

关于群智感知的几个重要应用有：用于构建城市蜂窝网及 Wi-Fi 覆盖地图的 Sensorly<sup>[14]</sup>、提供道路交通拥塞信息的 NericeI<sup>[48]</sup> 和 Vtrack<sup>[49]</sup>、感知周围环境的 PIER<sup>[50]</sup>，以及构建城市噪声地图的 Ear-Phone<sup>[11]</sup>。本文关注于研究群智感知中的激励机制设计问题。根据这个领域的国内外研究现状，我们可以把群智感知中基于博弈论的激励机

制可以划分为：基于非合作博弈的激励机制和基于合作博弈的激励机制。基于非合作博弈的激励机制可以进一步划分为基于斯坦克博弈的激励机制、基于拍卖的激励机制和基于外部性的激励机制。根据拍卖类型的不同，基于拍卖的激励机制可以分为：基于逆向拍卖的激励机制、基于全支付拍卖的激励机制和基于双向拍卖的激励机制。基于合作博弈的激励机制可以分为：基于契约模型的激励机制和基于纳什议价模型的激励机制。不同博弈模型关注的场景不一样，其面临的技术挑战也不同，这造成了对应的激励机制设计原理不同。我们首先调研基于不同博弈模型的激励机制相关研究工作，最后总结本文使用斯坦克伯格博弈来建模激励机制设计问题的原因。我们将这种分类总结在图2.2。关于群智感知更详细的内容可以参考国内综述<sup>[1-3,7,16,51]-54]</sup>和国外综述<sup>[5,6,55-63]</sup>。

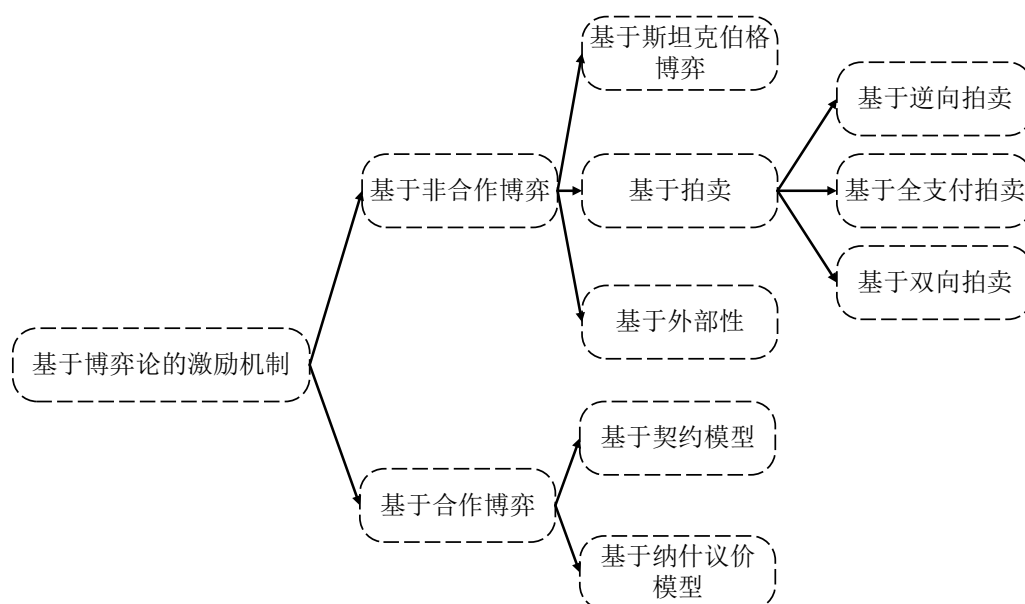


图 2.2 群智感知中基于博弈论的激励机制的分类

### 2.2.1 基于斯坦克伯格博弈的激励机制

在群智感知中，感知平台和用户相继做决策。感知平台先确定以多少奖励激励用户参与执行感知任务，并把这个定价的奖励和相应的任务通知给用户群。平台宣布奖励策略后，每个用户回应基于该奖励策略的参与度（如执行时间、感知资源使用的多少）。基于这个激励过程的相继决策特性，大部分研究工作使用动态博弈来解决激励机制设计问题，并把激励机制建模为一个阶段博弈。通过推导阶段博弈的子博弈完美



均衡来得到激励机制的方案。斯坦克伯格博弈就是典型的阶段博弈。在斯坦克伯格博弈中，所有玩家被分为主导者和跟随者两种决策，其中感知平台作为主导者首先制定策略确定奖励方案（对任务的定价或者对用户的奖励），而所有用户作为跟随者同时确定对感知任务的参与程度来响应主导者的决策。由于自私性，每个用户都想从策略控件中选择最佳策略来最大化自己的效益函数。因此，求解出斯坦克伯格均衡（子博弈完美均衡）可以视为最佳的激励方案。为了求出斯坦克伯格均衡，一般使用的方法是后向推导法，即分析的起点是先假设第一阶段的决策已给定来分析第二阶段跟随者的最优策略，得到跟随者的最优参与策略后，我们可以分析主导者在第一阶段的最优奖励策略。这个分析方法得到的策略组合已被证明是斯坦克伯格均衡。

根据这个思路，Yang 等人<sup>[26]</sup> 早期在 2012 年计算机网络顶级会议 MobiCom 上率先使用斯坦克伯格博弈建模以平台为中心的激励机制，称作 MSensing 博弈。在分析 MSensing 博弈的斯坦克伯格均衡时，他们使用了后向推导法。并进一步把第二阶段所有用户的参与决策问题建模为一个非合作博弈，称作感知时间确定博弈，STD。由于他们设定的每个玩家效益函数为凸的，该博弈具有唯一的均衡点。其他工作将更多特征因素考虑到设计基于斯坦克伯格博弈的激励机制，比如用户异构性和社会网络效应。Nie 等人<sup>[64]</sup> 提出的基于斯坦克伯格博弈激励机制考虑到了社会网络效应的影响，Cheung 等人<sup>[65]</sup> 在此基础上还考虑了用户异构性的影响。尽管考虑了其他印象的影响，但是推导斯坦克伯格均衡点的方法一样使用了后向推导法。唯一区别是考虑这些因素会导致用户的效益函数形式的不同。Xiao 等人<sup>[66]</sup> 提出安全群智感知博弈并研究了当平台汇报评定误差率一定的情况下如何激励用户选择实际感知精度。他们使用了斯坦克伯格博弈来建模平台和用户的交互。与前面的几个工作不同，他们并没有把收益函数设定为凸函数形式，但是斯坦克伯格均衡的唯一性可以通过分析期望收益函数而得到。在不同的群智场景下（如以图像为中心的群智感知应用、污染监测、信息质量的评定等）可以推导出不同斯坦克伯格均衡的闭式解。

这些工作都存在一些信息对称的假设，比如用户的感知代价参数和效益函数的形式对平台来说是事先知道的。这个信息对称假设是斯坦克伯格博弈框架的通用假设，在许多现实情况是不切实际的，然而，对于一个稳定的群智感知系统来说可以视为成立。因为这样稳定的群智感知系统已经积累了大量的用户数据，平台可以从历史数据当中推断用户的信息和参数、以及采用合适的效益函数形式。

## 2.2.2 基于拍卖模型的激励机制

正如群智感知早起开拓工作<sup>[26]</sup>指出的那样,除了以平台为中心的群智感知系统外,还存在以用户为中心的群智感知系统。以平台为中心的群智感知系统的激励机制设计问题主要以斯坦克伯格博弈来建模,而以用户为中心的群智感知系统的激励机制则更适合以拍卖模型来建模。这是因为拍卖把群智感知过程建模为一个数据交易市场,在这个市场中,用户具有更多的主动控制权。用户作为数据提供者,和其他用户竞标去提供感知服务,一旦赢标则获得金钱奖励。平台作为拍卖商从用户群请求数据收集服务。在这个过程当中,平台不知道用户的私人信息,比如用户类型、实际感知代价和位置。每个用户提出一个标,并汇报给平台,代表该用户的保留价和执行感知任务造成的感知开销。而且竞标用户之间都不知道对方的信息。因此,信息不对称是基于拍卖模型的激励机制的一大特点。尽管存在信息不对称,拍卖模型依然可以使用博弈论中的机制设计理论(逆向博弈论)来分析。这个分析方法主要关注拍卖设计的三大目标:a)激励兼容性(防策略性);b)个体理性;c)计算有效性。这些分析所依托的理论是基于显示原理(又称作梅森定理)。它把一个拍卖模型的设计分为两部分:a)分配规则(确定谁是赢家);b)支付规则(给所有竞标者计算奖励值)。这两个规则设计的好坏直接影响上述三大目标。而根据设计拍卖中的两个规则的不同,可以把基于拍卖模型的激励机制划分为基于逆向拍卖的激励机制、基于全支付拍卖的激励机制和基于双向拍卖的激励机制。

Yang 等人<sup>[26]</sup>设计了一个以用户为中心的逆向拍卖激励机制,他们首先观察到了在这个情形下的用户收益函数具有子模性,并提出了基于局部搜索的方式来设计分配规则来最大化平台的收益。对于支付规则,他们证明支付用户的标价会违反了激励兼容性目标。所以他们进一步设计分配规则,根据一个临界值支付用户,这个临界值为用户不管是否成为赢家可以出的最大标价,也称之为 VCG 价格。他们提出的逆向拍卖激励机制可以作为一个标准方案,然而这个激励方案只能适用于单一请求者的情形。Feng 等人<sup>[67]</sup>提出了一个名为 TRAC 的真实可靠拍卖机制激励用户合作地执行感知任务。每个用户可以对一组任务出标,他们证明了此情形下的分配规则是 NP 难解的,并规约到最小带权的集合覆盖上,因此设计了基于最小带权的集合覆盖的贪婪算法,达到了一定的近似比保证。对于支付规则他们的方案类似于 Yang 等人的工作<sup>[26]</sup>。Feng 的工作在实施分配规则时候,使用了用户的私人信息,这些私人信息平台是不可以访问到的,这一定程度上违反了信息不对称属性。此外,该工作只能使用于单一

感知平台,为此,他们在文献<sup>[68]</sup>考虑了多平台以及多平台之间的竞争关系。Zhang 等人<sup>[69]</sup>将前面的感知任务组合成一个感知工作,并正式定义一个感知工作是单独不可分的感知任务组成的多重子集。根据请求者数目和竞标数目划分为三个子模型来研究激励机制:单请求者单标模型、单请求者多标模型和多请求者多标模型。前两个都是基于逆向拍卖的激励机制,而后一个属于双向拍卖的激励机制。Chen 等人<sup>[70]</sup>使用广义二价拍卖来建模激励机制,分配规则是出价高者成为赢家,由于要取多个赢家,因此可以对标进行排序。支付规则为 VCG 价格。然后,此种拍卖类型所建模的激励机制并不是真实可靠的,用户可以谎称报价而称为赢家,即违反了激励兼容性。Hu 等人<sup>[71]</sup>把上述几个工作结合起来设计面向车辆群智感知的激励机制。Gao 等人<sup>[72]</sup>将逆向拍卖和李雅普诺夫优化技术结合起来设计激励机制,分配规则为选择用户来最大化总的社会福利效益函数服从长期公平性,从而保证每个用户有机会成为赢家而达到长期激励的目的。在支付规则方面计算赢家的 VCG 价格作为奖励。Wen 等人<sup>[73]</sup>提出了一个基于数据质量的数据驱动拍卖激励机制,以数据质量而不是用户的出标设计分配规则和支付规则。Zheng 等人<sup>[74]</sup>解决两个群智感知数据交易中的两个相关问题:收益最大化和支付最小化。针对这两个问题,他们提出了两个机制:VENUS-PRO 和 VENUS-PAY。VENUS-PRO 用于挑选感知任务的兴趣点(POI),而 VENUS-PAY 用于从用户中挑选工人。其中 VENUS-PAY 使用逆向拍卖来进行设计,具有防策略和最优支付属性。

对于全支付拍卖,技术难点在于如何设计好的支付规则,因为在这种类型拍卖中,所有用户都被选为赢家。Palantino 等人<sup>[75]</sup>在众包中研究了多任务全支付拍卖的激励机制。由于每个用户竞争去执行一个感知任务而获得奖励,每个任务被建模为一场竞赛,并且每个竞赛为一个全支付拍卖。然而,支付规则只奖励贡献最好的赢家用户,所以会造成失败的用户得不到激励。Luo 等人<sup>[76]</sup>研究了基于全支付拍卖的收益最大化激励机制。他们推导出最优奖励函数来确定严格个体理性在不完全信息,反风险个体和随机用户总体的情况下。他们的扩展工作<sup>[77]</sup>进一步找到了全支付的简便性和风险消除的全支付激励机制。然而,他们对使用场景进行了一定的假设:用户的类型和对奖励的信念是事先已知的。他们的工作没有为均衡点提供闭式解。为了松弛这个假设统一性假设,他们在文献<sup>[78]</sup>使用了非对称全支付拍卖设计了一组奖励函数,这个激励机制鼓励不同用户根据他们自己的类型贡献感知能力。

Wei 等人<sup>[79]</sup>提出了一个在线双向拍卖框架用于解决动态群智感知的激励机制设



计问题。Huang 等人<sup>[80]</sup>解决了来自多请求者的多任务分配问题，并提出了基于双向拍卖的激励机制来最大化所有请求者的最小效用值。把多请求者、平台和用户之间的交互过程建模为一个双向拍卖。Zhang 等人<sup>[81]</sup>设计了一个多市场双向拍卖机制用于群智感知系统中，解决了多市场中的公平交易问题。提出的拍卖机制包含拍卖模块、准入模块和存活模块。Jin 等人<sup>[82]</sup>提出一个新型多请求者双向拍卖机制，称作 CENTURION，包含激励模块和数据融合模块。Zhai 等人<sup>[83]</sup>考虑了一个组合双向拍卖机制来分配感知任务，在 D2D 群智感知中，他们证明了分配规则的 NP 难解性，使用整数规划进行规约。他们设计了近似算法和启发式算法来确定分配规则，以此减少计算复杂度。

### 2.2.3 基于外部性的激励机制

通常，一个博弈中玩家的效益函数直接受到其他玩家策略的影响，甚至是玩家的总数量，并且这部分影响没有得到直接的补偿，这种现象被称作为外部性。如果受到影响的效益得到增加，我们称之为正外部性，否则我们称之为负外部性。正外部性的例子有社交媒体的价值，会随着使用它的人数而增加。而负外部性的例子有流量拥堵（如交通和通信网络），会减少使用它的效益。正外部性也叫作网络效应，由于玩家向其他玩家对齐他们自己的行为，它们的效益会增加。正是由于网络效应，均衡点中的策略看起来有点反直觉。例如，一些用户自愿去贡献资源，尽管没有得到直接补偿。基于这个观察，平台可以在群智感知中设计激励机制时候考虑网络效应来吸引更多的参与者。在此情形下，用户的效益不仅受到外部平台提供金钱奖励的影响，还受到内部所有用户造成的网络效益等内部奖励影响。因此，当设计激励机制时候考虑到网络效应，平台可以节省许多开支。实际上，在群智感知中结合网络效应来设计激励机制是合理的，这是因为从用户中收集到的感知数据后，合理的进行数据分析和融合则可以精确地反应了环境和个人的有用信息和状态，这又反过来有助于人们的日常生活，因此对移动用户产生了正外部性。

现有的工作研究激励机制中的外部金钱激励如何受到网络效应的内部奖励影响。Chen 等人<sup>[84]</sup>研究了在群智感知中考虑到网络效应的激励机制，并形式化了一个策略参与博弈。网络效应被建模为一个正因子，加到每个用户的效益函数，这个正因子与参与度有关。他们研究了参与度的动态性并推导出了参与度的均衡点。基于均衡参与度，平台设计了关于用户努力度的最优的固定外部金钱奖励方案和灵活的外部金钱奖励方案。然而，他们的工作假设了网络效应因子对所有用户来说是一样的，而没考虑

到不同用户对网络效应的异构性。所以, Nie<sup>[64]</sup> 和 Cheung<sup>[65]</sup> 等人分别在他们的的工作中考虑了异构网络效应,并结合到了所设计的基于斯坦克伯格博弈的激励机制。增加用户内部奖励的其他外部性形式有声誉值,这些典型的工作有<sup>[85-88]</sup>。Dobakhshari 等人<sup>[88]</sup>提出了基于声誉的激励机制,结合了契约模型,并把激励机制设计问题形式化为一个重复博弈。Ma 等人<sup>[86]</sup>结合了进化博弈模型来设计基于声誉的激励机制,并建模用户和请求者之间的交互为一个进化博弈。然而,这些工作只考虑了一个用户,假设了声誉是线性函数,并没有考虑开支约束。

#### 2.2.4 基于纳什议价模型的激励机制

群智感知中,平台和用户在数据收集上进行合作有共同的利益,但是如何进行合作上需要进一步协商。一方面,移动设备的增长不仅让用户更容易获得感知数据,而且为平台从用户中收集大规模感知数据带来了新的机遇。通过聚合分析所收集的感知数据来提供服务,反过来又为用户提供了便利。另一方面,提供更多的奖励给用户会减少平台收益,尽管增加了用户的效益,反之亦然。因此,平台和用户存在冲突的利益关系,需要进一步协调折中。在这种情形下为群智感知设计激励机制需要使用合作博弈中的纳什议价模型。现有已有许多工作使用纳什议价理论来建模群智感知中执行任务的合作问题,并求解所形式化的合作问题,得到纳什议价解来表征激励机制。纳什议价解将在合作中所得到的收益等份地分配给合作双方(平台和用户),只有这样平台和用户才在合作收集感知数据这项任务上达成协议。纳什议价解也表明了平台和用户如何采取策略来最大化各自双方的效益。值得注意的是纳什议价解可以使得所有用户的效益最大化。

很多现有工作只分析了精确的纳什议价问题,然后这往往是很难以求解(NP 难),他们并没有提供近似方案。He 等人<sup>[89]</sup>使用纳什议价模型研究了不同用户对不同任务的公平定价问题。这是对计算最优任务分配的重要补充,通过提供在纳什议价解中的公平价格。Zhan 等人<sup>[90]</sup>通过一对多的纳什议价框架研究了以平台为中心的群智感知的激励机制,他们不仅分析了纳什议价的顺序对激励结果的影响,还探索了同时纳什议价的激励方案。他们还把所推导的纳什议价框架推广到机会群智感知中的激励机制设计研究中<sup>[91,92]</sup>。

### 2.2.5 基于契约模型的激励机制

上述激励机制的研究要么基于完全信息假设来分析最佳策略，要么假设所有玩家都是自我约束来执行所计算的均衡解。很多情况并不满足这种假设，因此，更加适合的理论工具是契约论。契约论所设计的激励机制允许关于用户的信息是不对称的，平台不可获得的。更适用于需要外部约束来完成群智感知的任务执行和激励约束。在群智感知中，关于用户的信息不对称包括隐藏类型和隐藏动作。隐藏类型指的是用户的类型（感知代价、位置、感知能力）是私人的信息，对平台来说是透明的。因此，平台很难确定精准的激励和任务分配。隐藏动作是指，当平台把任务分配给用户后，实际执行的感知动作和用户做了多少工作量，平台是不得而知的。契约论中的两类模型经常用于解决这两种信息不对称：逆向选择和道德风险。在逆向选择中，平台设计一些契约选项，让不同类型的用户选择符合自己类型的选项来执行感知任务，并获得相应的奖励。而道德风险模型则设计一些动作奖励表，用户执行多少工作量，则获得多少奖励。这些工作量可以使用系统性能增益来衡量。Zhao<sup>[93]</sup> 和 Zhang<sup>[94]</sup> 等人使用了道德风险模型来设计群智感知中的激励机制。Li 等人<sup>[95]</sup> 设计了基于契约的激励机制，并考虑数据质量的影响。所考虑的场景包括完全信息场景和不完全信息场景。完全信息场景下的设计问题是基于道德风险的框架解决。而不完全信息的场景是基于逆向选择的框架解决。Dobakhshari 等人<sup>[88]</sup> 提出了基于声誉的激励机制，结合了契约模型，先进行逆向选择的设计，后解决道德风险问题。Zhang 等人<sup>[96]</sup> 研究了一个面向隐私保护的契约模型激励机制。把激励机制建模为逆向选择问题。

本文主要使用斯坦克伯格博弈来建模激励机制的设计问题，主要原因有：1) 本文主要关注的是以平台为中心的群智感知场景，用户则是无意识的被动参与群智感知中；2) 作为多阶段完全信息的动态博弈，斯坦克伯格博弈符合了群智感知中请求者、平台和用户的交互过程；3) 斯坦克伯格博弈倾向于先定价后分配任务，而拍卖假设了用户对任务有估价函数而需要用户先提交关于任务的报价；4) 斯坦克伯格博弈适用于用户交互度较少，无意识参与的群智感知场景。而契约论通过逆向选择和道德风险两个模型设计的合同项来强加用户与平台的协同关系；纳什议价模型假设群智感知为一个数据交易市场。

## 2.3 本章小节

本章首先从博弈论的基本概念和基本原理出发,开始介绍与本文相关的理论和技术预备知识,接着引出与本文激励机制设计相关的完全信息动态博弈—斯坦克伯格博弈。随后,我们介绍与斯坦克伯格阶段优化问题相关的理论和技术,包括多臂老虎机模型、凸优化、子模优化和李雅普诺夫优化等技术。最后,我们对群智感知中激励机制的相关研究工作进行调研和总结,通过回顾相关工作的主要研究内容,对现有相关工作进行分类,分成了:以基于斯坦克伯格博弈、基于拍卖和基于外部性的非合作博弈激励机制与以基于契约模型和基于纳什议价模型的合作博弈激励机制。我们总结之前工作存在的问题,提炼出亟待解决的研究问题,并分析本文的研究和之前工作的不同之处,强调了本文的贡献。

### 第3章 第三方应用协助的用户征募激励机制

在本章，我们提出了一个基于第三方应用协助的激励机制，叫做 PTASIM，该激励机制探索了潜在的第三方应用合作，有助于感知平台稳定地征募更多用户去执行感知任务。PTASIM 首先请求第三方应用把一些当前任务的位置标记为兴趣点，这样可以让第三方应用的用户来到标记的兴趣点使用第三方应用 App 服务，同时执行感知任务。我们进一步建模该场景下，感知平台、第三方应用和用户的策略交互为三阶段斯坦克伯格博弈。在阶段一，第三方应用首先确定兴趣点标记价格策略，去最大化其效益函数。在阶段二，平台做关于当前任务的奖励定价决策，同时确定挑选一组任务来让第三方应用标记。在阶段三，所有用户根据其最大化效益函数的策略来决定是否要执行感知任务，以及执行哪个感知任务。我们使用后向推断法来分析该激励机制对应的三阶段斯坦克伯格博弈的均衡点。特别地，我们使用贪婪算法为平台设计其效益最大化策略，并且在多项式时间内达到最优策略。最后，我们使用仿真实验来验证 PTASIM 的有效性。实验结果显示了：1) 第三方应用的协助可以帮助感知平台提供长期充足的用户参与；2) 均衡点上的策略可以使得感知平台减少激励用户执行任务的代价，同时也提升了第三方应用的收益。

#### 3.1 引言

近些年来，随着移动技术的发展，移动用户的手持设备（如智能手机、智能手表，以及其他可穿戴设备等等）配备了丰富传感器，例如加速度计、陀螺仪、磁力计、GPS、摄像头、麦克风等等。群智感知<sup>[97]</sup>作为物联网中新兴的感知模式，通过征募携带手持设备的移动用户在特定地点和区域执行感知任务，从而提供了大规模感知服务，例如利用移动用户的惯性传感器和用户之间的机会接触来进行室内地图的自动构建<sup>[36]</sup>。现有的群智感知架构是基于云计算的运营架构，这种架构由于云端平台激励机制的计算负担过载而面临着群智感知服务的可扩展性问题。在本章，我们借助于新兴的边缘计算架构<sup>[98,99]</sup>来解决基于云架构群智感知激励机制设计所具有的挑战，这种将激励机制部署在边缘架构上的群智感知，称作移动边缘群智感知（Mobile Edge Crowdsensing, MEC）<sup>[100-102]</sup>。在移动边缘群智感知中，平台卸载感知数据收集任务到各种兴趣点所在的边缘服务器，进而由边缘服务器征募附近用户来执行感知任务。而平台所担任的



角色是在云端接收来自请求者的服务请求，然后生成不同的感知任务，卸载到对应的边缘服务器。然而，移动用户一般都具有自私性（追求效益最大化），同时执行感知任务对于用户来说存在一定量的感知代价，甚至会有暴露隐私的风险，没有足够的奖励则无法吸引用户参与执行群智感知任务。因此，设计一个合理的激励机制来吸引更多用户的参与是群智感知应用成果的必要因素<sup>[103]</sup>。尽管如此，现有的激励机制研究工作都假设只有单个大的群智感知任务，并且在任务对应兴趣点的固定位置存在大量的用户。所以这些研究工作都忽视了用户对参与群智感知意愿的异构性和平台有限的预算，认为只要给足够多的奖励，用户就会到相关兴趣点位置执行感知任务。需要注意的是，这种假设并不适用于一些实际场景，如平台需要分配一组具有不同兴趣点的感知任务，而并不是每个兴趣点都有足够多的用户可以征募。在这种场景下，一个更实际的做法是把这种位置感知的任务<sup>[104,105]</sup> 考虑到激励机制设计当中去，并借助不同任务所在的边缘服务器来征募附近的用户来执行感知任务。另外一方面，如果寻求合作于本身具有大量用户黏着度的第三方应用，则将有助于帮助感知平台吸引到大量的用户到任务的兴趣点区域附近，从而便于感知平台获得大量的用户群并且从中征募用户来执行感知任务。然而，群智感知研究领域还没有现成的研究工作探索结合第三方应用协助来设计激励机制。本章将从这种合作角度出发，研究第三方应用协助的激励机制设计问题。

为了结合第三方应用协助，本章研究设计了一个名为 PTASIM（即 PoI-Tagging App-aSsisted Incentive Mechanism 的简写）的激励机制。这个动机是基于目前越来越流行的标记性 App（需要注意的是，在本章中 App 和第三方应用交替使用，指同一个事物）的普及，例如 Pokemon Go<sup>[106]</sup>、支付宝等扫福活动。这类型的 App 为它们的用户带来一些内在价值，例如娱乐性和舒适性，这是因为它们结合了虚拟现实/增强现实技术来融合用户体验和现实世界。因此，这些 App 可以改变用户移动行为和交互行为，促使它们的用户到某个指定的地点使用 App 的服务或者参与 App 的活动。所以，PTASIM 的设计原理是群智感知系统中的感知平台寻求与这些作为第三方应用的合作，请求他们把 App 的活动设置在群智感知用户比较缺乏或者征募用户比较昂贵的任务兴趣点。

为了说明 PTASIM 激励机制的运行过程，我们在图3.1展示了 PTASIM 激励机制的基本设计思想。假设有三个移动用户，其中一个是普通用户，两个是第三方应用 App 用户。为了便于说明，我们只假设有一个边缘服务器，随时间以独立同分分布的

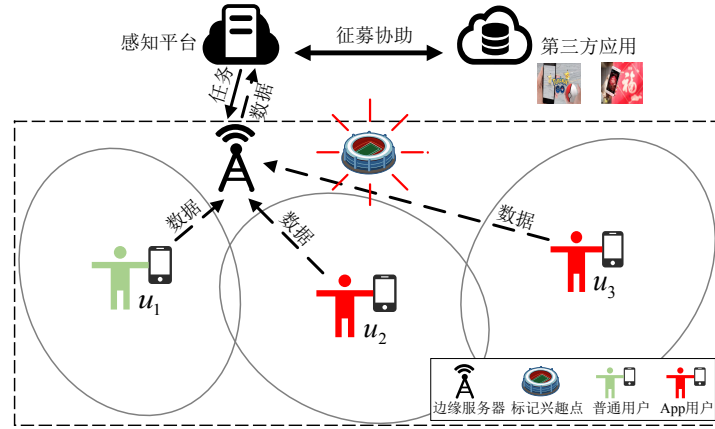


图 3.1 PTASIM 激励机制示意图

随机任务到达感知平台。这些与位置相关的任务，其兴趣点都在该边缘服务器的覆盖区域内。平台接收到服务请求后，将其对于的感知任务转达到相应的边缘服务器。如果编译服务器直接征募用户执行感知任务，那么只有一个普通用户可以被征募到。显然，对于需要多个用户来执行任务才能得到多份感知数据的任务来说，这时候的用户参与率是不够的。这里需要注意的是，我们使用平台关于某任务规定用户参与率来代替规定的用户数目，是因为在用户征募的过程需要在极短的时间内完成，总用户数目固定，规定的用户参与率等同用户数目，使用用户参与率便于激励机制中策略交互的设计。由于在图3.1中的任务分配场景中，用户参与率达不到规定的要求。而这时，第三方应用在该边缘服务器附近设置活动，吸引了两个 App 用户到达附近参与第三方应用的活动。如果感知平台寻求与第三方应用合作，并请求第三方应用把活动的地点设置在任务的兴趣点区域附近，同时规定其 App 用户参与活动并顺带执行感知任务，那么这时候平台与未合作前相比，总共获得了三个用户的参与（其中，一个普通用户，两个 App 用户），从而提高了感知任务的用户参与率。

尽管这种第三方应用在协助感知平台征募用户方面具有巨大的推动作用，但是结合这种第三方应用的协助来设计 PTASIM 激励机制还存在一些挑战难点：1) 当前到达的任务，其对应的感知区域分布不均，而且移动用户在各个兴趣点的聚集程度也不同，因此不可能请求第三方应用把全部任务的感知区域都标记为其活动的兴趣点，然而选择哪一个任务作为标记的兴趣点需要平台细心决策以最大化其效益函数；2) 第三方应用的存在复杂的利益关系，一方面，第三方应用存在操作代价，比如标记任务的地点为它的兴趣点，以及设置操作界面等等。另一方面，突然强制让第三方应用的用户来执行感知任务会降低他们使用 App 服务的体验；3) 第三方应用和用户（普通用

户和 App 用户), 作为激励机制的参与方, 存在自私性。如果它们得不到合适的奖励, 他们将不会参与完成感知数据收集任务。此外, 用户和平台都想策略性地最大化其效益函数, 这使得群智感知系统的各方之间策略交互变得相当复杂, 需要设计合理的激励机制来规定交互规则。而所有策略交互都需要在线进行, 这意味着各方决策的响应时间需要尽可能的短。而在这些挑战背后的关键科学问题是感知平台如何为各个当前任务做合理奖励定价决策和如何选择哪些任务作为兴趣点让第三方应用标记, 从而最大化其效益函数。另外, 站在第三方应用的角度上, 第三方应用如何确定标记兴趣点的价格来最大化自己的效益, 从而在合作中获益。在本章, 我们集中解决结合第三方应用协助设计激励机制的场景下所具有的挑战问题, 并提出了一个名为 PTASIM 激励机制。我们把 PTASIM 的设计过程建模为一个三阶段斯坦克伯格博弈, 并为策略交互的各方推导其最优策略, 组成斯坦克伯格均衡。我们总结本章的主要贡献如下:

- 我们结合了第三方应用的协助而提出了一种新颖的激励机制, 叫做 PTASIM。我们探讨并分析了 PTASIM 激励机制在这种第三方应用协助的场景下群智感知系统中各方决策者之间复杂的策略交互关系。
- 我们使用三阶段斯坦克伯格博弈来建模这种第三方应用协助下的激励机制设计问题。我们进一步分析了每一阶段用户、感知平台和第三方应用在均衡点下的最优策略。特别地, 我们使用贪婪算法来求解平台效益最大化问题, 并使用拟阵来证明贪婪算法在该问题中的最优性。
- 我们使用仿真实验了研究 PTASIM 激励机制的有效性。实验结果显示了这种第三方应用的卸载可以提升用户参与率, 并且可以减少平台激励用户参与执行任务的奖励代价, 同时还可以增加第三方应用的收入。

本章的后续内容将如下组织编排: 在节3.2, 我们介绍本章关注群智感知系统的模型, 包括平台、用户和第三方应用模型, 在此基础上定义参数和效益函数, 引出激励机制的三阶段斯坦克伯格博弈的问题形式化。在节3.3, 我们详细探索激励机制中三个阶段第用户、平台和第三方应用的最优策略, 推导斯坦克伯格博弈均衡点。在节3.4, 我们使用数值仿真实验来评估用户、平台和第三方应用的策略性能, 尤其是标记任务的量对平台制定奖励的影响。最后, 我们在节3.5总结了本章的激励机制研究工作。



表 3.1 第3章所设计的激励机制常用数学符号表

符号	含义
用户	$\mathcal{U}, N$
	用户集和用户数目
	$\kappa$
	用户集中 App 用户的比例
	$L$
	用户的当前电量
	$L_{th}$
平台	用户参与执行任务的电量阈值
	$f_{app}$
	指示一个用户是普通用户还是 App 用户的布尔变量
	$c_{ij}$
	用户 $j$ 执行任务 $i$ 的感知代价
	$d_{ij}$
	指示用户 $j$ 是否执行任务 $i$ 的布尔变量
平台	$\Phi_{ij}(L, f_{app}, \rho_i, r_i, d_{ij})$
	用户 $j$ 关于任务 $i$ 的效益函数
	$\mathcal{TS}$
	平台接受到的任务集
	$M$
	任务集的大小
	$\gamma_i$
	平台收取分配任务 $i$ 的费用
	$\rho_i$
	平台对任务 $i$ 的奖励定价值
	$n_i$
	平台征募的用户数来执行任务 $i$
第三方应用	$I_i$
	任务 $i$ 的感知区域网络基础设施状态值
	$\Phi_p$
	平台的效益函数
	$E_i^\theta$
	用户关于任务 $t_i$ 的网络跟从效应
	$E_i^\delta$
	用户关于任务 $t_i$ 的网络拥堵效应
第三方应用	$\mathbf{p}$
	平台的任务奖励向量
	$\mathbf{r}$
	平台的兴趣点挑选标记向量
第三方应用	$P_{app}$
	第三方应用的兴趣点标记价格
	$a$
第三方应用	第三方应用的单位广告收益值
	$\Phi_{app}$
第三方应用	第三方应用的效益函数

## 3.2 模型、定义和问题描述

在这一节，我们首先描述群智感知系统中各个决策者（用户、平台和第三方应用）之间的策略。接着，我们基于各个决策者的策略定义了他们各自的效益函数。在此之前，我们在表3.1总结了本章主要的数学符号以方便查阅。

### 3.2.1 用户模型

群智感知系统中的用户分为普通用户和 App 用户。每个用户  $u_j$  可以由一个二元组  $(L, f_{app})$ 。这里的变量  $L$  是用户的智能设备的剩余电量， $f_{app}$  是一个布尔变量，指示该用户是否是 App 用户。我们假设  $L$  在不同时槽是一个独立同分布的随机变量，在区间  $[0, 1]$  服从均匀分布。令常量  $L_{th}$  为一个电量阈值，如果变量  $L$  小于  $L_{th}$  时，对应的用户将不会执行感知任务或者使用 App，从而离开群智感知系统。我们使用变量  $\kappa \in [0, 1]$  来表示群智感知系统中 App 用户的比例。我们用集合  $\mathcal{U} = \{u_1, u_2, \dots, u_N\}$  来表示群智感知系统中的所有用户，用户数目为  $|\mathcal{U}| = N$ 。普通用户只挑选一个可以最大化其效益的任务来执行。而 App 用户会去第三方应用标记为兴趣点（PoI）的地点

参与 App 活动，同时执行从平台中所选的任务。尽管存在一些用户，即是 App 用户又是群智感知系统的普通用户，为了便于分析，我们把这群用户视作为 App 用户，因为 App 用户对于的效益函数一般都大于单独考虑为普通用户的效益函数。

### 3.2.2 平台模型

群智感知中的平台在某一时槽有  $M$  与位置相关的感知任务需要卸载给相应的边缘服务器，由边缘服务器征募用户来执行感知。边缘服务器可以直接证明普通用户来执行感知任务。如果征募的普通用户无法满足任务的参与率要求，则平台可以与第三方应用合作，请求第三方应用为感知任务的感知区域标记为兴趣点 (PoI)，即把第三方应用的 App 活动设置在感知任务的感知区域，吸引 App 用户来参与 App 活动，同时执行感知任务。假设平台需要分配的任务集为  $\mathcal{TS} = \{t_1, t_2, \dots, t_M\}$  (满足  $|\mathcal{TS}| = M$ )。每个任务  $t_i$  由一个四元组  $(\gamma_i, \rho_i, n_i, I_i)$  来表示。其中， $\gamma_i$  表示当任务  $i$  被用户执行完并收集到该任务对应的感知数据时平台可以从该任务对应的请求者得到的支付费用作为收入。 $\rho_i$  表示平台为任务  $i$  所做的奖励定价决策变量。 $n_i$  表示任务需要至少被  $n_i$  个用户执行，这样才能获得多份关于该任务的数据从而提升了关于该任务的服务质量。 $I_i \in [0, 1]$  是任务对应的感知区域的网络基础设施状态值，用户表征该区域的网络通信质量，即 Wi-Fi 或蜂窝网络的信号强度或者当前可用带宽等等。如果  $I_i$  接近 1，表示任务  $i$  的感知区域网络通信质量强，用户执行完感知任务后，可以很快通过该位置的网络基础设施传输感知数据。感知平台需要为所有任务确定合适的奖励值作为激励来吸引用户参与，同时决定挑选哪些任务，让第三方应用标记为活动兴趣点。

### 3.2.3 第三方应用模型

我们考虑了在第三方应用的协助下感知平台征募用户参与执行感知任务。第三方应用一般是可以标记兴趣点的 App (例如 Pokemon Go、Snapchat、支付宝中扫福活动)，把 App 活动设置标记的位置时，则可以吸引大量用户来完成 App 活动，这些活动为 App 用户带来内在效益，记作  $V$ 。如果第三方应用收到感知平台关于任务  $t_i$  的标记请求，它可以帮助感知平台标记任务  $t_i$  的感知区域为兴趣点，收取费用  $P_{app}$ ，这个费用的值称作为兴趣点标记价格。本章中提及的第三方应用提供的 App 对于用户来说是免费使用的，这也符合绝大多数实际情况的兴趣点标记 App<sup>[107]</sup>。在协助的初始阶段，第三方应用需要确定兴趣点标记价格  $P_{app}$  来最大化其效益函数，这对应着第三

方应用如何与感知平台合作，以多少兴趣点标记价格来合作。实际上，感知平台不需要开发部署这类型的 App，因为这会增加感知平台的额外开销，而感知平台无法集中于提供感知服务业务。相反，感知平台可以利用这些现成的 App 来帮助它征募更多的用户，这样才能提供高好的感知服务，从而达到节省开销的目标。

### 3.2.4 各方效益函数的定义

**(1) 用户的效益函数：**当用户  $u_j$  决定执行感知任务  $t_i$  时，它的效益值为  $\rho_i - c_{ij}$ 。这里的  $c_{ij}$  是用户  $u_j$  执行任务  $t_i$  时所承受的感知代价，例如用户  $u_j$  到任务  $t_i$  地点的交通费用，传输感知数据的流量费用，以及执行感知任务所消耗的计算资源和电量等等<sup>[107]</sup>。因此，用户的效益值可解释为任务的奖励减去执行任务的感知代价。不失一般性，我们假设  $c_{ij}$  的值是在区间  $[0, c_{max}]$  上服从均匀分布的随机变量。

如果第三方应用把任务  $t_i$  标记为 App 活动的兴趣点，那么 App 用户  $u_j$  将获得一个内在的效益值  $V$ ，这个内在效益值是由于用户使用 App 参与活动而获得的娱乐性所带来的。我们使用布尔变量  $r_i$  来指示任务  $t_i$  是否为第三方应用标记的活动兴趣点。当  $r_i = 1$  时，表示感知平台请求第三方应用帮助标记任务  $t_i$  为活动兴趣点。当  $r_i = 0$  时，表示任务  $t_i$  不是第三方应用的活动兴趣点，这时感知平台只能为任务  $t_i$  征募普通用户来执行它。

我们还考虑网络跟从效应（network effect）和网络拥堵效应（congestion effect）<sup>[84,108]</sup> 对用户关于任务  $t_i$  效益值的影响，它们分别用  $E_i^\theta$  和  $E_i^\delta$  来表示。网络跟从效应是指一个网络应用，如果使用的人数越多，那么其对使用者来说，更有内在价值。正如罗伯特·梅特卡夫在梅特卡夫定律（Metcalfe's law）<sup>[109]</sup> 指出一个网络的价值等于该网络内的节点数的平方，而且该网络的价值与联网的用户数的平方成正比。而网络拥堵效应是指一个网络应用在有限的网络带宽下，当通过该应用联网使用其服务的用户数越多，则造成的拥堵会降低应用的服务质量，进而使得用户体验下降。在本章所研究的基于第三方应用协助激励机制设计问题中，网络跟从效应表示任务  $t_i$  被标记为活动兴趣点时在任务  $t_i$  处使用 App 的人数对其他 App 用户的正效益值，网络拥堵效应表示在任务  $t_i$  处使用网络基础设施的人数对其该处所有用户的负效益值。其中，常数  $\theta$  是网络跟从效应系数。为了便于分析，我们假设  $\theta$  对所有用户来说，取值都是一样的。 $\theta$  关于所有用户异构取值的情况对激励机制设计的理论结果影响在下文进行分析。常数  $\delta$  是网络拥堵效应系数，它对所有用户包括普通用户和 App 用户来说，取值

都是一样的（而且一定相同，无异构取值情况），这是因为不管是普通用户还是 App 用户，当在同一个区域使用网络来使用 App 服务或者执行感知任务并传输感知数据时都使用同样的网络基础设施，如 Wi-Fi 或蜂窝，而网络基础设施的无线带宽资源在同一区域是相同且有限的。我们定义决策变量  $d_{ij} \in \{0, 1\}$  来表示用户  $u_j$  是否执行任务  $t_i$ ，取值为 0 时不执行，否则执行。基于以上定义的符号，如果用户  $u_j$  的类型为  $(L, f_{app})$  并且执行任务  $t_i$  时，我们定义其效益函数为：

$$\Phi_{ij}(L, f_{app}, \rho_i, r_i, d_{ij}) = \begin{cases} (\rho_i - c_{ij} - E_i^\delta + r_i f_{app}(V + E_i^\theta)) \cdot d_{ij}, & L \geq L_{th}, \\ 0, & L < L_{th}, \end{cases} \quad (3.1)$$

根据文献<sup>[107]</sup>的计算方式，变量  $E_i^\theta$  和  $E_i^\delta$  的计算公式为： $E_i^\theta = \theta \tilde{y}_i(r_i)N$  和  $E_i^\delta = \frac{\delta}{L_i} \tilde{x}_i(r_i)N$ 。这里的  $\tilde{y}_i(r_i)$  表示 App 用户关于任务  $t_i$  的参与率而  $\tilde{x}_i(r_i)$  表示任务  $t_i$  的所有用户总参与率，其中参与率是指执行任务  $t_i$  的用户数比上群智感知系统的所有用户数目，包括普通用户和 App 用户。变量  $\tilde{x}_i(r_i)$  和  $\tilde{y}_i(r_i)$  对于推导感知平台和第三方应用的策略非常重要，在均衡点上，它们的值都收敛到固定值<sup>[107]</sup>。在下一节，我们将推导出变量  $\tilde{x}_i(r_i)$  和  $\tilde{y}_i(r_i)$  在  $r_i = 0$  和  $r_i = 1$  情况下的闭式计算公式。需要值得注意的是，假设变量  $L$  和  $c_{ij}$  服从均匀分布不会影响 PTASIM 激励机制的理论结果，只会影响仿真实验的结果。

**(2) 感知平台的效益函数：**平台的效益函数取决于被完成的任务数量。因为这样可以为请求者提供感知服务，并获得请求者为感知服务支付的费用。为了增加被完成的任务数量，平台应该为执行感知任务的用户提供奖励来激励更多用户参与。不同于以往的激励机制，要求接收任务的用户到达规定地点执行任务<sup>[26,65,69,72,82,84,105,110]</sup>，我们提出的激励机制通过边缘服务器征募可用的普通用户来参与执行感知任务，在普通用户参与率不够的时候，通过和第三方应用合作来征募 App 用户。直观上，感知平台支付第三方应用，让其把相关任务的感知区域置为 App 活动的兴趣点，从而 App 用户在使用 App 完成活动时候执行感知任务。因此，我们定义感知平台所要操控的两个策略变量为：任务的奖励向量  $\mathbf{p} = (\rho_{t_1}, \rho_{t_2}, \dots, \rho_{t_M})$  和兴趣点挑选标记向量  $\mathbf{r} = (r_1, r_2, \dots, r_M)$ 。当第三方应用的兴趣点标记价格为  $P_{app}$  且用户参与率在均衡点是  $\tilde{x}_i(r_i)(\forall t_i \in \mathcal{TS})$  时，感知平台的效益函数可以定义为：

$$\Phi_p = \sum_{i=1}^M \mathbb{I}(\tilde{x}_i(r_i) \geq \frac{n_i}{N})(\gamma_i - N \tilde{x}_i(r_i) \rho_i) - \mathbf{r}^T \mathbf{P}_{app}, \quad (3.2)$$

其中,  $\mathbb{I}(\cdot)$  是一个指示函数, 如果对应的不等式成立, 那么指示函数的值为 1, 否则为 0。  $\mathbf{P}_{app}$  是兴趣点标记价格向量, 每个元素为  $P_{app}$ 。在式3.2中, 我们把每个任务的收益进行求和, 然后减去给第三方应用标记兴趣点的费用, 则结果为平台关于所有任务的效益。每个任务都有参与率要求, 由指示函数的条件给出  $\tilde{x}_i(r_i) \geq \frac{n_i}{N}$ , 即如果每个任务  $t_i$  在均衡点至少由  $n_i$  个用户执行, 则  $\mathbb{I}(\tilde{x}_i(r_i) \geq \frac{n_i}{N}) = 1$  成立。

**(3) 第三方应用的效益函数:** 当第三方应用的兴趣点标记价格为  $P_{app}$  时, 感知平台将策略性最优化地选择  $|\mathbf{r}^*(P_{app})|$  个任务来让第三方应用标记。因此, 第三方应用帮助感知平台标记  $|\mathbf{r}^*(P_{app})|$  个任务为活动兴趣点所获得的收入为:  $\mathbf{P}_{app}^T \mathbf{r}^*(P_{app})$ 。此外, 第三方应用一般在其 App 上投放广告来获得更多的收入。我们令  $aN\kappa$  为 App 的广告收入, 其中常数  $a$  为单位广告收益值, 而  $N\kappa$  为群智感知系统中 App 用户的总数目。显然, 第三方应用的效益函数有任务标记收入和广告收入组成, 表示为:

$$\Phi_{app} = \mathbf{P}_{app}^T \mathbf{r}^*(P_{app}) + aN\kappa. \quad (3.3)$$

在我们提出的激励机制中, 第三方应用将策略性最优化地选择兴趣点标记价格为  $P_{app}$  来最大化其效益函数  $\Phi_{app}$ , 同时考虑了感知平台的兴趣点挑选标记向量  $\mathbf{r}$  策略和额外广告收入的影响。

### 3.2.5 基于三阶段斯坦克伯格博弈的激励机制设计问题描述

为了衡量我们设计基于第三方协助激励机制的有效性, 我们使用博弈论中的概念, 无秩序代价 (Price of Anarchy, PoA) <sup>[39]</sup> 来进行衡量, 其定义为最好情况的均衡点下系统的效益值比上最差情况的均衡点下系统的效益值, 反映了由于非合作对系统所带来的性能损失。我们从用户参与率的角度来计算无秩序代价。当平台考虑第三方应用的协助来设计激励机制时, 所达到的最好情况下用户参与率在均衡点时为 1, 而假设平台忽视了第三方应用的协助, 单独设计激励机制来征募用户, 所达到的最好情况下用户参与率在均衡点时为  $1 - \kappa$ 。因此, 无秩序代价为  $\frac{1}{1-\kappa}$ 。可见, 当  $\kappa$  越大 (即 App 用户越多), 则无秩序代价就越大。因此, 平台设计里机制时, 更需要考虑第三方应用的协助来增加用户的参与率。

在本章, 我们使用三阶段斯坦克伯格博弈来建模所要设计的激励机制, PTASIM。博弈的整个过程如下, 在阶段一、第三方应用首先确定兴趣点标记价格  $P_{app}$  来最大化



其效益函数  $\Phi_{app}$ 。在阶段二、平台做关于当前任务的奖励定价决策  $\mathbf{p}$ ，同时确定挑选一组任务来让第三方应用标记为兴趣点，即  $\mathbf{r}$ 。在阶段三，所有用户根据其最大化效益函数的策略来决定是否要执行感知任务，以及执行哪个感知任务。为了便于分析，我们在随后三节使用后向推断法<sup>[38,107,108,111]</sup>来分析各方在不同阶段的最优策略。

特别地，我们首先在节3.3.1分析不同情况下关于用户参与率的均衡点存在。这个用户参与率均衡点可以让感知平台预测到所有类型用户的决策，从而使得平台可以计算关于其策略  $\mathbf{p}$  和  $\mathbf{r}$  的最优解。因此，我们在节3.3.1推导对于任一给定的奖励  $\mathbf{p} \succeq \mathbf{0}$  下用户参与率，然后在节3.3.2分析平台关于  $\mathbf{p}$  和  $\mathbf{r}$  的最优策略，从而组成了斯坦克伯格均衡点<sup>[26]</sup>。

### 3.3 激励机制设计

在这一节，我们详细描述所设计的基于第三方应用协助激励机制。我们使用了三阶段斯坦克伯格博弈来建模激励机制的过程。在阶段一、第三方应用首先确定兴趣点标记价格  $P_{app}$  来最大化其效益函数  $\Phi_{app}$ 。在阶段二、平台做关于当前任务的奖励定价决策  $\mathbf{p}$ ，同时确定挑选一组任务来让第三方应用标记，即  $\mathbf{r}$ 。在阶段三，所有用户根据其最大化效益函数的策略来决定是否要执行感知任务，以及执行哪个感知任务。但是为了便于求解博弈中各方的最优策略，我们使用后向推断法来分析博弈的均衡点，即先从阶段三用户的决策开始分析，到阶段二平台的策略分析，在到最后阶段一第三方应用的兴趣点标记价格策略。

#### 3.3.1 阶段三：用户-任务匹配策略

在这一小节，我们分析用户关于选择最好任务的最优策略来最大化其效益。即我们分析激励机制对应三阶段斯坦克伯格博弈的阶段一，为了推导用户的最优策略，我们假设平台在阶段二关于任务的奖励向量  $\mathbf{p}$  和兴趣点挑选标记向量  $\mathbf{r}$  是给定的。基于所有用户的最优策略，我们可以推断任务在  $r_i = 0$  和  $r_i = 1$ （即任务  $t_i$  是否被第三方应用标记为活动兴趣点）情况下关于用户的参与率。当  $r_i = 0$  时，感知平台需要通过边缘服务器来单独招募普通用户。当  $r_i = 1$  时，感知平台需要求助于第三方应用，把该任务的感知区域标记为活动兴趣点，从而平台即可以招募普通用户又可以招募 App 用户来提高任务的用户参与率。

显然，普通用户（ $f_{app} = 0$ ）和 App 用户（ $f_{app} = 1$ ）都可以从当前任务集中选择

一个最好的任务来最大化其效益函数。因此，我们可以进一步扩展用户效益最大化问题  $d_{ij}^* = \arg \max \Phi_{ij}(L, f_{app}, \rho_i, r_i)$  的形式化如下：

$$(UPM) \quad \begin{aligned} & \max \sum_{i=1}^M \Phi_{ij}(L, f_{app}, \rho_i, r_i, d_{ij}) \\ & s.t. \quad \begin{cases} \sum_{i=1}^M d_{ij} = 1, \\ (i = 1, 2, \dots, M) \\ d_{ij} \in \{0, 1\}, \\ (i = 1, 2, \dots, M) \end{cases} \end{aligned}$$

在问题 UPM 中的第一个约束确保每个用户只执行一个感知任务，因此，该问题也表达了每个用户选择一个可以为他带来最大效益的任务。每个用户都单独求解问题 UPM，并得到最优解  $d_{ij}^* = 1$ ，根据  $d_{ij}^*$  来选择任务，如果  $d_{ij}^* = 1$  时，表示用户  $u_j$  选择任务  $t_i$  来执行。为了求解问题 UPM，每个用户可以简单地枚举所有任务，并在  $\mathcal{O}(M)$  内选择具有最大奖励的任务。通过分析每个用户在阶段三的最优策略，我们可以预测所有用户的参与行为，从而得到任务关于用户的参与率，即总用户参与率  $\tilde{x}_i(r_i)$  和 App 用户参与率  $\tilde{y}_i(r_i)$ 。显然，用户的手持设备电量较低时（即  $L < L_{th}$ ），该用户将不参与执行任何任务，它对应问题 UPM 的解为  $d_{ij}^* = 0 (\forall t_i)$ 。为了推导更一般的结论，我们假设所有用户的当前电量都充足（即  $L \geq L_{th}$ ）。我们将分两种情况讨论均衡状态下用户参与率：任务  $i$  未被标记为活动兴趣点（ $r_i = 0$ ）和已被标记为活动兴趣点（ $r_i = 1$ ）。

#### A. 任务 $i$ 未被标记为活动兴趣点（ $r_i = 0$ ）

当  $r_i = 0$  时，这意味着感知平台直接通过边缘服务器来招募普通用户去执行感知任务  $t_i$ ，并为其提供奖励  $\rho_i$ 。令  $\mathbf{p}_{-i}$ ， $\mathbf{c}_{-i,j}$  和  $\mathbf{E}_{-i}^\delta$  为由除了任务  $t_i$  的其余任务的奖励、用户只需其的代价和拥堵效应值所组成的向量。我们在下面的命题中总结在  $r_i = 0$ （即平台通过边缘服务器直接招募用户）时问题 UPM 的解。

**命题 3.1** (直接招募). 对于任务  $t_i$ ，如果平台通过边缘服务器直接招募来执行该任务，并提供奖励  $\rho_i$  时，用户  $u_j$  的最优策略  $d_{ij}^*$  是关于问题 UPM 的最优解，其解析式如下：

$$d_{ij}^* = \begin{cases} 1 & i = i^*, \\ 0 & i \neq i^*. \end{cases} \quad (3.4)$$

其中，最优任务  $i^* = \arg \max \{\rho_i, -c_{ij} - E_i^\delta\}$ 。如果最优任务有多个，则随机取任

意一个。命题3.4揭示了普通用户  $u_j$  从当前任务集  $\mathcal{TS}$  中选择一个任务  $t_{i^*}$  来最大化其效益函数。

对于所有用户而言，当平台给定当前所有任务的奖励  $\mathbf{p}$  时，所有用户都单独求解问题 UMP，并根据命题3.4的最优策略进行决策。从整体效果上看，这可以进一步导出用户对于任务的参与率，即总用户参与率  $\tilde{x}_i(r_i)$  和 App 用户参与率  $\tilde{y}_i(r_i)$  ( $\forall i \in \mathcal{TS}$ )。对  $\tilde{x}_i(r_i)$  和  $\tilde{y}_i(r_i)$  的预测对于平台进行激励决策来说至关重要，因为平台可以根据  $\tilde{x}_i(r_i)$  和  $\tilde{y}_i(r_i)$  来进一步计算其最优策略。我们在以下引理总结了所有用户参与率  $\tilde{x}_i(0)$  和  $\tilde{y}_i(0)$  的计算解析式：

**引理 3.1.** 对于任务  $t_i$  来说，如果平台直接通过边缘服务器来征募普通用户去执行任务，而不是让第三方应用把任务的感知区域标记为活动兴趣点 ( $r_i = 0$ ) 来征募 App 用户时，任务  $t_i$  关于所有用户的参与率在均衡点下为：

$$\begin{cases} \tilde{x}_i(0) = \frac{(1-\kappa)\rho_i I_i}{(1-\kappa)N\delta + c_{max}I_i}, \\ \tilde{y}_i(0) = 0. \end{cases} \quad (3.5)$$

**证明.** 很容易验证  $\tilde{y}_i(0) = 0$  因为任务  $t_i$  不是 App 活动兴趣点时，App 用户不会出现在任务  $t_i$  的感知区域。为了计算  $\tilde{x}_i(0)$ ，我们先考虑临界用户的效益值（其关于任务  $t_i$  的效益值为 0），即  $\rho_i - c_{ij} - E_i^\delta = 0$ 。由于我们假设  $c_{ij}$  服从均匀分布，我们得到  $\frac{c_{ij}}{c_{max}} = \frac{\tilde{x}_i(0)}{1-\kappa}$ 。联立着两个等式，我们可以求得  $\tilde{x}_i(0)$  的值。引理得证。  $\square$

### B. 任务 $i$ 被标记为活动兴趣点 ( $r_i = 1$ )

当平台通过边缘服务器无法征募到足够的用户参与执行任务时，它可以通过请求第三方应用来标记任务  $t_i$  为活动兴趣点，这 App 用户将会来到任务  $t_i$  的感知区域，使用 App 参与活动的同时执行感知任务。任务  $t_i$  为活动兴趣点时，变量  $r_i = 1$ 。需要值得注意的是，即使任务  $t_i$  为活动兴趣点时，不单单只有 App 用户参与执行感知任务，而且普通用户也会参与执行，只要该任务可以使用户的效益值最大。我们在下面的命题中总结在  $r_i = 1$ （即平台通过第三方应用协助来联合征募用户）时问题 UMP 的解。

**命题 3.2** (第三方应用协助联合征募). 对于任务  $t_i$ ，如果感知平台请求第三方应用标记任务  $t_i$  为活动兴趣点，通过第三方应用协助来联合征募用户并提供奖励  $\rho_i$  时，每个用户  $u_j$  的最优策略  $d_{ij}^*$  是关于问题 UPM 的最优解，其解析式如下：



$$d_{ij}^* = \begin{cases} 1 & i = i_1^*, \\ 1 & i = i_2^*, \\ 0 & i \neq i_1^*, i_2^*. \end{cases} \quad (3.6)$$

其中, 对于普通用户  $f_{app} = 0$ , 最优任务  $i_1^* = \arg \max \{\rho_i - c_{ij} - E_i^\delta\}$ , 对于 App 用户  $f_{app} = 1$ , 最优任务  $i_2^* = \arg \max \{\rho_i - c_{ij} - E_i^\delta + E_i^\theta\}$ 。命题3.6揭示了所有用户  $u_j$  从当前任务集  $\mathcal{TS}$  中选择一个任务  $t_{i^*}$  来最大化其效益函数。式中的第一个条件对应着普通用户的最优策略, 第二个条件对应着 App 用户的最优策略。正如在  $r_i = 0$  情况的分析一样, 在  $r_i = 1$  的情况, 通过命题3.6的结论可以预测  $\tilde{x}_i(r_i)$  和  $\tilde{y}_i(r_i)$ , 这对平台进行激励决策来说至关重要, 因为平台可以根据  $\tilde{x}_i(r_i)$  和  $\tilde{y}_i(r_i)$  来进一步计算其最优策略。我们在以下引理总结了所有用户参与率  $\tilde{x}_i(1)$  和  $\tilde{y}_i(1)$  的计算解析式:

**引理 3.2.** 对于任务  $t_i$  来说, 如果感知平台请求第三方应用标记任务  $t_i$  为活动兴趣点 ( $r_i = 1$ ), 通过第三方应用协助来联合征募用户, 任务  $t_i$  关于所有用户的参与率在均衡点下为:

$$\begin{cases} \tilde{x}_i(1) = \frac{I_i(\kappa(V+\rho_i)((1-\kappa)N\delta+c_{max}I_i)-(1-\kappa)I_i\rho_i(\kappa N\theta-c_{max}))}{(\kappa\delta N-I_i(\kappa\theta N-c_{max}))((1-\kappa)N\delta+c_{max}I_i)}, \\ \tilde{y}_i(1) = \frac{I_i\kappa((V+\rho_i)((1-\kappa)N\delta+c_{max}I_i)-(1-\kappa)N\delta\rho_i)}{(\kappa\delta N-I_i(\kappa\theta N-c_{max}))((1-\kappa)N\delta+c_{max}I_i)}. \end{cases} \quad (3.7)$$

**证明.** 考虑任务  $t_i$  感知区域内的用户总参与率, 当任务  $t_i$  没有被标记为活动兴趣点时, 普通用户的参与率是  $\tilde{x}_i(0)$ ; 而当任务  $t_i$  被标记为活动兴趣点时, App 用户的参与率为  $\tilde{y}_i(1)$ 。由于任务  $t_i$  有没有被标记为活动兴趣点不影响普通用户的参与率, 因此, 任务  $t_i$  感知区域内的用户总参与率  $\tilde{x}_i(1)$  为:

$$\tilde{x}_i(0) + \tilde{y}_i(1) = \tilde{x}_i(1). \quad (3.8)$$

由于临界用户的效益值为 0, 我们进一步令式3.1中的效应函数在任务  $t_i$  的值等于 0, 我们得到:

$$\kappa \frac{\rho_i + V + \theta \tilde{y}_i(1)N - \frac{\delta}{I_i} \tilde{x}_i(1)N}{c_{max}} = \tilde{y}_i(1). \quad (3.9)$$

联立式3.8和式3.9求解方程, 则可以得到引理中的等式关系。□

从式3.8中, 我们可以看出, 如果感知平台在第三方应用协助下, 让第三方应用把任务感知区域置为 App 活动兴趣点, 那么用户总参与率会得到增加。从而帮助感知平台在边缘服务器无法征募足够普通用户来参与任务时特别有用, 此外还可以减少平

台直接对任务的奖励代价。值得注意的是，引理3.1和引理3.2中所给出的用户参与率： $\tilde{x}_i(r_i)$  和  $\tilde{y}_i(r_i)$ ，是关于平台策略（即奖励向量  $\mathbf{p}$  和兴趣点挑选标记向量  $\mathbf{r}$ ）的均衡状态期望参与率。基于这些期望参与率的预测，平台可以在阶段二计算其最优策略：奖励向量  $\mathbf{p}$  和兴趣点挑选标记向量  $\mathbf{r}$ ，我们将在下一小节分析平台的最优策略。

### 3.3.2 阶段二：感知平台的确定奖励和选择任务标记协同优化策略

在这一小节，我们分析平台关于奖励向量和兴趣点挑选标记向量的最优策略： $\mathbf{p}^*$  和  $\mathbf{r}^*$ 。直观上，直接选择  $\mathbf{p}^*$  和  $\mathbf{r}^*$  来最大化式3.2中的平台效益函数是存在困难的，因为其效益函数中存在指示函数。为此，我们将式3.2中平台的效益函数最大化转化为如下直观的数学规划问题，把指示函数转化为约束条件：

$$(PPM) \quad \begin{aligned} & \min \quad N\mathbf{p}^T \tilde{\mathbf{x}}(\mathbf{r}) + \mathbf{r}^T \mathbf{P}_{app} \\ & s.t. \quad \begin{cases} N\mathbf{p}^T \tilde{\mathbf{x}}(\mathbf{r}) + \mathbf{r}^T \mathbf{P}_{app} \leq \sum_{i=1}^M \gamma_i, \\ \tilde{x}_i(r_i) \geq \frac{n_i}{N}, \\ \rho_i \leq (1 - r_i)p_{th1}(I_i) + r_i p_{th2}(I_i), \\ \mathbf{p} \succeq \mathbf{0}, r_i \in \{0, 1\}, (i = 1, 2, \dots, M), \end{cases} \end{aligned}$$

其中，我们定义第三个约束中两个常量阈值为：

$$\begin{cases} p_{th1}(I_i) \triangleq \frac{(1-\kappa)N\delta + c_{max}I_i}{I_i}, \\ p_{th2}(I_i) \triangleq \frac{I_i^2 c_{max}(c_{max} - V - \kappa\theta N) + I_i c_{max} \delta N + I_i N \delta (\kappa^2 \theta N - \kappa \theta N + \kappa V - V)}{c_{max} I_i^2}. \end{cases} \quad (3.10)$$

这两个阈值可以从引理3.1和引理3.2中令  $\tilde{x}_i(0) \leq 1$  和  $\tilde{x}_i(1) \leq 1$  而进一步推导得到的，这是因为，不管任务  $t_i$  是否被第三方应用标记为活动兴趣点，平台所提供的奖励来征募得到的总用户参与率不会大于 1。一个简单的方法来求解问题 PPM 是暴力枚举算法，检查所有任务的标记  $\mathbf{r}$  情况，布尔取值。所有任务的总数为  $M$ ，所以遍历布尔取值的总数为  $2^M$ ，所以遍历的时间复杂度为  $\mathcal{O}(2^M)$ 。剩下来使用单纯性算法或 KKT 来求解关于奖励向量  $\mathbf{p}$  的二次规划，可以在  $\mathcal{O}(M^2)$  的时间复杂度内完成，因此，暴力枚举算法的时间复杂度为  $\mathcal{O}(M^2 2^M)$ ，这是一个指数阶的时间复杂度算法。

由前述分析可以看出，问题 PPM 是混合整数二次规划问题，使用暴力枚举算法来求解，时间复杂度为指数阶，效率低下，可扩展性不好，最多只能处理不超过 10 个

任务的群智感知场景。为此，我们需要设计高效低复杂度的激励机制。尽管问题 PPM 是混合整数二次规划问题。但是该问题存在良好的结构有利于设计多项式时间算法来求解最优解。我们将使用贪婪算法来设计感知平台最优策略的求解算法，并使用拟阵<sup>[112]</sup>来证明算法的高效率（即多项式时间复杂度）和最优性。我们首先给出以下定义来对贪婪算法进行分析。

**定义 3.1 (独立标记集).** 对于任务子集  $\mathcal{S} \subseteq \mathcal{TS}$ ，如果该任务子集中的每一个任务  $t_i \in \mathcal{S}$  被第三方应用标记为活动兴趣点，并且感知平台还为执行该任务的用户提供奖励  $\rho_i$ ，而且该任务的标记变量  $r_i = 1$  满足问题 PPM 中的所有约束，且所造成的目标函数值不超过  $obj(\mathbf{0})$ ，那么任务子集  $\mathcal{S}$  被称作独立标记集，它的大小被称作秩。其中，函数值  $obj(\mathbf{r})$  表示问题 PPM 在标记向量取值下的目标函数值。

在以上独立标记集的定义下，问题 PPM 可以重新形式化为一个拟阵： $\mathcal{M} = (\mathcal{TS}, \mathcal{I})$ ，其中， $\mathcal{I}$  表示为总任务集  $\mathcal{TS}$  的所有非空独立标记集构成的集族。拟阵  $\mathcal{M}$  具有以下属性：

- (传递性) 对于每一个独立标记集  $I \in \mathcal{I}$ ，其子集也是独立的；
- (交换性) 如果  $A \in \mathcal{I}$ ， $B \in \mathcal{I}$  且满足  $|A| < |B|$ ，那么存在一个任务  $x \in B - A$ ，满足  $A \cup \{x\} \in \mathcal{I}$ ，即把一个独立标记集中的任务放到另外一个独立标记集，结构还满足独立性。

由上述属性可知，如果我们在拟阵  $\mathcal{M}$  中找到秩最大的独立标记集，则相当于问题 PPM 被等价地求解，其中的最优兴趣点挑选标记向量  $\mathbf{r}^*$  可以通过把独立标记集的任务都标记为活动兴趣点而得到。我们通过以下三个引理来说明以贪婪的方式来找到秩最大的独立标记集，并把独立标记集的任务都标记为活动兴趣点，可以得到问题 PPM 的最优解。

**引理 3.3.** 如果任务  $t_i \in \mathcal{TS}$  第一个被贪婪策略选择的任务，并让第三方应用标记为活动兴趣点，且满足任务集  $\{t_i\}$  是独立的，那么存在一个最大独立标记集  $A$ ，它包含任务  $t_i$ ，即  $t_i \in A$

**证明.** 我们使用构造法来证明此引理。假设  $B \in \mathcal{I}$  是最大独立标记集，如果  $t_i \in B$ ，令  $A = B$ ，从而引理得证。如果  $t_i \notin B$ ，令  $A = \{t_i\}$ ，在这个条件下，如果  $|A| = |B|$ ，则引理得证。否则，如果  $|B| > |A|$ ，我们一直贪婪地从  $B$  中挑选任务，加入  $A$  由于

拟阵的交换性, 加入后的  $A$  还能保持独立, 直到  $|A| = |B|$ 。因此, 最后得到的结果满足对于  $y \in B$  和  $y \notin A$ , 存在等式  $A = B - \{y\} \cup \{t_i\}$  成立。标记任务集  $A$  中的所有任务, 得到关于问题 PPM 的目标函数值, 记作  $obj(A)$ 。由于任务  $t_i \in \mathcal{TS}$  第一个被贪婪策略选择的任务, 单任务集  $\{t_i\}$  包含在集族  $\mathcal{I}$  中, 其对应的目标函数值  $obj(t_i)$ , 因此, 我们可以得到  $obj(A) \leq obj(B)$ 。另外一方面, 由于  $B$  是最大独立标记集, 不等式  $obj(B) \leq obj(A)$  成立。因此, 我们可以得到  $obj(A) = obj(B)$ , 这意味着  $A$  也是最大独立标记集, 而  $A$  包含任务  $t_i$ 。由此可见, 该引理成立。  $\square$

**引理 3.4.** 如果任务  $t_i$  加入一个独立标记集  $\phi$  后, 破坏了任务集  $\phi$  的独立性, 则拟阵中所有独立标记集  $A \in \mathcal{I}$  都不包含该任务  $t_i$ 。

**证明.** 我们使用反证法来证明此引理。假设  $t_i \in A$ , 使用拟阵  $\mathcal{M}$  的传递性可以得出, 单任务集  $\{t_i\}$  是独立的。由于初始的  $\phi$  是独立的, 使用拟阵  $\mathcal{M}$  的交换性, 把任务  $t_i$  加入  $\phi$  后,  $\phi$  仍然是独立的。这与假设矛盾, 因此, 该引理成立。  $\square$

**引理 3.5.** 如果任务  $t_i \in \mathcal{TS}$  第一个被贪婪策略选择的任务, 并让第三方应用标记为活动兴趣点, 那么拟阵  $\mathcal{M}$  可以导出一个新的子拟阵  $\mathcal{M}' = (\mathcal{TS}', \mathcal{I}')$ , 其中:

$$\begin{aligned}\mathcal{TS}' &= \{y | y \in \mathcal{TS} \text{ and } \{t_i, y\} \in \mathcal{I}\}, \\ \mathcal{I}' &= \{B | B \subseteq \mathcal{TS} - \{t_i\} \text{ and } B \cup \{t_i\} \in \mathcal{I}\}.\end{aligned}\tag{3.11}$$

**证明.** 如果  $A$  是拟阵  $\mathcal{M}$  中的最大独立标记集, 那么根据式 3.11, 任务集  $A' = A - \{t_i\}$  在子拟阵  $\mathcal{M}'$  也是独立标记集。反之, 对于子拟阵  $\mathcal{M}'$  中任一独立标记集  $A'$ , 我们可以构造拟阵  $\mathcal{M}$  中的独立标记集  $A$ , 即  $A = A' \cup \{t_i\}$ 。在这种情况下, 我们可以得到两个独立标记集  $A$  和  $A'$  对应目标函数值的关系:  $obj(A) = obj(A') + \alpha$ , 其中, 常数  $\alpha = N\tilde{x}_i(1)\rho_i + P_{app}$ , 与标记任务  $t_i$  相关。因此, 如果拟阵  $\mathcal{M}$  中的最大独立标记集包含任务  $t_i$ , 则子拟阵  $\mathcal{M}'$  中的最大独立标记集为其子集。  $\square$

基于以上三个引理, 我们为问题 PPM 设计了贪婪算法, 伪代码展示在算法 1。第 1–4 行定义并初始化一些临时变量, 用于在第 5–9 行贪婪构建最大独立标记集。在第 10 行, 我们计算关于找到的最大独立标记集, 退化问题 PPM 的另一决策变量: 最优奖励定价决策向量  $\mathbf{p}^*(\mathcal{S})$ 。在最坏情况下, 第 5–9 行循环最多运行  $M$  次, 在每一次循环, 我们使用 KKT 条件来求解退化后的二次规划问题 PPM, 时间复杂度是  $\mathcal{O}(M \log M)$ <sup>[113]</sup>。因此, 算法 1 的时间复杂度为  $\mathcal{O}(M^2 \log M)$ 。我们在以下定理展示了算法 1 的理论性质。

**Algorithm 1** 问题 PPM 的贪婪算法

**Input:** 用户数  $N$ , 任务数  $M$ , 最大感知代价  $c_{max}$ , App 用户比例  $\kappa$ , 用户集  $\mathcal{U}$ , 任务集  $\mathcal{TS}$ , 兴趣点标记价格  $P_{app}$ , App 所带来的内在效益值  $V$ , 网络跟从效应系数  $\theta$  和网络拥堵效应系数  $\delta$

**Output:** 最优奖励定价决策向量  $\mathbf{p}^*(\mathcal{S})$  和最优兴趣点挑选标记向量  $\mathbf{r}^*(\mathcal{S})$

- 1: 定义临时变量  $\mathcal{C} = \mathcal{TS}$
- 2: 定义标记任务集并初始化为空  $\mathcal{S} = \phi$
- 3: 标记集合  $\mathcal{S}$  中的任务, 得到对应的兴趣点挑选标记向量  $\mathbf{r}(\mathcal{S})$
- 4: 定义变量  $tobj = +\infty$
- 5: **while**  $obj(\mathbf{r}(\mathcal{S})) < tobj$  **do**
- 6:   更新  $tobj = obj(\mathbf{r}(\mathcal{S}))$
- 7:   选择  $t_i = \arg \min_{i \in \mathcal{C}} obj(\mathbf{r}(\mathcal{S} \cup \{i\}))$
- 8:   更新  $\mathcal{S} = \mathcal{S} \cup \{t_i\}$  和  $\mathcal{C} = \mathcal{C} - \{t_i\}$
- 9: **end while**
- 10: 将向量值  $\mathbf{r}(\mathcal{S})$  代入问题 PPM, 并求解剩余的二次规划问题, 得到最优奖励定价决策向量  $\mathbf{p}^*(\mathcal{S})$
- 11: **return**  $\mathbf{p}^*(\mathcal{S})$  和  $\mathbf{r}^*(\mathcal{S})$

**定理 3.1.** 问题 PPM 的贪婪算法可以求解出问题 PPM 的最优解。

**证明.** 根据引理3.3, 第一个被算法1选择的任务包含在最优的独立标记集中, 引理3.4表明没有被算法1选中的任务不会包含在最优的独立标记集中。因此, 从剩余任务中选择最优任务来标记是问题 PPM 的子问题。引理3.5保证了贪婪算法在求解问题 PPM 的子问题的最优秀性。因此, 我们可以通过递推的方式, 得到关于问题 PPM 的全局最优解。因此, 该定理得证。  $\square$

### 3.3.3 阶段一：第三方应用的兴趣点标记价格最优定价策略

在这一小节, 我们分析第三方应用如何确定兴趣点标记价格  $P_{app}$ , 协助感知平台标记任务为获得兴趣点进而增加任务的用户参与率。即第三方应用在对阶段二和三策略预期下选择最优的  $P_{app}^* = \arg \max \Phi_{app}$  来最大化式3.3的效益函数  $\Phi_{app}$ 。

然而, 第三方应用存在一定量的操作代价来标记任务为活动兴趣点, 并协助感知平台激励用户来参与执行感知任务。为此, 第三方应用需要确保其在协助感知平台进行激励用户参与时不能得到负的效益值, 即要得到一定量的盈利。此外, 我们还假设和感知平台合作的盈利不会大于第三方应用的主要广告收入。综合考虑了这些约束条



**Algorithm 2** 问题 PPM 的列生成算法

**Input:** 用户数  $N$ , 任务数  $M$ , 最大感知代价  $c_{max}$ , App 用户比例  $\kappa$ , 用户集  $\mathcal{U}$ , 任务集  $\mathcal{TS}$ , 兴趣点标记价格  $P_{app}$ , App 所带来的内在效益值  $V$ , 网络跟从效应系数  $\theta$  和网络拥堵效应系数  $\delta$ , 第三方应用的单位广告收益  $a$ , 兴趣点标记代价  $C_{tag}$

**Output:** 兴趣点标记价格  $P_{app}$

- 1: 将兴趣点标记价格赋值为  $P_{app} \in [C_{tag}, +\infty)$
- 2: **repeat**
- 3:   使用算法1来求解问题 PPM, 得到基于当前  $P_{app}$  问题 PPM 关于最优独立标记集的最优解  $\mathbf{r}^*(P_{app})$
- 4:   使用上述的解  $\mathbf{r}^*(P_{app})$  来求解关于问题 APM 的最优解  $P_{app} = P_{app}^*$
- 5: **until** 连续两次迭代关于兴趣点标记价格  $P_{app}$  的值, 其误差小于预定阈值 (如  $10^{-6}$ )
- 6: **return**  $P_{app}$

件后, 我们可以形式化第三方应用的兴趣点标记价格最优定价问题为:

$$(APM) \quad \begin{aligned} & \max \mathbf{P}_{app}^T \mathbf{r}^*(P_{app}) \\ & s.t. \quad \begin{cases} P_{app} \|\mathbf{r}^*(P_{app})\|^2 \leq aN\kappa, \\ P_{app} \geq C_{tag}, \end{cases} \end{aligned}$$

其中,  $\|\mathbf{r}^*(P_{app})\|^2$  为向量  $\mathbf{r}^*(P_{app})$  2 范数的平方。

直接求解问题 APM 是不容易的, 因为问题 APM 存在与阶段二问题 PPM 的参数  $\mathbf{r}^*(P_{app})$ , 而求解问题 PPM 又反过来依赖问题 APM 的解  $P_{app}$ 。为此, 我们根据材料切割问题中的列生成算法思想<sup>[114]</sup>来设计算法求解问题 APM, 列生成算法把原问题分解为主模型和子模型, 迭代依次求解这两个问题, 直到它们收敛。因此, 我们把激励机制中阶段二的问题 PPM 和阶段一的问题 APM 分别定义为主模型和子模型, 进而使用列生成算法。我们总结求解阶段一的第三方应用的兴趣点标记价格最优定价策略算法如下, 其伪代码展示在算法2。

**引理 3.6.** 当算法的预定阈值足够小, 使得迭代次数足够多, 算法2输出的标记价格  $P_{app}$  会收敛到均衡标记价格。

**证明.** 显然, 在问题 PPM 中, 被挑选来标记为活动兴趣点的任务数目会随着兴趣点标记价格  $P_{app}$  的增加而减少。而在问题 APM 中, 兴趣点标记价格  $P_{app}$  与被标记的数目成正比。这是因为感知平台和第三方应用之间各自的策略都单独最大化冲突的目标函数。而这个冲突的目标函数在斯坦克伯格博弈的均衡点  $(P_{app}^*, \mathbf{r}^*)$  达到折中。  $\square$

表 3.2 第3章的实验参数设置

参数符号	取值
总用户数 $N$	200
任务数 $M$	50
最大感知代价 $c_{max}$	80
App 用户比例 $\kappa$	$\sim U[0, 1]$
任务 $t_i$ 感知区域内网络基础设施状态值 $I_i$	$\sim U[0, 1]$
网络拥堵效应系数 $\delta$	13.14
网络跟从效应系数 $\theta$	$\sim U(0, 0.1]$
App 所带来的内在效益值 $V$	100
兴趣点标记代价 $C_{tag}$	15
第三方应用的单位广告收益 $a$	82.4

### 3.4 仿真实验

为了便于直接评估所提出的激励机制,在这一小节,我们对本章所提出的 PTASIM 激励机制进行仿真实验,来验证其性能。所得到效果可以扩展到真实轨迹数据集(如 D4D)模拟的群智感知系统。我们首先在表3.2总结实验中参数的设置。我们运行每个实验达到 100 次,并将结果取平均。在实验过程中,对应所要求解的最优化模型(如二次规划、线性规划),我们使用优化工具 IBM ILOG CPLEX Optimization (v12.8.0) 来对其进行编程。

#### 3.4.1 关于感知平台的策略性能评估

在前述中,我们得知在阶段二感知平台使用算法1中的贪婪算法来求得关于奖励向量和兴趣点挑选标记向量的最优策略:  $\mathbf{p}^*$  和  $\mathbf{r}^*$ 。为了验证贪婪算法的有效性,我们使用随机算法来作为基准程序进行性能比较,其中随机算法在一些实际的群智感知应用中用到,如 Waze<sup>[115]</sup>。随机算法的主要思路是每个任务以一定概率被标记为活动兴趣点,从而使得被选中的任务,其标记布尔变量  $r_i = 1$ ,我们把由随机算法得到的兴趣点挑选标记向量记作  $\mathbf{r}^{\S}$ 。随机算法重复执行来计算  $\mathbf{r}^{\S}$ ,直到条件  $obj(\mathbf{r}^{\S}) < \min\{obj(\mathbf{0}), obj(\mathbf{1})\}$  得到满足。我们把这个基准随机算法记作 RandomizedPPM。另外一个基准程序是 EXPPM,即求解问题 PPM 的暴力枚举算法,具有  $\mathcal{O}(M^2 2^M)$  的时间复杂度。

首先,我们评估算法1中的贪婪算法(记作 GreedyPPM)的时间复杂度,并与两个基准: EXPPM 和 RandomizedPPM,作比较。评估场景是在任务数为  $M = 10$  和  $M = 15$  两种场景。实验结果如图3.2所示。每个算法在两种场景( $M = 10$  和  $M = 15$ )

关于问题 PPM 的目标函数值显示在每条柱子上。在图3.2中，我们可以看到暴力枚举算法 EXPPM 尽管可以达到最优值并求得最优解，但是所消耗的计算时间多于随机算法 RandomizedPPM 和本章所提的贪婪算法 GreedyPPM，尤其是在任务数  $M$  很大的场景，当  $M$  增加时候，暴力枚举算法 EXPPM 的计算时间是指数阶增长，而其余两个是多项式增加。因此暴力枚举算法 EXPPM 存在可扩展性问题。与此同时，我们还可以看到我们提出的贪婪算法 GreedyPPM 在比暴力枚举算法 EXPPM 具有计算时间优势外，还可以得到与暴力枚举算法 EXPPM 一样的最优值。因此，在接下来的大规模任务场景下的实验中，我们使用贪婪算法 GreedyPPM 来代替暴力枚举算法 EXPPM 来求解激励机制中关于第二阶段感知平台求解问题 PPM 得到的最优策略。

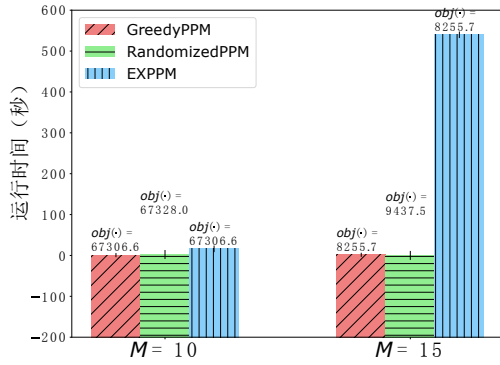


图 3.2 算法1的贪婪算法 GreedyPPM 和基准程序（随机算法 RandomizedPPM 和暴力枚举算法 EXPPM）的性能比较

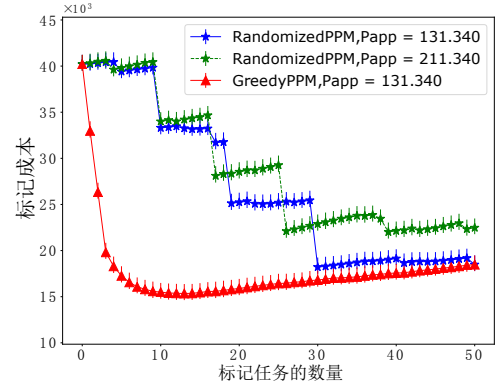


图 3.3 贪婪算法 GreedyPPM 和随机算法 RandomizedPPM 在标记的任务数从 0 到 50 个时关于问题 PPM 的目标函数值（奖励代价）的变化曲线

再接下来的实验中，我们将评估感知平台在两个方面：1) 即平台的兴趣点挑选策略（即兴趣点挑选标记向量  $\mathbf{r}$ ）如何影响其激励用户参与执行任务所支付的奖励代价（即问题 PPM 的目标函数值）；2) 第三方应用的 App 活动内在效益值  $V$  如何影响感知平台的兴趣点挑选策略  $\mathbf{r}$ 。

关于平台的兴趣点挑选策略与奖励代价的实验，我们确定需要考虑的标记集的大小，然后使用算法1的贪婪算法 GreedyPPM 和随机算法 RandomizedPPM 进行挑选，对于贪婪算法 GreedyPPM，如果考虑的标记集大小大于最优集，则使用算法1第 7 行的操作  $t_i = \arg \min_{i \in C} \text{obj}(\mathbf{r}(\mathcal{S} \cup \{i\}))$  继续挑选知道满足标记集大小约束条件；而随机算法 RandomizedPPM 直接根据标记集大小随机挑选任务加入。得到的标记集后，带入问题 PPM 求其目标函数值，得到奖励代价。我们把实验效果展示在了图3.3，在图中，我们



可以看到存在一个标记集大小  $\|\mathbf{r}\|$  (横纵), 使得奖励代价最小 (纵轴)。这验证了平台选择全部的当前任务标记为活动兴趣点不是最优策略, 因为在某些任务的感知区域内存在较多普通用户, 平台可以直接通过相应的边缘服务器征募即可, 无需与第三方合作并支付一个多余直接征募的标记价格  $P_{app}$ 。另外, 图3.3中红线代表算法1的贪婪算法 GreedyPPM, 而蓝线和绿线代表基准随机算法 RandomizedPPM, 我们可以看到, 起初 GreedyPPM 和 RandomizedPPM 的奖励代价一样, 是因为平台不选择任一任务作为活动兴趣点而单独征募用户, 其奖励代价是一样的。而在以后的每一标记集大小中, GreedyPPM 比其他两个基准取得更低的奖励代价。此外, 我们可以看到, 如果当选择的标记任务越多时 (多于最优任务集), 那么 GreedyPPM 和 RandomizedPPM 所取得的奖励代价相近, 这是因为在标记任务越多, 所给第三方应用的标记费用主导奖励费用。

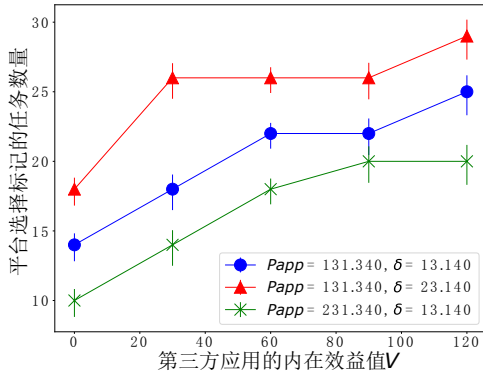


图 3.4 在不同参数 (App 活动的内在效益  $V$ 、兴趣点标记价格  $P_{app}$  和网络拥堵效应系数  $\delta$ ) 影响下, 平台挑选任务作为被标记活动兴趣点的数目




图 3.5 平台的奖励定价策略  $\rho_{t_i}$  对用户参与率的影响

关于第三方应用的 App 活动内在效益值  $V$  与感知平台的兴趣点挑选策略  $\mathbf{r}$  的关系, 我们设置了三组对比试验: 1)  $P_{app} = 131.34, \delta = 13.14$ ; 2)  $P_{app} = 131.34, \delta = 23.14$ ; 3)  $P_{app} = 231.34, \delta = 13.14$ 。并设置  $V$  的取值范围为  $[0, 120]$ 。实验效果如图3.4所示, 如果 App 活动内在效益值  $V$  越大, 代表第三方应用对用户的操控度越大, App 用户更愿意参与执行感知任务, 即  $V$  越大, 第三方应用协助激励的效果越好, 感知平台更倾向于与第三方应用合作, 所以会选择更多任务作为标记的活动兴趣点。然而, 如果标记价格越高, 感知平台选择的标记集就越小 (反映在绿线)。此外, 我们还可以观察到一个反直觉的效果 (反映在红线), 即如果网络拥堵效应系数  $\delta$  越大, 感知平台就会选择更多任务加入标记集, 这是因为网络质量越差时候, 普通用户和 App 用

户上网体验越差，平台单独征募普通用户时候需要花费更多的奖励代价，多于标记价格  $P_{app}$ ，那么此时，感知平台更倾向于和第三方应用合作，让第三方应用征募并引导 App 用户执行感知任务。

接下来，我们进行实验调研关于某一任务  $t_i$ ，平台的奖励定价策略  $\rho_{t_i}$  对用户参与率（普通用户和 App 用户）的影响。一些实验参数的取值依照表3.2，用户参与率根据引理3.1和3.2给出的计算公式。我们把  $\rho_{t_i}$  取值范围定在  $[0, 1000]$ 。结果如图3.5所示，其中，蓝线代表当任务没有被标记为活动兴趣点时，对应普通用户的参与率，红线和绿线分别对应着任务被标记为活动兴趣点时的 App 用户参与率和全部用户参与率。可以看出，所定价奖励  $\rho_{t_i}$  与用户参与率成正比，当任务被标记为活动兴趣点时总用户参与率大于没有被标记时的用户参与率。

### 3.4.2 关于第三方应用的策略性能评估




图 3.6 第三方应用的标记价格定价策略  $P_{app}$  与其效益函数的性能评估

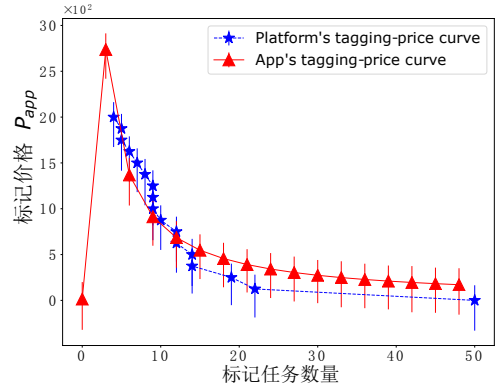


图 3.7 平台的标记需求曲线和第三方应用标记定价曲线关系

最后，我们评估第三方应用的标记价格定价策略  $P_{app}$ ，首先评估其对第三方应用效益函数的影响，最后通过感知平台的标记需求曲线和第三方应用标记定价曲线关系来直观刻画激励机制的均衡点。第三方应用的标记价格定价策略  $P_{app}$  与其效益函数的性能评估结果如图3.6所示，图中包含了三种实验场景下的第三方应用的标记价格定价策略  $P_{app}$  与其效益函数的曲线关系：1)  $\kappa = 0.5, a = 82.14$ ；2)  $\kappa = 0.6, a = 82.14$ ；3)  $\kappa = 0.5, a = 92.14$ 。从图中可以观察到存在一个最优的兴趣点标记价格  $P_{app}^*$  来最大化第三方应用的效益值。这是因为当兴趣点标记价格  $P_{app}$  越大时，平台就会选择少量的标记任务（即倾向于不合作），这样第三方应用的标记收入就越少。而兴趣点

标记价格  $P_{app}$  越少，第三方应用的标记收入也越少。因此，存在一个最优的兴趣点标记价格  $P_{app}^*$ 。此外，当 App 用户数越多，第三方应用的效益值就越大，这反映在绿线 ( $\kappa = 0.5$ ) 和蓝线 ( $\kappa = 0.6$ ) 的比较结果。我们也可以观察到单位广告收益值  $a$  对第三方应用效益的正效应，即随着  $a$  而增大，这反映在蓝线 ( $a = 82.14$ ) 和红线 ( $a = 92.14$ )。

最后，我们将感知平台的标记需求曲线和第三方应用标记定价曲线关系展示在图3.7，红线代表第三方应用的标记定价曲线，蓝线代表感知平台的标记需求曲线。从图3.7中，我们可以看到两个曲线在中间有一个交点，该点代表着整个激励机制过程对应三阶段斯坦克伯格博弈关于合作的均衡点，均衡点在 (12, 600) 处。

### 3.5 本章小结

在本章，我们探索了潜在的第三方应用合作，并用于设计激励机制 PTASIM，该激励机制高效地征募用户参与执行感知任务，并大量减少平台的奖励代价，保证了任务高质高量低成本的完成。我们使用三阶段斯坦克伯格博弈来建模 PTASIM 激励机制，并博弈参与各方提供高效的策略交互方案，在阶段一，第三方应用首先确定兴趣点的标记价格变量，去最大化其效益函数。在阶段二，平台做关于当前任务的奖励定价决策，同时确定挑选一组任务来让第三方应用标记。在阶段三，所有用户根据其最大化效益函数的策略来决定是否要执行感知任务，以及执行哪个感知任务。最后，我们进行仿真实验来评估 PTASIM 激励机制，实验结果验证了该机制的高效性。



## 第4章 平台盈利性和用户公平性保证的长期激励机制

在本章，我们考虑动态时变的群智感知场景，在这种场景下，不同的服务请求者在每一时槽生成各自的感知任务，并把任务以及所支付的费用提交给平台。此外，为了长期激励用户参与群智感知，则需要考虑用户被挑选为参与者的公平性约束。我们提出一个适用于连续时变感知场景的激励机制，并使用三阶段斯坦克伯格博弈建模该激励机制。我们系统分析了每个时槽的均衡策略交互，基于三阶段斯坦克伯格博弈的激励机制交互过程如下：在第一阶段，平台在没有足够多的信息情况下对接收到的任务进行定价决策（确定完成任务的奖励），并把所得到的任务-价格对通知给在线用户。在第二阶段，在线用户收到当前时槽的任务及其价格后挑选满足某些约束的一组任务作为兴趣集，汇报给平台。在第三阶段，平台挑选用户来覆盖当前任务集并满足一些挑选约束（如覆盖约束和公平性约束）。由于没有先验知识和未来时槽的任务需求和用户兴趣信息，我们使用李雅普诺夫优化技术来解决第一和第三阶段平台的在线决策问题，提出的第一阶段在线任务定价算法达到了平台收益和感知系统效益（任务被更多用户的执行）的性能折中  $[\mathcal{O}(1/\nu), \mathcal{O}(\nu)]$ ，提出的第三阶段在线用户选择算法达到了用户公平性保障和平台征募奖励最小化的性能折中  $[\mathcal{O}(1/V), \mathcal{O}(V)]$ 。考虑到决策的快速响应需求，我们提出一个完全多项式时间近似方案让用户在第二阶段根据自己移动设备的计算能力来计算一组  $(1 - \varepsilon)$ -近优任务集作为兴趣集。最后，我们通过数值仿真实验来验证所提出的激励机制在连续时变的感知场景下具有较好的性能。

### 4.1 引言

移动时代的蓬勃发展使得各种如移动手机、平板电脑和可穿戴设备等智能设备在现代社会中更加普及盛行，人类社会生活中的方方面面由此得到很大的变革。其中，充分利用内置在用户所携带智能设备中的各种传感器来对现实世界进行实时测量，则催生了物联网中一种新型的感知模式-移动群智感知<sup>[5,104]</sup>。群智感知成功的案例有实时交通信息监测的 Waze<sup>[115]</sup>，移动市场调研的 Gigwalk<sup>[116]</sup>，空气质量监测的 U-Air<sup>[117]</sup>和 CCS-TA<sup>[118]</sup>，公共信息共享的 FlierMeet<sup>[119]</sup>。

为了营建一个好的群智感知生态系统，设计一个合适的激励机制是必不可少的环节<sup>[62]</sup>。与第3章针对普通用户参与率少的情况通过第三方应用的协助来征募用户的激

励机制不同，本章所考虑的激励机制需要满足以下三个关键的必要条件才能成功地促使群智感知的可持续发展。1) 所有请求者的任务都被完成以及完成质量得到保障；2) 用户广泛参与到感知任务中来；3) 平台在分配任何和征募用户过程中实现盈利性。然而，很多现成激励机制研究工作<sup>[26,67,120]</sup>都稀释以上要求并做了较强的假设。一方面，它们只关注任务是否分配给用户执行<sup>[67]</sup>，或者用户贡献多少感知计算资源来执行感知任务<sup>[26,120]</sup>。这些研究工作都忽视了需要完成任务的质量问题。尽管后来有一个研究工作提出了质量驱动的激励机制，但是它无法处理请求者和用户的动态特征。另一方面，这些研究工作都假设只有一个服务请求者发布感知任务到平台，而且只考虑单时槽决策的静态场景。在实际情况下，不同的任务都会随时间而由不同请求者生成。因此，有必要考虑多时槽场景下的激励机制设计问题。值得注意的是，这些现成激励机制并不能简单地扩展到多时槽场景，因为请求者和用户具有动态属性，如可变的任务需求，用户随时间移动，以及在不同时槽离开群智感知系统而短暂“休眠”。为此，本章集中考虑一个更实际的感知场景：1) 激励需要考虑多时槽；2) 不同请求者请求者随时间生成感知任务；3) 用户可能因为手机电量不足而短暂休眠并离开群智感知系统，在休眠时候不参与执行感知任务。在这种场景下，我们还需要考虑用户对公平性的要求（公平地被选为工人参与执行感知任务并获得奖励）。这样用户才不会离开群智感知系统并持续地参与执行感知任务。此外，平台在分配任务，征募用户的过程当中获得盈利的要求在设计激励机制时也是非常重要的考虑因素，因为保证平台的盈利可以促使群智感知系统达到良好可持续的生态。然而，设计一个激励机制满足以上的要求存在以下挑战难点。

**任务的不确定性：**每个请求者在不同时间槽有不同的任务需求。这意味着在每个时间槽不同请求者发布到平台的任务不同。此外，由于每个请求者具有不同的预算，他们为订阅平台提供的感知服务支付的费用也不同。因此，任务的不确定性使得现成的静态激励机制很难扩展到多时槽时变场景。

**用户的动态性：**每个用户的感知状态都会随时间变化。他们的位置都服从用户的移动模型而改变。而且他们的手持设备因各种操作而持续消耗剩余电量。因此，用户执行感知任务的代价在每一时槽都是不一样的。此外，一些用户由于手持设备低电量或者繁忙而短暂“休眠”并离开群智感知系统。也就是说，用户动态地出现或者离开群智感知系统。因此，用户的动态性使得现有的离线激励机制无法正常使用。

**关键技术挑战：**本章所考虑的激励机制存在三个紧密关联的子问题。即对任意时



槽：1) 平台如何为接收到的感知任务进行定价决策来确定其完成时给予的奖励？2) 接着，用户如何在给定约束下从平台通知的任务集中挑选一组任务作为兴趣集来最大化其自己的效益？3) 最后，当平台接收都用户的兴趣集时，平台如何挑选用户来覆盖所有任务，并达到完成任务的约束？对于要解决的第一个子问题，没有关于请求者需求的先验知识、用户是否休眠的未来信息和当前时刻用户的兴趣集信息。这些特性使得第一个定价决策问题变为一个在线决策问题。当用户收到平台通报的当前任务及其奖励信息时，理性的用户都要选择满足一定约束的一组任务来执行，这样才能最大化其收益。然而，由于他们持有不同的移动设备，不同用户的计算能力不同，所以计算最优的兴趣集能力不同，这种挑战称为用户的有限理性<sup>[121]</sup>。当从用户那里收到关于当前任务的兴趣集信息时，平台面临用户挑选问题。但是，这个用户挑选问题存在以下两个挑战：1) 用户的感知代价是用户的私人信息，用户不愿意透露给平台，因此平台挑选用户时并不知道用户的私人信息。2) 用户挑选问题是一个 NP 难解问题（在分析环节证明）。此外，用户挑选问题还有一个公平性约束来保证用户公平地被选为工人而获得奖励。这是为了确保用户长期参与执行感知任务。然而，在一个本来就是 NP 难解的用户挑选问题考虑公平性约束将使得问题更具挑战性。尽管一些现有研究工作<sup>[67,73,79,122]</sup>使用拍卖论来完成用户任务的匹配以及诱导用户真实地揭露其私人信息，并支付其 VCG 奖励，但是拍卖论并不适合本章考虑的激励机制设计问题。这是因为本章考虑的场景需要在每个时槽的初始时刻快速地分配任务给用户，而拍卖论者需要等待用户提交完竞价后才能确定。此外，拍卖论还需要用户对任务有一个对任务的内在估值函数，并因此会自动地对任务提交竞价。这种强假设需要用户主动地参与和平台进行多轮交互，使得平台和用户之间的策略交互更加复杂。因此，我们希望在本章中设计一个激励机制，以平台为中心，面向动态任务到达的场景，而且用户可以被动式或者准被动式地参与群智感知系统。

在本章，我们提出一个基于三阶段斯坦克伯格博弈的激励机制来解决群智感知系统中请求者的可变任务需求和用户的动态性。上述中每个时槽的三个子问题将建模为一个三阶段斯坦克伯格博弈。在第一阶段，平台使用所提出的在线算法做定价决策，值得注意的是，这个在线算法结合了在线凸优化的 Zinkevich 在线梯度学习方法和李雅普诺夫优化的 drift-plus-penalty 技术来设计的。在第二阶段，不同用户根据提出的完全多项式近似算法计算出一组任务作为兴趣集。在第三阶段，平台求解一个在线用户挑选问题，同时考虑了关于用户的公平性约束。得到问题的解后，平台根据解来挑选用户。我们总结本章的创新点如下：

- 我们考虑了一个时变的群智感知场景，在这个场景下，任务需求存在不确定性而且用户也具有动态性特征。我们将统一解决存在于请求者、用户和平台之间复杂的策略交互问题。我们提出的激励机制可以保证用户被公平地挑选为工人，从而促进了用户长期参与到群智感知系统，满足了用户的有限理性约束来揭露他们自己的兴趣集信息，最后确保了平台的长期盈利目标从而维持了群智感知系统的可持续发展生态。
- 在第一阶段，我们通过结合了 Zinkevich 在线梯度学习方法和李雅普诺夫优化的 drift-plus-penalty 技术来设计在线定价算法，这个在线定价算法可以让平台在最大化系统效益和追求盈利最大化两个目标进行折中。在第二阶段，我们考虑了用户不同的计算能力并设计一个完全多项式近似算法为每个计算能力不同的用户计算出一组最优任务集作为自己的兴趣信息提交给平台。在第三阶段，平台通过结合集合多覆盖的近似算法和李雅普诺夫优化技术，使用用户提交的兴趣集信息设计在线用户挑选算法。该算法可以让平台在保证近似比和保证公平性之间进行折中。
- 我们使用数值仿真实验来评估本章所提出的激励机制。实验结果揭示了从长期效果的角度来看，该激励机制保证了用户被公平地挑选为工人，同时也满足了平台的可盈利性。

本章组织结构如下：在第4.2节，我们介绍群智感知系统的任务、平台和用户的模型和参数定义，引出平台和用户的效益函数，接着描述基于三阶段斯坦克伯格激励机制对应的三个子问题，以及所设计的激励机制在边缘-云架构的实现方式。在第4.3节，分三阶段提出激励机制的解决方法，通过后向推断来推导激励机制的斯坦克伯格均衡点：平台在第一阶段的最优奖励定价策略、用户在第二阶段的最优兴趣集揭露策略和平台在第三阶段的最优用户选择策略。在第4.4节，我们使用数值仿真实验来验证激励机制的性能：平台达到了在最大化群智感知系统整体效益和追求盈利上的折中，用户根据自己设备的计算能力计算近似最优的任务兴趣集，平台在用户选择中达到了保证公平性和降低奖励成本的折中。最后，在第4.5节我们总结了本章所设计的激励机制。



表 4.1 第4章所设计的激励机制常用数学符号表

符号	含义
用户	$\mathcal{N}, N$
	用户集和用户集的大小
	$\mathcal{S}_i^t$
	用户 $i$ 的兴趣集
	$c_{ij}^t$
	用户 $i$ 执行任务 $j$ 的感知代价
	$\beta_i^t$
	用户 $i$ 的资源总量值
平台	$x_i^t$
	指示用户 $i$ 是否被挑选为工人的布尔变量
	$\bar{x}_i$
	用户 $i$ 的时间平均挑选率
	$D_i$
	用户 $i$ 离开群智感知系统的概率
	$\eta_i$
	分配给用户 $i$ 的最大任务数量
平台	$p_j^t$
	请求者 $j$ 在第 $t$ 轮支付的单位费用
	$\mathbf{p}_t$
	第 $t$ 轮平台收到的单位费用向量
	$r_j^t$
	平台在第 $t$ 轮为任务 $j$ 所做的定价决策变量
	$\mathbf{r}_t$
	第 $t$ 轮的奖励定价决策向量
任务	$d_j^t$
	对第 $t$ 轮任务 $j$ 感兴趣的用户数量（兴趣数量）
	$\mathbf{d}_t$
	在第 $t$ 轮所有任务的兴趣数量组成的向量
	$U_t(\mathbf{r}_t \mathbf{d}_t)$
	平台在第 $t$ 轮的效益函数
任务	$B$
	平台最大的奖励预算
	$M$
	请求者的数量
	$\mathcal{M}_t, \mathbf{M}_t$
任务	第 $t$ 轮请求者发布的任务集和任务集的大小
	$k_j^t$
	需要挑选来执行第 $t$ 轮任务 $j$ 的用户数量
任务	$\theta_j$
	执行任务 $j$ 需要消耗的资源数目

## 4.2 模型和定义

在介绍系统模型，陈述研究问题，分析理论结果之前，我们总结了本章主要的数学符号如表4.1以方便查阅。

### 4.2.1 任务模型

我们假设有  $M$  个请求者订阅平台的群智感知服务。在本章中，我们考虑  $T$  轮策略交互的结果，尽管如此，所设计的激励机制可以拓展到任意的时槽长度。在  $t$  时槽，一组请求者发布任务请求到平台。每个请求者在每一时槽只能发布一个任务。在  $t$  轮时槽的任务集记作  $\mathcal{M}_t$ ，其大小为  $|\mathcal{M}_t| = M_t$ 。每个任务  $j \in \mathcal{M}_t$  都关联一个单位支付费用  $p_j$ ，表示当任务  $j$  被完成时，所属的请求者将支付给平台  $p_j$  单位费用，我们假设  $p_j$  服从某一未知的分布，这一分布于所属请求者的预算有关。这里，我们说变量  $j$  时，可以表示任务  $j$ ，也可以表示该任务所属的请求者  $j$ ，在不混淆情况下其含义取决于上下文。对于该轮没有发布任务的请求者  $j \in \mathcal{M}_t$ ，其支付  $p_j = 0$ 。我们假设请求者可以容忍任务存在一定时间的延迟，这意味着  $t$  时槽发布的任务可能不在  $t$  时槽内得到完成结果。当任务  $j \in \mathcal{M}_t$  被执行时，它将消耗用户手持设备的计算资源和存储

资源，造成电量消耗  $\theta_j$ 。

#### 4.2.2 平台模型

在  $t$  轮初始阶段，平台收到了一组来组请求者发来的任务集  $\mathcal{M}_t$ 。基于收到请求者的单位支付费用  $\mathbf{p}_t = (p_1^t, p_2^t, \dots, p_M^t)$ ，平台需要做定价决策  $\mathbf{r}_t = (r_1^t, r_2^t, \dots, r_M^t)$ ，即作为奖励吸引用户参与。当把定价决策  $\mathbf{r}_t$  通知给用户后，平台收到来自用户对当前任务的兴趣信息  $\mathbf{d}_t$ ，表示有  $d_j^t \in \mathbf{d}_t$  个用户对任务  $j$  ( $\forall j \in \mathcal{M}_t$ ) 感兴趣，愿意执行它。值得注意的是，直到用户汇报其兴趣信息给平台后，平台才知道变量  $\mathbf{d}_t$  的具体值。而在此之前，需要实现确定定价决策  $\mathbf{r}_t$ 。在收到用户关于任务的兴趣信息  $\mathbf{d}_t$  后，平台达到一个效益值，由效益函数  $U_t(\mathbf{r}_t|\mathbf{d}_t)$  表征。一般地，我们假设  $U_t(\mathbf{r}_t|\mathbf{d}_t)$  是关于  $\mathbf{r}_t$  连续且为上凸的。常用的效益函数<sup>[26,75,120]</sup>形式是：

$$U_t(\mathbf{r}_t|\mathbf{d}_t) = \sum_{j \in \mathcal{M}_t} \log(1 + r_j^t d_j^t), \quad (4.1)$$

这里的  $r_j^t d_j^t$  可以解释为平台在任务  $j$  的最大投资，而  $\log(1 + r_j^t d_j^t)$  作为任务  $j$  所产生的效益，这种形式可以捕捉到平台在任务  $j$  最大投资的边际递减效益属性。下面的引用表征了公式 (4.1) 中效益函数的函数属性，这个属性将有助于平台如何最大化它。

**引理 4.1.** 在公式 (4.1) 中  $U_t(\mathbf{r}_t|\mathbf{d}_t)$  是关于  $\mathbf{r}_t$  上凸的。

**证明.** 当  $\mathbf{d}_t$  已知时，此效益函数是上凸的，这是因为  $\log(\cdot)$  函数的上凸性。如果  $\mathbf{d}_t$  不给定， $\mathbf{d}_t$  与  $\mathbf{r}_t$  相关。对于任务  $j$ ，我们将奖励-参与函数记作  $d_j^t(r_j^t)$ 。我们可以假设  $d_j^t(r_j^t)$  具有边际递减的上凸属性，这个假设是合理的因为文献<sup>[75]</sup>已经证明了奖励与参与度的关系具有边际效益递减的属性，这意味着用户的参与度随着奖励的增加而增加，但是边际值递减，即参与度的变化量，同时也表明该函数的一阶导数为负，二阶导数为正。通过检查一阶条件和二阶条件，我们可以判断效益函数  $\log(1 + r_j^t d_j^t(r_j^t))$  对于任务  $j$  是关于  $r_j^t$  上凸的。将这个分析判别扩展到总的效益函数  $U_t(\mathbf{r}_t|\mathbf{d}_t)$  的海塞矩阵<sup>[123]</sup>，我们可以证明该引理的结论。  $\square$

平台一般从长远角度出发，最大化时间平均效益函数。而在每个时槽中，可行的定价决策  $\mathbf{r}_t$  满足以下条件：

$$\mathcal{R} = \{\mathbf{r}_t | \mathbf{r}_t \cdot \mathbf{1}^\top \leq B\}, \quad (4.2)$$

这里常数  $B$  是平台在每一轮中的最大奖励预算。此外，平台的另外一个目标是在长远角度上获得盈利，所以定价决策还满足以下时间平均定价约束：

$$\overline{p_j} = \lim_{t \rightarrow \infty} \frac{\sum_{\tau=0}^t p_j^\tau}{t} \geq \lim_{t \rightarrow \infty} \frac{\sum_{\tau=0}^t r_j^\tau}{t} = \overline{r_j}. \quad (4.3)$$

为了叙述建模，我们定义符号  $\overline{\mathbf{p}} = (\overline{p_1}, \overline{p_2}, \dots, \overline{p_j}, \dots, \overline{p_M})$  and  $\overline{\mathbf{r}} = (\overline{r_1}, \overline{r_2}, \dots, \overline{r_j}, \dots, \overline{r_M})$ 。除了解决在线定价问题，平台还需要根据收到的用户兴趣信息完成在线用户挑选问题。对于任务  $j$ ，平台挑选了  $k_j^t$  个用户来完成该任务，这是为了得到多份关于此任务更精确的数据，从而提升关于任务的服务质量。显然，数量  $k_j^t$  小于  $d_j^t$ ，这是因为可挑选的人数不应超过对该任务感兴趣的人数。尽管数量  $d_j^t$  对于平台来说是未知的，但是平台可以预先设定合适的  $k_j^t$ 。

### 4.2.3 用户模型

假设有  $N$  个移动用户注册到群智感知系统，用户集记作  $\mathcal{N} = \{1, 2, \dots, N\}$ 。用户随着时间出现在各个任务的兴趣点（Point-of-Interest, PoI）。每一时槽用户的位置由用户的移动模型随确定。在第  $t$  轮，用户  $i$  存在感知代价  $c_{ij}^t$  去执行任务  $j$ ，例如从它的位置到任务位置的交通费用。而且，由于剩余电量的不同，用户在不同时槽有不同的感知容量（与当前电量相关）。我们将时槽  $t$  用户  $i$  的感知容量记作  $\beta_i^t$ ，我们假设  $\beta_i^t$  对于用户  $i \in \mathcal{N}$  是随时间的独立同部分随机变量。当得知平台的定价决策  $\mathbf{r}_t$ ，用户  $i$  基于感知约束选择一组任务子集  $\mathcal{S}_i^t \subseteq \mathcal{M}_t$  作为自己的兴趣集，然而将所确定的兴趣集  $\mathcal{S}_i^t$  提交给平台。当平台收到所有用户的兴趣集信息后，平台可以确定任务  $j$  的兴趣数目  $d_j^t$ ，即  $d_j^t = \sum_{i \in \mathcal{N}} \mathbf{1}_{\{j \in \mathcal{S}_i^t\}}$ ，这里的  $\mathbf{1}_{\{\cdot\}}$  是指示函数，当条件为真时，它的值为 1。

群智感知系统是随时间动态演进的，这种场景下每一轮的任务都被分配给用户去完成。但是，如果用户长期不被选择工人，那么他们参与群智感知的积极性将褪去，从而离开群智感知系统。为此，平台很有必要确保以下公平性约束来保证用户的长期参与度<sup>[72]</sup>：

$$\liminf_{t \rightarrow \infty} \frac{\sum_{\tau=0}^t x_i^\tau}{t} = \overline{x}_i \geq D_i, \forall i \in \mathcal{N}. \quad (4.4)$$

这里的  $x_i^t \in \{0, 1\}$  是一个布尔变量，指示用户  $i$  是否被挑选为工人。 $\overline{x}_i$  是用户  $i$  的时间平均挑选率。 $D_i$  是用户  $i$  挑选率的阈值量，可以解释为用户  $i$  的参与率，时间平均

挑选率  $\bar{x}_i$  低于这个值时，用户  $i$  将离开群智感知系统。因此，在式 (4.4) 中的约束表明用户  $i$  的时间平均挑选率应该不低于  $D_i$ ，这样用户  $i$  才会停留在群智感知系统中并持续参与执行感知任务。根据上述的描述，我们定义所设计激励机制的公平性如下：

**定义 4.1 (公平性).** 一个激励机制可以被认为是公平的当且仅当式 (4.4) 中的不等式对所有用户  $i \in \mathcal{N}$  成立，而且分配给用户  $i$  的任务数量不多于  $\eta_i$ 。

公平性定义中的第一部分（即式 (4.4)）在文献<sup>[72,124]</sup>中的用法类似，都关注于确保用户的长期参与度。而第二部分可以确保更多用户有机会被挑选来执行感知任务，这样用户的广发参与度得到保障（即基数约束）。注意，我们假设群智感知系统不存在恶意用户，这样我们可以集中注意力到所设计激励机制的长期效果。另外，在我们设计的激励机制中，请求者是无策略性的，因为请求者只关注于服务质量。由于所设计的激励机制可以达到较高的效率，所执行的时间都是多项式阶的，激励机制可扩展到任意数量的请求者情况。

#### 4.2.4 问题描述

我们使用三阶段斯坦克伯格博弈来建模本章所研究的激励机制设计问题。在每个阶段，平台和用户都要解决不同的子问题，并根据子问题的解做相应的决策。博弈的形式化如下：

- **阶段一：**在时槽  $t$  的初始阶段，平台需要对请求者提交的任务做在线最优定价决策  $\mathbf{r}_t^*$  来最大化时间平均的期望效益函数  $\mathbb{E}[U_t(\mathbf{r}_t|\mathbf{d}_t)]$ ，这个决策可以通过求解以下随机规划问题而得到：

$$(P1) \quad \begin{aligned} & \max \liminf_{t \rightarrow \infty} \frac{\sum_{\tau=0}^t \mathbb{E}[U_t(\mathbf{r}_t|\mathbf{d}_t)]}{t} \\ & s.t. \quad \begin{cases} \bar{\mathbf{r}} \leq \bar{\mathbf{p}}, \\ \mathbf{r}_j^t \geq 0, \\ (\mathbf{r}_t \in \mathcal{R}, j \in \mathcal{M}_t). \end{cases} \end{aligned}$$

第一个约束保证了平台的长期盈利性，第二个约束确保所求解的奖励价格为非负。一旦平台从问题 (P1) 求解出定价决策，它将把当前任务及其对应的奖励价格通知给用户。值得注意的是，与一般的确定性规划问题不同，问题 (P1) 的当

前效益函数  $U_t(\mathbf{r}_t|\mathbf{d}_t)$  事先不知道，直到用户在阶段二确定其兴趣集信息并通报给平台后，平台才知道  $\mathbf{d}_t$ ，进而才知道  $U_t(\mathbf{r}_t|\mathbf{d}_t)$  的确切形式。

- **阶段二：**当平台将阶段一所定的决策  $\mathbf{r}_t^*$  通知给用户时，每个用户决定挑选一组任务作为其兴趣集。我们使用有界背包问题来建模用户的兴趣集确定问题。那用户  $i$  作为例子，它的兴趣集确定问题可以形式化为如下：

$$(P2) \quad \begin{aligned} & \max \sum_{j \in \mathcal{M}_t} r_j^t y_{ij}^t \\ & s.t. \quad \begin{cases} \sum_{j \in \mathcal{M}_t} \theta_j y_{ij}^t \leq \beta_i^t, \\ r_j^t y_{ij}^t \geq c_{ij}^t, \\ \sum_{j \in \mathcal{M}_t} y_{ij}^t \leq \eta_i, \\ (y_{ij}^t \in \{0, 1\}, j \in \mathcal{M}_t). \end{cases} \end{aligned}$$

问题 (P2) 的目标函数  $\sum_{j \in \mathcal{M}_t} r_j^t y_{ij}^t$  是挑选当前任务来执行时用户  $i$  所得到的总奖励。第一个约束确保了所挑选的任务消耗的总电量（即， $\sum_{j \in \mathcal{M}_t} \theta_j y_{ij}^t$ ）不超过用户  $i$  当前的感知容量（即， $\beta_i^t$ ）。第二个约束揭示了用户只对奖励值不低于其感知代价的任务感兴趣，从而挑选这些任务。第三个约束表明了用户  $i$  挑选的任务数量不能超过  $\eta_i$ ，这是由于公平性定义（定义4.1）所决定的。求解问题 (P2) 后，用户  $i$  可以构造其兴趣集  $\mathcal{S}_i^t = \{j|y_{ij}^t = 1\}$ 。每个用户单独求解问题 (P2) 来揭露其兴趣集，并汇报给平台。平台接下来在阶段三解决用户挑选问题，根据问题的解来挑选用户并满足规定的约束。被平台挑选到的用户，当他们执行完各自兴趣集里的任务，他们将由平台支付给他们由阶段一确定的奖励价格  $\mathbf{r}_t^*$ 。

- **阶段三：**当平台得知用户的兴趣集信息后，平台挑选用户去执行他们各自的兴趣集任务，并服从任务的约束和用户的长期参与约束。用户挑选问题的目标是 minimized 挑选用户所支付的时间平均奖励代价。由于存在时间平均代价和时间平均约束，我们把用户挑选问题形式化为以下随机规划问题：

$$(P3) \quad \begin{aligned} & \min \limsup_{t \rightarrow \infty} \frac{\sum_{\tau=0}^t \sum_{i \in \mathcal{N}} R_i^t x_i^t}{t} \\ & s.t. \quad \begin{cases} \sum_{S_i^t: j \in S_i^t} x_i^t \geq k_j^t, \\ \liminf_{t \rightarrow \infty} \frac{\sum_{\tau=0}^t x_i^t}{t} = \bar{x}_i \geq D_i, \\ (x_i^t \in \{0, 1\}, i \in \mathcal{N}, j \in \mathcal{M}_t). \end{cases} \end{aligned}$$



这里的  $R_i^t$  是指平台给用户  $i$  执行其任务集  $\mathcal{S}_i^t$  的奖励代价。第一个约束揭示了任意的任务  $j$  可以被至少  $k_j^t$  个用户执行，这样任务的质量可以得到保障。后一个约束可以确保所有用户的长期参与约束。

需要注意的是，上述的三个子问题是紧密关联的，这造成了无法单独的对每一个子问题进行求解。这是因为：1) 阶段一的价格决策影响问题 (P2) 的结果，同时又需要来自问题 (P2) 求解后的兴趣集信息；2) 在阶段二中问题 (P2) 的求解又影响着问题 (P1) 和问题 (P3) 的结果，同时又需要问题 (P1) 的奖励价格决策；最后，在阶段三中解决问题 (P3) 需要问题 (P2) 的兴趣集信息，但同时又反过来影响着用户是否在下一轮求解问题 (P2)（即公平性是否得到保障）。这里需要强调一下，对于斯坦克伯格博弈的各方来说，平台的策略确定是在阶段一和阶段三，而用户的策略确定是在阶段二。尽管在每一阶段，信息是不完全的，但是还是有可能使用后向推断法<sup>[107,111,125]</sup>来分析求解斯坦克伯格均衡策略（Stackelberg Equilibrium, SE）。

#### 4.2.5 该激励机制在边缘-云架构上的实现

由于所设计的激励机制需要进行计算密集型的策略交互，当平台对请求者和用户进行交互协调时候，传统的云架构群智感知模型会造成大量的延迟。可庆的是，新兴的移动边缘计算使得原本部署在云计算的服务更接近网络编译，为缓解传统基于云服务的群智感知架构响应延迟过大的挑战带来了机遇。我们把这种群智感知部署的架构成为基于边缘-云架构的群智感知。在边缘-云架构的群智感知中，平台卸载激励机制中的大部分工作量（奖励价格的决策、兴趣集的收集和用户挑选的确定）到边缘服务器，这些边缘服务器由于在网络的边缘，距离端用户更近，因此有利于快速响应。驻扎在云服务器的平台只接收来自请求者的服务请求，并转发所生成的任务到与任务的 PoI 较近的边缘服务器。边缘服务器一旦受到来自云服务器的任务后，立马运行本章所设计的三阶段斯坦克伯格博弈激励机制去征募移动用户为参与者来执行任务。一旦边缘服务器收集到来自参与者所执行任务获得的感知数据，边缘服务器进行数据融合，得到感知结果，最后把感知交给传给平台，平台再用感知结果服务请求者。这种边缘-云架构的群智感知模式已经存在一些早期研究<sup>[100-102]</sup>，我们相信在这种边缘-云架构下部署我们所设计的激励机制，将会达到很高的效率。此外，边缘-云架构的另外一个优势是保护了用户的隐私（感知数据只在边缘服务器进行融合），从而使得感知感知系统的安全性得到进一步提高。

### 4.3 激励机制设计

本节具体描述如何设计基于三阶段斯坦克博格博弈激励机制，我们从上述所描述三个子问题出发，使用后向推断法来求解博弈的均衡策略：即阶段一的在线用户挑选，阶段二的用户兴趣集揭露，阶段三的在线定价。

#### 4.3.1 阶段三：在线用户挑选

在这一小结，我们分析问题 (P3) 的解。我们使用以下引理来表征问题 (P3) 的问题特性。

**引理 4.2.** 问题 (P3) 是 NP 难解的。

**证明.** 本质上，问题 (P3) 可以视作受限集合覆盖问题。选择一组用户的兴趣集来覆盖当前所有任务，并且满足问题 (P3) 中的约束。因此，我们可以把原始集合多覆盖问题 (Set Multiple Cover, SMC) 归约到问题 (P3)，并附加额外长期参与约束（即问题 (P3) 中的第二个约束）。所要覆盖的全集是第  $t$  轮的所有任务，即  $\mathcal{M}_t$ 。子集族对应着所有用户的兴趣集。因此，完成了问题的归约。由于集合多覆盖问题 SMC 是属于 NP 完全问题，问题 (P3) 也属于 NP 难问题。所以，这个引理成立。  $\square$

**引理 4.3.** 如果存在一个任务  $j^\dagger \in \mathcal{M}_t$  满足  $\sum_{i \in \mathcal{N}} \mathbf{1}_{\{j^\dagger \in \mathcal{S}_i^t\}} < k_{j^\dagger}^t$ ，则问题 (P3) 无解。

**证明.** 该引理可以理解为，如果对一个任务感兴趣的用户数少于任务的覆盖数，则不存在一个覆盖对应问题 (P3) 的解。正式证明可以使用反证法来证明，假设引理条件  $\sum_{i \in \mathcal{N}} \mathbf{1}_{\{j^\dagger \in \mathcal{S}_i^t\}} < k_{j^\dagger}^t$  成立，并且问题 (P3) 存在这样一个解  $\mathbf{x}^t = (x_1^t, x_2^t, \dots, x_N^t)$ ，那么该解满足问题 (P3) 中的第一个约束，即  $\sum_{i \in \mathcal{S}_i^{*j} : j \in \mathcal{S}_i^{*j}} x_i^t = k_j^t$ 。但是，这与前面的前提假设存在冲突，由此得出引理中的结论。  $\square$

问题 (P3) 中的第二个约束是关于用户长期参与的约束，为了保证用户长期参与的约束得到满足，我们只需要确保用户在每个时槽都被公平地挑选为参与者去执行任务。根据定义 4.1，如果式 (4.4) 中的约束从长期角度来看是成立的话，公平性可以得到满足。然而，式 (4.4) 中的约束属于时间平均约束，为此，我们使用虚拟队列技术<sup>[43]</sup>来处理式 (4.4) 中的时间平均约束。这里的关键思想是确保式 (4.4) 中的约束等价于平台在挑选用户时候要维持所有用户对应的虚拟队列，使之达到稳定。为此，我们为每

一个用户  $i \in \mathcal{N}$  定义一个虚拟队列，该队列在时槽  $t$  虚拟长度记作  $Q_i(t)$ 。虚拟队列长度  $Q_i(t)$  随时间根据平台的挑选决策而改变，其变化规律可以用以下公式 (4.5) 的动态方程来描述：

$$Q_i(t+1) = \max\{Q_i(t) - x_i^t + D_i, 0\}. \quad (4.5)$$

该公式可以由式 (4.4) 中的约束转化而来。我们把所有虚拟队列长度的向量记作  $\mathbf{Q}(t) = (Q_1(t), Q_2(t), \dots, Q_N(t))$ 。虚拟队列长度可以解释为虚拟分配请求或者关于用户的虚拟分配债务。这意味着，如果一个用户长期不被挑选，那么其对应的虚拟队列长度会很大，从而虚拟队列系统得不到稳定。也就是说， $Q_i(t)$  越大，其对应式 (4.4) 中的约束偏离可行域就越多。为了满足式 (4.4) 中的长期约束，平台设计的用户挑选策略在挑选用户的时候需要考虑到所有用户的虚拟队列长度，这样式 (4.4) 中的长期约束对于每一个用户来说都可以成立。我们正式定义虚拟队列的稳定性如下：

**定义 4.2.** 一个队列系统  $\mathbf{Q}(t)$  是强稳定的当且仅当以下条件成立：

$$\limsup_{t \rightarrow \infty} \sum_{\tau=0}^t \mathbb{E}[\sum_{i=1}^N Q_i(\tau)] < \infty. \quad (4.6)$$

类似于向量范数反映向量的大小，我们定义一个标量函数来衡量虚拟队列总大小：

$$L(\mathbf{Q}(t)) = \frac{1}{2} \sum_{i=1}^N \omega_i Q_i^2(t). \quad (4.7)$$

这里的  $\omega_i$  表示队列  $Q_i(t)$  的权重。为了公平处理每一个用户的虚拟队列，对于每一个用户  $i$ ，我们设  $\omega_i = 1$ 。式 (4.7) 的函数  $L(\mathbf{Q}(t)) \geq 0$  称作李雅普诺夫函数 (Lyapunov function) <sup>[43]</sup>，它有以下三个特性：1) 当  $L(\mathbf{Q}(t)) = 0$  时，这意味着时槽  $t$  的所有虚拟队列都为空；2) 在时槽  $t$ ， $L(\mathbf{Q}(t))$  的值越小，则所有虚拟队列长度就越小；3) 在时槽  $t$ ， $L(\mathbf{Q}(t))$  的值越大，则至少存在一个虚拟队列，其队列长度很大。因此，如果我们设计一个在线用户挑选算法，该算法同时考虑了控制李雅普诺夫函数  $L(\mathbf{Q}(t))$  在每个时槽的上界，那么所有虚拟队列就能在一定程度上满足稳定性。为了控制李雅普诺夫函数  $L(\mathbf{Q}(t))$  在每个时槽的上界，我们提出的在线用户挑选算法需要最小化两个连续时槽的李雅普诺夫函数的改变量。我们把两个连续时槽的李雅普诺夫函数的改变量称作李雅普诺夫漂移 (Lyapunov drift)，数学上的正式定义是  $\Delta(\mathbf{Q}(t)) \triangleq \mathbb{E}[L(\mathbf{Q}(t+1)) - L(\mathbf{Q}(t)) | \mathbf{Q}(t)]$ 。

当平台通过在每个时槽最小化李雅普诺夫漂移来挑选用户以保证用户长期参与



约束时，它的另外一个目标是挑选感知代价尽可能小的用户，这样支付的奖励费用就可以尽可能的少，以此来节省平台开支。无论如何，用户的感知代价是用户的私有信息，平台不得而知。所以平台使用其兴趣集对应的总奖励来代替，即平台最小化当前奖励代价的同时要保持虚拟队列  $\mathbf{Q}(t)$  的稳定性。然而，这两个目标（最小化奖励代价和稳定虚拟队列）是冲突的，因此，算法需要考虑两个冲突目标的折中，我们使用参数  $V$  来代表这种折中， $V$  越大，平台越偏向最小化奖励代价，反之，平台就偏向于稳定虚拟队列来保证用户的公平性约束。我们使用以下引理来表征平台的在线用户挑选策略。

**引理 4.4.** 对于  $\mathcal{N}$  中的用户，如果他们的兴趣集覆盖所有当前任务  $\mathcal{M}_t$ ，那么平台根据以下准则来挑选一组用户  $S_t^*$ ：

$$S_t^* = \arg \max_{S \in 2^{\mathcal{N}}} \sum_{i \in S} [Q_i(t) - V \sum_{j \in \mathcal{S}_i^t} r_j^t]. \quad (4.8)$$

这里的用户集  $S_t^*$  对应的兴趣集应该满足任务  $\mathcal{M}_t$  的覆盖要求，参数  $V$  是一个可控参数，平台可以调整它来折中虚拟队列的稳定和激励用户的奖励代价的最小化。

**证明.** 式 (4.8) 中的挑选准则可以使用漂移加惩罚技术（drift-plus-penalty, DPP）<sup>[43]</sup> 进行推导而得到。计算李雅普诺夫漂移的上界，我们得到：

$$L(\mathbf{Q}(t+1)) - L(\mathbf{Q}(t)) \quad (4.9a)$$

$$= \frac{1}{2} \sum_{i=1}^N Q_i^2(t+1) - \frac{1}{2} \sum_{i=1}^N Q_i^2(t) \quad (4.9b)$$

$$\leq \sum_{i=1}^N \frac{D_i^2 + (x_i^t)^2}{2} + \sum_{i=1}^N Q_i(t) D_i - \sum_{i=1}^N Q_i(t) x_i^t \quad (4.9c)$$

$$\leq N + \sum_{i=1}^N Q_i(t) D_i - \sum_{i=1}^N Q_i(t) x_i^t, \quad (4.9d)$$

其中，式 (4.9a) 是李雅普诺夫漂移的定义，式 (4.9b) 中替换李雅普诺夫函数的形式，式 (4.9c) 成立是因为不等式  $(\max\{Q - x + D, 0\})^2 \leq Q^2 + x^2 + D^2 + 2Q(D - x)$ ，式 (4.9d) 成立是因为变量  $D_i$  和  $x_i^t$  的取值范围是  $[0, 1]$ 。在上式 (4.9) 推导最后结果的两

端取关于当前虚拟队列长度  $Q(t)$  的条件期望，我们可以得到：

$$\Delta(Q(t)) \leq N + \sum_{i=1}^N Q_i(t) D_i - \mathbb{E}[\sum_{i=1}^N Q_i(t) x_i^t | Q(t)]. \quad (4.10)$$

在线用户挑选算法的决策变量只能影响式 (4.10) 的右边式子 (即  $\mathbb{E}[\sum_{i=1}^N Q_i(t) x_i^t | Q(t)]$ )。所以，在线用户选择算法通过选择一组用户  $S$  来最大化对应用户的当前虚拟队列长度  $\sum_{i \in S} Q_i(t)$ ，从而最小化式 (4.10) 中左边的李雅普诺夫漂移，同时还要满足任务覆盖的约束。另外，由于在线用户选择算法还需要关注另外一个目标，即最小化激励被挑选用户的奖励代价。因此，通过选择一个折中参数  $V$ ，算法最小化新的目标，即漂移加奖励代价（惩罚） $\Delta(Q(t)) + V\mathbb{E}[\sum_{i \in S} \sum_{j \in \mathcal{S}_i^t} r_j^t | Q(t)]$ ，这等价于最大化  $\sum_{i \in S} [Q_i(t) - V \sum_{j \in \mathcal{S}_i^t} r_j^t]$ ，即为式 (4.8) 中的挑选准则。需要注意的是，挑选的用户集  $S$ ，他们的兴趣集要多次覆盖当前所有任务  $\mathcal{M}_t$ 。  $\square$

---

**Algorithm 3** 在线用户挑选算法

---

**Input:** 平台的奖励决策  $r_t$ , 用户集  $\mathcal{N}$ , 当前的任务集  $\mathcal{M}_t$ , 挑选率阈值  $D_i (\forall i \in \mathcal{N})$ , 控制参数  $V$ , 任务覆盖数  $k_j^t (\forall j \in \mathcal{M}_t)$  和所有用户的兴趣集  $\{\mathcal{S}_1^t, \mathcal{S}_2^t, \dots, \mathcal{S}_N^t\}$

**Output:** 被选中的用户  $\mathcal{C}$

- 1: 初始化  $\mathcal{C} = \emptyset$ , 定义临时变量  $\zeta_j^t = 0, \forall j \in \mathcal{M}_t$ .
  - 2: 在时槽  $t$ , 根据方程 (4.5) 更新  $Q(t)$ .
  - 3: 令  $\mathcal{C}' = \mathcal{N}$ .
  - 4: **if** 根据引理4.3判断问题 (P3) 关于  $\mathcal{C}'$  无解 **then**
  - 5:     **return**  $\mathcal{C}$ .
  - 6: **end if**
  - 7: **while**  $\cup_{j \in \mathcal{M}_t} \zeta_j^t < k_j^t$  **do**
  - 8:     对于用户  $i \in \mathcal{C}'$ , 设置  $\alpha_i = \frac{\sum_{j \in \mathcal{S}_i^t} r_j^t}{|T_i|}$ , 其中  $T_i = \{j | j \in \mathcal{S}_i^t \text{ 且 } \zeta_j^t < k_j^t\}$ .
  - 9:      $i^* = \arg \max_{i \in \mathcal{C}'} Q_i(t) - V\alpha_i$ .
  - 10:     $\mathcal{C} = \mathcal{C} \cup \{i^*\}$ .
  - 11:     $\mathcal{C}' = \mathcal{C}' - \{i^*\}$ .
  - 12:     $\zeta_j^t = \zeta_j^t + 1, \forall j \in \mathcal{S}_{i^*}^t$ .
  - 13: **end while**
  - 14: **return**  $\mathcal{C}$ .
- 

基于引理4.4中的用户挑选准则，我们设计了在线用户挑选算法，算法的伪代码展示在算法3。在算法3中，我们输入平台的奖励决策  $r_t$ 、用户集  $\mathcal{N}$ 、当前的任务集  $\mathcal{M}_t$ 、对于每个用户  $i$  的挑选率阈值  $D_i$ 、控制参数  $V$ 、任务  $j$  的任务覆盖数  $k_j^t$  和所有用户的兴趣集  $\{\mathcal{S}_1^t, \mathcal{S}_2^t, \dots, \mathcal{S}_N^t\}$ 。在第1行，我们定义了集合  $\mathcal{C}$  来记录被挑选的用户，并初始化为空集。此外，我们还定义了为任务  $j$  一个计数器变量  $\zeta_j^t$ ，初值为0。在第2行，对

于即将进行的用户挑选决策，我们首先基于前一时槽的决策，用公式 (4.5) 更新所有用户的虚拟队列长度  $Q(t)$ 。在第 3–6 行，我们定义另外一个变量  $\mathcal{C}'$ （候选用户集）并初始化它的值为  $\mathcal{N}$ ，基于引理 4.3 我们用它来检查要解决的用户挑选问题是否存在解。如果没有解，算法返回空集，表示平台在该轮无法挑选合适的用户集满足任务需求。否则，我们在第 7–14 行求解被挑选的用户集  $\mathcal{C}$ 。这里的关键操作有：1) 对于每个用户  $i \in \mathcal{C}'$ ，计算其挑选代价  $\alpha_i$ （第 8 行），2) 对应所有用户  $i \in \mathcal{C}'$ ，关联一个新的指标值  $Q_i(t) - V\alpha_i$ ，3) 从  $\mathcal{C}'$  中找一个指标值  $Q_i(t) - V\alpha_i$  最大的用户  $i^*$ （第 9 行），4) 更新变量  $\mathcal{C}$ ， $\mathcal{C}'$  和  $\zeta_j^t$ （第 10–12 行）。执行关键操作后，我们获得被挑选的用户集  $\mathcal{C}$  并返回给平台供其选择该用户集所有的用户（第 14 行）。算法 3 的时间复杂度主要由第 7–13 行的 **while** 循环决定，这个循环执行时间取决于其判断条件  $\cup_{j \in \mathcal{M}_t} \zeta_j^t < k_j^t$ 。因此，它的时间复杂度最多是  $\mathcal{O}(|\mathcal{M}_t|K)$ ，其中  $K = \max_{j \in \mathcal{M}_t} k_j^t$ 。我们在定理 4.1 总结算法 3 的理论性能。

**定理 4.1.** 算法 3 所取得的理论性能如下式所示：

$$\bar{r} = \lim_{T \rightarrow \infty} \frac{1}{T} \sum_{t=0}^{T-1} \mathbb{E}[R(t)] \leq \mathcal{O}(\log \mathbf{M}_t) \mathbb{E}[OPT] + \frac{N}{V}, \quad (4.11)$$

$$\lim_{T \rightarrow \infty} \frac{1}{T} \sum_{t=0}^{T-1} \sum_{i=1}^N Q_i(t) \leq \frac{N}{\epsilon} + \frac{V(\mathcal{O}(\log \mathbf{M}_t) \mathbb{E}[OPT] - \bar{r})}{\epsilon}. \quad (4.12)$$

**证明.** 在上述不等式中，我们使用  $OPT$  来表示问题 (P3) 中的最小值，即挑选最优用户集  $S^*$  所带来的最小奖励代价。 $\epsilon$  是一个正常数，其满足  $\mathbb{E}[x_i^t] \geq D_i + \epsilon, (\forall i \in \mathcal{N})$ ，该常数的存在意味着算法 3 可以确保所有虚拟队列  $Q(t)$  稳定。为了便于分析，我们还定义符号  $R(t) = \sum_{i \in S} \sum_{j \in \mathcal{S}_i^t} r_j^t$ 。

回顾一下，算法 3 执行在线用户挑选并保证挑选的公平性，同时还要确保所支付的奖励代价接近于  $\mathcal{O}(\log \mathbf{M}_t) \mathbb{E}[OPT]$ （即使用纯贪婪算法时问题 (P3) 目标函数的近优值）。把不等式  $VR(t) \leq V\mathcal{O}(\log \mathbf{M}_t) \mathbb{E}[OPT]$  回代到式 (4.10)，并在两端取迭式期望，则得到：

$$\begin{aligned} & \mathbb{E}[L(Q(t+1))] - \mathbb{E}[L(Q(t))] + V\mathbb{E}[R(t)] \\ & \leq N + V\mathcal{O}(\log \mathbf{M}_t) \mathbb{E}[OPT] - \epsilon \sum_{i=1}^N Q_i(t). \end{aligned} \quad (4.13)$$

在式 (4.13) 的两端关于时槽  $t \in \{0, 1, \dots, T-1\}$  累计求和, 并使用伸缩和规律 (the law of telescoping, 即  $a_1 - a_2 + a_2 - a_3 + a_3 + a_n$ ), 则得到:

$$\begin{aligned} & \mathbb{E}[L(\mathbf{Q}(T))] - \mathbb{E}[L(\mathbf{Q}(0))] + V \sum_{t=0}^{T-1} \mathbb{E}[R(t)] \\ & \leq NT + VT\mathcal{O}(\log \mathbf{M}_t)\mathbb{E}[OPT] - \epsilon \sum_{t=0}^{T-1} \sum_{i=1}^N Q_i(t). \end{aligned} \quad (4.14)$$

在式 (4.14) 中重排各项, 并在两端除以  $VT$  (推导定理中第二个不等式时候用  $\epsilon T$ ), 然后最两端取极限  $\lim_{T \rightarrow \infty}$ , 最后省去一些不影响不等式符号的不相关项, 我们可以导出如下的不等式:

$$\begin{aligned} \bar{r} &= \lim_{T \rightarrow \infty} \frac{1}{T} \sum_{t=0}^{T-1} \mathbb{E}[R(t)] \leq \mathcal{O}(\log \mathbf{M}_t)\mathbb{E}[OPT] + \frac{N}{V}, \\ \lim_{T \rightarrow \infty} \frac{1}{T} \sum_{t=0}^{T-1} \sum_{i=1}^N Q_i(t) &\leq \frac{N}{\epsilon} + \frac{V(\mathcal{O}(\log \mathbf{M}_t)\mathbb{E}[OPT] - \bar{r})}{\epsilon}. \end{aligned}$$

故而, 该定理成立。  $\square$

上述定理4.1揭示了当控制参数  $V$  越大时, 算法3可以生成一个更小更接近于最小值的奖励代价。但是  $V$  越大, 虚拟队列长度的值也会相应地增大, 增加率是  $\mathcal{O}(V)$  阶。这意味着在  $V$  值很大的场景下, 算法3优先最优化激励用户所支付的奖励代价, 而牺牲了式 (4.4) 中的长期激励参与约束的收敛性 (即虚拟队列的稳定性)。反之, 在  $V$  值很小的场景下, 算法3优先稳定虚拟队列, 而牺牲最优化激励用户所支付的奖励代价。因此, 算法3在两个冲突目标, 最小化奖励代价和稳定虚拟队列进行性能的折中, 折中区间是  $[\mathcal{O}(\frac{1}{V}), \mathcal{O}(V)]$ 。当  $V \rightarrow \infty$ , 算法3退化为集合多重覆盖的贪婪算法, 并提供近似因子  $\mathcal{O}(\log \mathbf{M}_t)$ 。

值得注意的是, 通过少量的修改, 算法3可以拓展到用户可以“休眠”的场景, 这个场景下, 用户在某些时槽可能因为手机电量不足而短暂休眠并离开群智感知系统, 在休眠时候不参与执行感知任务。我们假设用户集  $\mathcal{N}_t \subseteq \mathcal{N}$  是在时槽  $t$  线上活跃的用户集, 平台值只需要使用式 (4.5) 来更新活跃用户集  $\mathcal{N}_t$  的虚拟队列长度, 其余操作和算法3一样。在时槽  $t$ , 对于休眠的用户 (即  $\mathcal{N} \setminus \mathcal{N}_t$ ), 我们保持他们的虚拟队列长度不变 (即  $Q_i(t) = Q_i(t-1), \forall i \in \mathcal{N} \setminus \mathcal{N}_t$ )。这可以解释为, 对于休眠的用户, 平台不用

为他们进行虚拟分配请求或者平台对他们没有分配债务。通过做上述的修改，得到的算法3变体可以处理用户休眠的场景。

#### 4.3.2 阶段二：用户对任务的兴趣揭露

在第  $t$  轮，当用户得知平台在阶段一为任务集  $\mathcal{M}_t$  做的奖励定价决策  $\mathbf{r}_t$  时，用户有动力去揭露他们对任务的兴趣，即选择一组任务，并汇报给平台，这是因为如果他们被选中为工人参与执行感知任务时候，他们就会根据奖励价格获得奖励。另外一个原因是，算法3可以保证用户的公平性约束，使得每个用户在长远角度上都有机会被选为工人参与执行感知任务并获得奖励。

正如在节4.2.4所述，用户通过求解问题 (P2) 来确定他们对当前任务集  $\mathcal{M}_t$  的兴趣。而问题 (P2) 又等价于背包问题，其中，物品对应任务，执行该任务所消耗的电量对应物品的大小，物品的利润对应着该任务的奖励价格，背包容量对于这用户的感知容量值  $\beta_i^t (\forall i \in \mathcal{N})$ 。无论如何，本节所解决的用户兴趣集确定问题与传统的背包问题存在两点不同：1) 我们的问题还考虑了激励约束（即  $r_j^t y_{ij}^t \geq c_{ij}^t$ ）；2) 我们对于每个用户的兴趣集增加了一个限制，即每个用户的兴趣集大小是有上界的，这是有公平性定义（即定义4.1）所规定的。尽管这样有这些不同点，我们可以在背包问题的动态规划上做稍微改动，则动态规划的方法可以用于求解问题 (P2)，所使用的动态递推方程如下所示：

$$H(j+1, \gamma) = \begin{cases} \min\{H(j, \gamma), \theta_{j+1} + H(j, \gamma - r_{j+1}^t)\}, & c_{i,j+1}^t \leq r_{j+1}^t \leq \gamma, \\ H(j, \gamma), & r_{j+1}^t < c_{i,j+1}^t, \end{cases} \quad (4.15)$$

其中， $H(j, \gamma)$  是关于已挑选任务  $\{1, 2, \dots, j\}$  的总电量消耗， $\gamma$  对应已挑选任务  $\{1, 2, \dots, j\}$  的总奖励。所以，问题 (P2) 的目标转化为最大化  $\max\{\gamma | H(\mathbf{M}_t, \gamma) \leq \beta_i^t\}$ ，此时对应着用户  $i$  挑选任务集  $\mathcal{S}_i^t$  作为兴趣集。每个用户可以使用动态规划来求解问题 (P2)，时间复杂度为  $\mathcal{O}(\mathbf{M}_t^2 R)$ ，其中  $R = \max_{j \in \mathcal{M}_t} r_j^t$ 。需要注意的是，动态规划求解问题 (P2) 是一个伪多项式时间复杂度的算法，它的复杂度取决于当前时槽  $t$  任务  $\mathbf{M}_t$  的数量大小和所得到的最大奖励值  $R$ 。尽管动态可以求得最优解，但当奖励很大  $R$  的时候，基于动态规划的算法执行时间会变得很长，违背了用户的有限理性约束（即有限的计算资源）。为此，我们需要设计一个近似算法计算近优解，我们通过使用一个折扣因子  $G = \frac{\varepsilon_i R}{\mathbf{M}_t}$  来松弛当前每个任务的奖励值，即将  $r_j^t$  松弛到  $\tilde{r}_j^t$ ，从而基于  $\tilde{r}_j^t$  使用动态规划

来求解。其中，参数  $\varepsilon_i$  是一个松弛参数，可以由用户  $i$  基于自己的计算资源进行调节。

---

**Algorithm 4** 兴趣集揭露算法
 

---

**Input:** 平台的奖励决策  $\mathbf{r}_t$ , 当前的任务集  $\mathcal{M}_t$ , 用户  $i$  的感知容量  $\beta_i^t$ , 分配给用户  $i$  的最大任务数量  $\eta_i$ , 执行该任务  $j$  所消耗的电量  $\theta_j$ , 用户  $i$  执行任务  $j$  的感知代价  $c_{ij}^t \forall j \in \mathcal{M}_t$  和松弛参数  $\varepsilon_i$

**Output:** 用户  $i$  的兴趣集  $\mathcal{S}_i^t$

- 1: 从  $\mathcal{M}_t$  中挑选满足激励约束  $r_j^t y_{ij}^t \geq c_{ij}^t (\forall j \in \mathcal{M}_t)$  的任务集，作为候选集，记作  $\mathcal{M}'_t$ .
  - 2: 确保  $\varepsilon_i > 0$ , 令  $G = \frac{\varepsilon_i R}{|\mathcal{M}'_t|}$ .
  - 3: **for**  $j \in \mathcal{M}'_t$  **do**
  - 4:   松弛奖励值  $\tilde{r}_j^t = \lfloor \frac{r_j^t}{G} \rfloor$ .
  - 5: **end for**
  - 6: 基于已松弛的奖励值  $\tilde{r}_j^t$  和候选集  $\mathcal{M}'_t$ ，使用动态规划（式 (4.15) 的递推公式）来计算兴趣集  $\mathcal{S}_i^t$ .
  - 7: **if**  $|\mathcal{S}_i^t| \leq \eta_i$  **then**
  - 8:   **return**  $\mathcal{S}_i^t$ .
  - 9: **else**
  - 10:   基于  $\tilde{r}_j^t$ ，以降序方式对所有任务  $j \in \mathcal{S}_i^t$  排序，得到  $\pi$ .
  - 11:   定义变量  $\tilde{\mathcal{S}}_i^t = \{\pi_1, \pi_2, \dots, \pi_{\eta_i}\}$ .
  - 12:   **return**  $\tilde{\mathcal{S}}_i^t$ .
  - 13: **end if**
- 

我们将用户的兴趣集揭露算法展示在算法4，该算法输入：平台的奖励决策  $\mathbf{r}_t$ , 当前的任务集  $\mathcal{M}_t$ , 用户  $i$  在时槽  $t$  的感知容量  $\beta_i^t$ , 分配给用户  $i$  的最大任务数量  $\eta_i$ , 执行该任务  $j$  所消耗的电量  $\theta_j$ , 时槽  $t$  用户  $i$  执行任务  $j$  的感知代价  $c_{ij}^t$  和松弛参数  $\varepsilon_i$ 。需要注意的是，每个用户在他们各自的手持设备单独运行算法4去揭露他们的兴趣集信息  $\tilde{\mathcal{S}}_i^t$ ，并汇报  $\tilde{\mathcal{S}}_i^t$  给平台。在第1行，用户  $i$  从  $\mathcal{M}_t$  中挑选满足激励约束  $r_j^t y_{ij}^t \geq c_{ij}^t (\forall j \in \mathcal{M}_t)$  的任务集，作为候选集  $\mathcal{M}'_t$ 。在第2行，用户  $i$  根据松弛参数  $\varepsilon_i$  计算折扣因子  $G$ 。在第3–5行，使用折扣因子  $G$  来计算候选集  $\mathcal{M}'_t$  中所有任务的新奖励价格  $(\tilde{r}_j^t, \forall j \in \mathcal{M}'_t)$ 。在第6行，用户  $i$  基于已松弛的奖励值  $\tilde{r}_j^t (\forall j \in \mathcal{M}'_t)$  从候选集  $\mathcal{M}'_t$  中使用动态规划（式 (4.15) 的递推公式）来选择获得最大奖励的兴趣集  $\mathcal{S}_i^t$ 。如果兴趣集  $\mathcal{S}_i^t$  的大小小于  $\eta_i$ ，该算法直接输出  $\mathcal{S}_i^t$ （第7–9行）。否则，算法基于  $\tilde{r}_j^t$ ，以降序方式排序所有任务  $j \in \mathcal{S}_i^t$ ，得到  $\pi$ ，取  $\pi$  中的前  $\eta_i$  组成用户  $i$  的兴趣集并返回。

在进行深入分析之前，我们首先给出一个定义来表征近似算法。

**定义 4.3** (完全多项式时间近似方案, FPTAS <sup>[126]</sup>). 假设  $\mathcal{A}$  是一个近似算法。如果它的时间复杂度是问题规模大小的上界，则算法  $\mathcal{A}$  叫做多项式时间近似方案。如果算法



$\mathcal{A}$  是一个多项式时间近似方案，并且它的时间复杂度依赖于一个松弛参数  $\varepsilon$ ，这个松弛参数同时也控制着算法的近似因子，那么算法  $\mathcal{A}$  叫做完全多项式时间近似方案，简称为 FPTAS。

我们下述的分析中展示了算法4的属性，并省去证明，类似的证明可以参考文献<sup>[126]</sup>的引理 8.3 和定理 8.4。

**引理 4.5.** 问题 (P2) 的目标值关于算法4输出的解满足：

$$Obj(\mathcal{S}_i^t) \geq (1 - \varepsilon_i)OPT. \quad (4.16)$$

**引理 4.6.** 算法4是问题 (P2) 的 FPTAS。

引理4.5表明了算法4的近似比为  $1 - \varepsilon_i$ 。引理4.6揭示了算法4的时间复杂度不仅依赖于候选集的大小  $|\mathcal{M}_t'|$ ，而且还与松弛参数  $\varepsilon_i$  有关。这是因为算法的时间复杂度是  $\mathcal{O}(|\mathcal{M}_t'|^2 \lfloor \frac{|\mathcal{M}_t'|}{\varepsilon_i} \rfloor)$ 。由此可见，我们可以通过松弛参数  $\varepsilon_i$  来控制问题 (P2) 解的粒度。如果需要一个细粒度小误差的解时，我们设置一个小的  $\varepsilon_i$  值，否则设置一个大的  $\varepsilon_i$  值。需要注意的是，在当前平台的奖励决策  $\mathbf{r}_t$  下，每个用户需要单独运行算法4来求解问题 (P2) 以揭露其对当前任务的兴趣集。不同用户的  $\varepsilon_i$  不同，与用户手持设备的计算能力有关。

### 4.3.3 阶段一：在线定价

对于在线决策的场景，平台首先需要在时槽  $t$  的初始阶段确定奖励价格决策  $\tilde{\mathbf{r}}_t$  去最大化效益函数  $U_t(\tilde{\mathbf{r}}_t | \tilde{\mathbf{d}}_t)$ 。在这里，我们使用了奖励价格决策变量和效益函数的新符号。即用  $\tilde{\mathbf{r}}_t$  来代替  $\mathbf{r}_t$ ，这是因为不是每个时槽每个请求者都有发布任务的需求，我们只需考虑那些有任务需求的请求者发布的任务，他们的奖励决策需要严格大于 0。具体来说， $\tilde{\mathbf{r}}_t = (r_{j(1)}^t, r_{j(2)}^t, \dots)$ ，其中， $j(k) \in \mathcal{M}_t, 1 \leq k \leq |\mathcal{M}_t|$ 。其他类似的变量如  $\tilde{\mathbf{d}}_t$ ， $\tilde{\mathbf{p}}_t$  和  $\tilde{\mathbf{Z}}(t)$  都有类似的含义。然而，最大化效益函数  $U_t(\tilde{\mathbf{r}}_t | \tilde{\mathbf{d}}_t)$  的挑战在于参数  $\tilde{\mathbf{d}}_t$  平台不能事先知道，直到用户在阶段二揭露其兴趣集信息，并汇报给平台后平台才知道这个变量的值。因此，平台的定价问题变成了一个在线决策问题，为此，我们设计了一个在线方法解决在线决策问题 (P1)，我们设计的方法结合了在线凸优化中 Zinkevich 在线梯度学习方法<sup>[127-130]</sup>和李雅普诺夫优化中 drift-plus-penalty 技术。这是因为传统的

在线凸优化方法，只能解决约束集是固定的问题，而每一时槽，请求者给予的支付费用都不同，因此约束集是变化的。而传统的李雅普诺夫优化只需要前一个时槽的决策变量信息，无法求出新时槽的决策，比如还需要梯度信息才能求出新时槽的决策。在线定价问题在求解奖励定价决策时需要保证式 (4.3) 长期定价约束。然而，这个约束又与最大化效益目标函数  $U_t(\tilde{\mathbf{r}}_t|\tilde{\mathbf{d}}_t)$  存在冲突，即保证平台的盈利性和最大化群智感知系统的整体效益。借助于阶段三使用虚拟队列技术保障用户的公平性约束来进行冲突目标问题的折中，我们定义了为每个请求者  $j$  一个预算队列，在时槽  $t$  的队列长度记作  $Z_j(t)$ ，队列长度随时间的变化过程由以下动态方程决定：

$$Z_j(t+1) = \min\{Z_j(t) + p_j^t - r_j^t, 0\}, \quad (4.17)$$

其中，如果请求者  $j$  不发布任务时候，它的费用和奖励定价决策变量都为 0，即  $p_j^t = r_j^t = 0, \forall j \notin \mathcal{M}_t$ 。奖励定价决策变量  $\tilde{\mathbf{r}}_t$  满足以下引理所表述的特性：

**引理 4.7.** 当任务集  $\mathcal{M}_t$  在时槽  $t$  到达，对于任一可调参数  $\nu > 0$ ，平台确定奖励定价决策变量  $\tilde{\mathbf{r}}_t$  的准则是最大化表达式： $\nu U_t(\tilde{\mathbf{r}}_t|\tilde{\mathbf{d}}_t) + \widetilde{\mathbf{Z}}(t)^\top \tilde{\mathbf{r}}_t$ ，即

$$\tilde{\mathbf{r}}_t^* = \arg \max_{\tilde{\mathbf{r}}_t} \nu U_t(\tilde{\mathbf{r}}_t|\tilde{\mathbf{d}}_t) + \widetilde{\mathbf{Z}}(t)^\top \tilde{\mathbf{r}}_t. \quad (4.18)$$

**证明.** 如阶段三分析公平性约束一样，我们定义一个李雅普诺夫函数  $L(\mathbf{Z}(t)) = \frac{1}{2} \sum_{j \in \mathcal{M}_t} Z_j^2(t)$ ，其李雅普诺夫漂移为  $\Delta(\mathbf{Z}(t)) \triangleq \mathbb{E}[L(\mathbf{Z}(t+1)) - L(\mathbf{Z}(t)) | \mathbf{Z}(t), j \in \mathcal{M}_t \cap \mathcal{M}_{t+1}]$ 。对李雅普诺夫漂移做进一步分析（代入李雅普诺夫函数，并简化），我们得到：

$$\Delta(\widetilde{\mathbf{Z}}(t)) \leq \frac{(\mathbf{1}^\top \widetilde{\mathbf{p}}_t)^2 + B^2}{2} + \widetilde{\mathbf{Z}}(t)^\top \widetilde{\mathbf{p}}_t - \widetilde{\mathbf{Z}}(t)^\top \tilde{\mathbf{r}}_t. \quad (4.19)$$

由式 4.19 可知，最小化李雅普诺夫漂移  $\Delta(\widetilde{\mathbf{Z}}(t))$  等价于通过确定  $\tilde{\mathbf{r}}_t$  来最小化  $-\widetilde{\mathbf{Z}}(t)^\top \tilde{\mathbf{r}}_t$  这一项。将惩罚项  $-\nu U_t(\tilde{\mathbf{r}}_t|\tilde{\mathbf{d}}_t)$  带入式 4.19 中，我们可以得到该引理的结论。  $\square$

尽管引理 4.7 给出了平台解决在线定价问题的准则，但是该问题还是难以解决的，因为效益目标函数  $U_t(\tilde{\mathbf{r}}_t|\tilde{\mathbf{d}}_t)$  平台无法预先知道。可幸的是，效益目标函数  $U_t(\tilde{\mathbf{r}}_t|\tilde{\mathbf{d}}_t)$  是上凸函数，这使得我们可以使用在线凸优化中 Zinkevich 在线梯度学习方法来设计在线定价算法。Zinkevich 在线梯度学习方法利用前一时槽的梯度信息，使用以下梯



度更新方程来求解新时槽的奖励定价决策变量:

$$\widetilde{\mathbf{r}}_{t+1} = \text{Proj}_{\mathcal{R}}\{\widetilde{\mathbf{r}}_t + \eta \nabla_{\mathbf{r}} U_t(\widetilde{\mathbf{r}}_t | \widetilde{\mathbf{d}}_t)\}, \quad (4.20)$$

其中,  $\text{Proj}_{\mathcal{R}}$  是投影变换, 把梯度上升的结果投影到可行奖励决策集  $\mathcal{R}$ ,  $\eta$  是学习率。由此可见, Zinkevich 在线梯度是一种在线学习方法, 可以从前一时槽的梯度信息学习新时槽的决策变量。然而, 使用式 (4.20) 的更新规则来最大化效益目标函数  $U_t(\widetilde{\mathbf{r}}_t | \widetilde{\mathbf{d}}_t)$  的同时, 还需要保持预算队列的稳定, 使得平台在长期角度上可以盈利。因此, 我们将在线凸优化中 Zinkevich 在线梯度学习方法和李雅普诺夫优化中 drift-plus-penalty 技术结合起来, 设计在线定价算法。以下引理展示了这种结合后的定价准则:

**引理 4.8.** 在时槽  $t$  平台根据以下准则做奖励定价决策:

$$\widetilde{\mathbf{r}}_t = \text{Proj}_{\mathcal{R}}\{\widetilde{\mathbf{r}}_{t-1} + \frac{1}{\nu} \nabla_{\mathbf{r}} U_{t-1}(\widetilde{\mathbf{r}}_{t-1} | \widetilde{\mathbf{d}}_{t-1}) + \frac{1}{\nu^2} \widetilde{\mathbf{Z}}(t)\}. \quad (4.21)$$

**证明.** 把关于效益目标函数  $U_t(\widetilde{\mathbf{r}}_t | \widetilde{\mathbf{d}}_t)$  的泰勒展开式带入式 (4.18), 并消除常数项, 我们得到:

$$\begin{aligned} \widetilde{\mathbf{r}}_t^* &= \arg \max_{\widetilde{\mathbf{r}}_t} \nu (\nabla_{\mathbf{r}} U_{t-1}(\widetilde{\mathbf{r}}_{t-1} | \widetilde{\mathbf{d}}_{t-1}))^\top (\widetilde{\mathbf{r}}_t - \widetilde{\mathbf{r}}_{t-1}) \\ &\quad - \frac{\nu^2}{2} \|\widetilde{\mathbf{r}}_t - \widetilde{\mathbf{r}}_{t-1}\|^2 + \widetilde{\mathbf{Z}}(t)^\top \widetilde{\mathbf{r}}_t. \end{aligned} \quad (4.22)$$

我们进一步转换投影变换的定义  $\min_{\widetilde{\mathbf{r}}_t \in \mathcal{R}} \|\widetilde{\mathbf{r}}_t - (\widetilde{\mathbf{r}}_{t-1} + \frac{1}{\nu} \nabla_{\mathbf{r}} U_{t-1}(\widetilde{\mathbf{r}}_{t-1} | \widetilde{\mathbf{d}}_{t-1}) + \frac{1}{\nu^2} \widetilde{\mathbf{Z}}(t))\|^2$  并将转换结果与上式 4.22 比较, 我们可以发现投影操作与式 4.22 是等价的。由此可见, 引理的结论成立。  $\square$

根据引理 4.8, 我们提出在线定价算法, 其伪代码如算法 5 所示。该算法输入第  $t$  轮的任务集  $\mathcal{M}_t$ , 第  $t$  轮平台收到请求者支付的单位费用向量  $\widetilde{\mathbf{p}}_t$ , 折中控制参数  $\nu$ 。在第 1 行, 算法初始化预算队列为  $Z_j(0) = 0, \forall j \in \{1, 2, \dots, M\}$ 。在第 2-4 行, 我们把当前任务  $\mathcal{M}_t$  划分成两个任务子集  $\mathcal{A}$  和  $\mathcal{B}$ 。 $\mathcal{A}$  中的任务对应着它们的所属请求者首先发布任务, 而  $\mathcal{B}$  中的任务对应着它们的所属请求者曾经发布过任务, 因此,  $\mathcal{B}$  中的任务包含历史信息  $\widetilde{\mathbf{r}}_{t-1}$  和  $\nabla_{\mathbf{r}} U_{t-1}(\widetilde{\mathbf{r}}_{t-1} | \widetilde{\mathbf{d}}_{t-1})$ , 这些历史信息可以基于引理 4.8 用于计算奖励定价决策变量  $\widetilde{\mathbf{r}}_t$  (第 6 行)。对于  $\mathcal{A}$  中的任务, 我们简单地将其奖励  $r_j^t$  赋值为其所属用于支付的单位费用  $p_j^t$ , 表示平台不从这些任务盈利 (第 7-9 行)。最后, 我们

---

**Algorithm 5** 在线定价算法
 

---

**Input:** 第  $t$  轮的任务集  $\mathcal{M}_t$ , 第  $t$  轮平台收到请求者支付的单位费用向量  $\tilde{\mathbf{p}}_t$ , 折中控制参数  $\nu$

**Output:** 对当前任务的奖励定价决策  $r_j^t (\forall j \in \mathcal{M}_t)$

- 1: 在时槽  $t = 0$ , 初始化  $Z_j(0) = 0, \forall j \in \{1, 2, \dots, M\}$ .
  - 2: 在时槽  $t > 0$ , 划分任务集  $\mathcal{M}_t$  为两个不相交的子集, 如下:
  - 3:  $\mathcal{A} = \{j | j \in \mathcal{M}_t \text{ 且请求者 } j \text{ 是首次发布任务的}\}$ .
  - 4:  $\mathcal{B} = \mathcal{M}_t \setminus \mathcal{A}$
  - 5: 将任务子集  $\mathcal{B}$  的奖励定价决策向量记作  $\tilde{\mathbf{r}}_t$ .
  - 6: 根据引理4.8计算  $\tilde{\mathbf{r}}_t$ .
  - 7: **for**  $j \in \mathcal{A}$  **do**
  - 8:     设置  $r_j^t = p_j^t$ .
  - 9: **end for**
  - 10: 根据式 (4.17) 更新  $Z_j(t), \forall j \in \mathcal{M}_t$ .
  - 11: **return**  $r_j^t (\forall j \in \mathcal{M}_t)$ .
- 

在第 10 行更新所有预算队列, 并在第 11 行返回所得到的奖励定价决策变量。显而易见, 算法5的时间复杂度为  $\mathcal{O}(M)$ 。我们在定理4.2描述算法5所取得的理论性能。

**定理 4.2.** 算法5所取得的理论性能如下式所示:

$$\bar{U} = \lim_{T \rightarrow \infty} \frac{1}{T} \sum_{t=0}^{T-1} \mathbb{E}[U_t] \geq \mathbb{E}[OPT] - \frac{\Omega}{\nu}, \quad (4.23)$$

$$\lim_{T \rightarrow \infty} \frac{1}{T} \sum_{t=0}^{T-1} \mathbf{Z}(t)^\top \mathbf{1} \geq -\frac{\Omega}{\delta} + \frac{\nu(\mathbb{E}[OPT] - \bar{U})}{\delta}. \quad (4.24)$$

**证明.** 在上述不等式中, 我们使用  $OPT$  来表示每一时槽离线场景下效益目标函数的最优值,  $\Omega$  是一个常数 (其值为  $\Omega = \frac{(\mathbf{1}^\top \tilde{\mathbf{p}})^2 + B^2}{2}$ ),  $\delta$  是一个正常数, 满足  $\mathbb{E}[r_j^t] + \delta \leq \mathbb{E}[p_j^t]$ , ( $\forall j \in \mathcal{M}_t$ )。

由于算法5旨在随时间最大化效益目标函数  $U_t(\tilde{\mathbf{r}}_t | \tilde{\mathbf{d}}_t)$ , 并使之收敛于离线最优值  $\mathbb{E}[OPT]$ 。与此同时, 算法5还需要维持预算队列  $\widetilde{\mathbf{Z}}(t)$  的稳定性。因此, 我们得到不等式  $U_t(\tilde{\mathbf{r}}_t | \tilde{\mathbf{d}}_t) \leq \mathbb{E}[OPT]$ , 此外还有  $U_t(\tilde{\mathbf{r}}_t | \tilde{\mathbf{d}}_t) \geq \mathbb{E}[OPT] - \Gamma(t)$ , 其中  $\Gamma(t)$  是效益目标函数  $U_t(\tilde{\mathbf{r}}_t | \tilde{\mathbf{d}}_t)$  和离线最优值  $\mathbb{E}[OPT]$  间隙序列关于时间的级数, 并队列稳定的情况下满足  $\lim_{t \rightarrow \infty} \frac{\sum_{\tau=0}^t \Gamma(\tau)}{t} = 0$ 。我们把  $U_t(\tilde{\mathbf{r}}_t | \tilde{\mathbf{d}}_t) \geq \mathbb{E}[OPT] - \Gamma(t)$  带入式 (4.19), 并在其

两端取迭式期望，则得到：

$$\begin{aligned} & \mathbb{E}[L(\widetilde{\mathbf{Z}(t+1)})] - \mathbb{E}[L(\widetilde{\mathbf{Z}(t)})] - \nu \mathbb{E}[U_t(\widetilde{\mathbf{r}}_t | \widetilde{\mathbf{d}}_t)] \\ & \leq \Omega - \nu \mathbb{E}[OPT] + \nu \Gamma(t) + \delta \mathbf{Z}(t)^\top \mathbf{1}. \end{aligned} \quad (4.25)$$

在式 (4.25) 的两端关于时槽  $t \in \{0, 1, \dots, T-1\}$  累计求和，并使用伸缩和规律（the law of telescoping，即  $a_1 - a_2 + a_2 - a_3 + a_3 + a_n$ ），则得到：

$$\begin{aligned} & \mathbb{E}[L(\widetilde{\mathbf{Z}(T)})] - \mathbb{E}[L(\widetilde{\mathbf{Z}(0)})] - \nu \sum_{t=0}^{T-1} \mathbb{E}[U_t(\widetilde{\mathbf{r}}_t | \widetilde{\mathbf{d}}_t)] \\ & \leq \Omega T - \nu T \mathbb{E}[OPT] + \nu \sum_{t=0}^{T-1} \Gamma(t) + \delta \sum_{t=0}^{T-1} \mathbf{Z}(t)^\top \mathbf{1}. \end{aligned} \quad (4.26)$$

在式 (4.26) 中重排各项，并在两端除以  $\nu T$ （推导定理中第二个不等式时候用  $\delta T$ ），然后最两端取极限  $\lim_{T \rightarrow \infty}$ ，最后省去一些不影响不等式符号的不相关项，我们可以导出如下的不等式：

$$\begin{aligned} \bar{U} &= \lim_{T \rightarrow \infty} \frac{1}{T} \sum_{t=0}^{T-1} \mathbb{E}[U_t] \geq \mathbb{E}[OPT] - \frac{\Omega}{\nu}, \\ \lim_{T \rightarrow \infty} \frac{1}{T} \sum_{t=0}^{T-1} \mathbf{Z}(t)^\top \mathbf{1} &\geq -\frac{\Omega}{\delta} + \frac{\nu(\mathbb{E}[OPT] - \bar{U})}{\delta}. \end{aligned}$$

故而，该定理成立。  $\square$

定理4.2揭示了预算队列  $\mathbf{Z}(t)$  的长度为负的，这与定理4.1中用到的虚拟队列  $\mathbf{Q}(t)$  的长度正负性不一样。这是因为预算队列  $\mathbf{Z}(t)$  的更新方程（即式 (4.17)）与虚拟队列  $\mathbf{Q}(t)$  的更新方程（即式 (4.5)）不一样。

## 4.4 仿真实验与分析

为了便于直接评估所提出的激励机制，在本节，我们执行仿真实验来验证本章所提激励机制的性能。不失一般性，我们采用了一个合成轨迹数据集来模拟群智感知系统，所得到效果可以扩展到真实轨迹数据集（如 D4D）模拟的群智感知系统。本章所牵涉的算法都是基于 Python 语言实现的，代码中对于线性规划（LP）和混合整数线性规划（MIP）部分使用了 CPLEX 的 Python 接口来实现。我们设置一些默认变量如下：用户数目  $N = 100$ ；对于所有用户，其  $D_i$  值使用均匀分布生成，即  $D_i \sim U(0.01, 0.11)$ ；

表 4.2 第4章的实验参数设置

参数符号	取值
总用户数 $N$	100
用户挑选率阈值 $D_i$	$\sim U(0.01, 0.11)$
支付单位费用 $p_j^t$	$\sim U(0, 1000)$
总时槽 $T$	1000
用户选择折中参数 $V$	20, 100
用户的资源总量值 $\beta_i^t$	$\sim U(50, 100)$
任务消耗的资源数量 $\theta_j$	$\sim U(1, 5)$
用户的奖励松弛因子 $\varepsilon_i$	$\sim U(0, 20)$
平台的奖励定价折中参数 $\nu$	10, 50
平台的最大预算 $B$	10000
总时槽 $T$	1000

对于所有请求者，其支付单位费用  $p_j^t$  值也由均匀分布生成，即  $p_j^t \sim U(0, 1000)$ ，总时槽长度为 1000 个时槽<sup>[26,72,120]</sup>。具体实验参数设置总结在表4.2中。

#### 4.4.1 阶段三的实验评估

在这一小结，我们首先单独验证算法3的性能，我们假设奖励定价决策变量  $\mathbf{r}_t$  在不同时槽都是给定的，这个可以在每一个时槽的开始阶段生成得到。在每一个时槽，每个请求者安装某种确定的分布生成一个任务。之后，用户选择一种任务来揭露其兴趣集信息，并汇报给平台。对于每个任务的覆盖数  $k_j^t$ ，平台对它的值从某一分布进行随机采样来确定（即  $k_j^t \sim U(1, d_j^t), \forall j \in \mathcal{M}_t$ ）。因此，我们得到了一个集合多覆盖问题实例，对应着阶段三的问题。为了求得最优解和最优值，我们使用 CPLEX 工具实现这个集合多覆盖问题，得到一个基准方案，我们假设每一时槽的总任务数最多为 30。我们还实现其他两个基准方案：一个是集合多覆盖问题的随机舍入算法，另一个是集合多覆盖问题的贪婪算法。值得注意的是，这两个算法都是集合多覆盖问题的经典近似算法，都提供了近似因子为  $\mathcal{O}(\log(|\mathcal{M}_t|))$  的性能。但是这三个基准程序并不能保证用户的长期参与约束。为了评估算法3的性能，我们考虑了两种  $V$  取不同值的场景： $V = 20$  和  $V = 100$ 。图4.1比较了算法3和三个基准方案（*OPT* 方案，贪婪 (greedy) 算法和随机舍入 (rounding) 算法）在付出奖励代价的性能。如图中  $V = 20$  和  $V = 100$  的曲线所示，算法3所要支付的奖励代价随时间增加，但是会趋于稳定。这是因为算法3牺牲原本可以获取到更低目标值的解去保证需要更高奖励代价用户的挑选率，从而使得长期参与约束得到满足。图4.2显示了算法3中虚拟队列长度随时间变化的曲线。如图4.2所示，如果  $V$  越大，算法3优先最小化奖励代价，但是反过来又需要更大的虚




图 4.1 算法3和基准方案在所获得的奖励代价目标函数上的性能比较




图 4.2 算法3在  $V = 20$  和  $V = 100$  时虚拟队列  $Q(t)$  总长度的性能比较

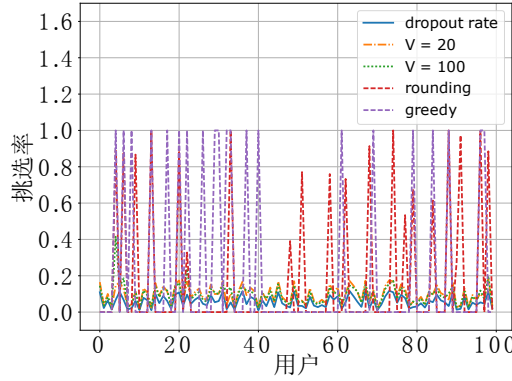


图 4.3 算法3在  $V = 20$  和  $V = 100$  时所有用户的挑选率性能比较

拟队列长度，这意味着虚拟队列需要更多时槽才能收敛，长期参与约束越难得到保障。图4.1和图4.2的结果验证了定理4.1的正确性。此外，我们还可以观察到， $OPT$  方案取得最小的奖励代价目标函数值，贪婪算法次之，随机舍入最差。与基准方案相比，算法3为了同时保证长期参与约束而造成了更大的奖励代价目标函数值，但是算法3可以收敛到一个稳定的次优值，其与最优值相差因子  $\mathcal{O}(\log M_t)$ 。但是图4.3的结果显示了基准方案都违反了用户的长期参与约束，导致他们无法长期激励用户参与群智感知系统，而算法3始终保持用户的挑选率曲线在逃离曲线之上，即挑选率大于逃离阈值。这些结果验证了我们所提出的算法具有保障公平性约束的特性。

#### 4.4.2 阶段二的实验评估

在这一小结，我们评估阶段二所提出了 FPTAS（即算法4）的性能。任务的数量是随机生成的，并发送到用户  $i$  供其挑选。我们使用均匀分布设置参数  $\beta_i^t$ 、 $r_j^t$ 、 $\theta_j$  的值，即  $\beta_i^t \sim U(50, 100)$ 、 $r_j^t \sim U(1, 100)$  和  $\theta_j \sim U(1, 5)$ ， $\forall j \in \mathcal{M}_t$ 。为了便于直接考察算法4FPTAS 的性能，我们设置小的感知代价值  $c_{ij}^t$ ，并使  $\eta_i$  的值大于当前任务的数量  $|\mathcal{M}_t|$ ，这样用户  $i$  可以完全被激励去现在所以到来的当前任务，作为兴趣集，其中  $\varepsilon_i$  的取值范围为  $[0, 20]$ 。

我们使用不同的  $\varepsilon_i$  运行 FPTAS 得到关于用户  $i$  兴趣集的总奖励，同时得到用户  $i$  运行 FPTAS 的运行时间。作为比较的基准程序，我们使用原始未松弛过的奖励定价决策输入到纯动态规划基准程序去计算最优值，并获取其总奖励和运行时间。我们把 FPTAS 和基准程序的比较标准：总奖励和运行时间，展示到图4.4。结果显示，如果  $\varepsilon_i$  的值越小，FPTAS 所得到的目标值越接近基金程序，但是运行时间会变多。

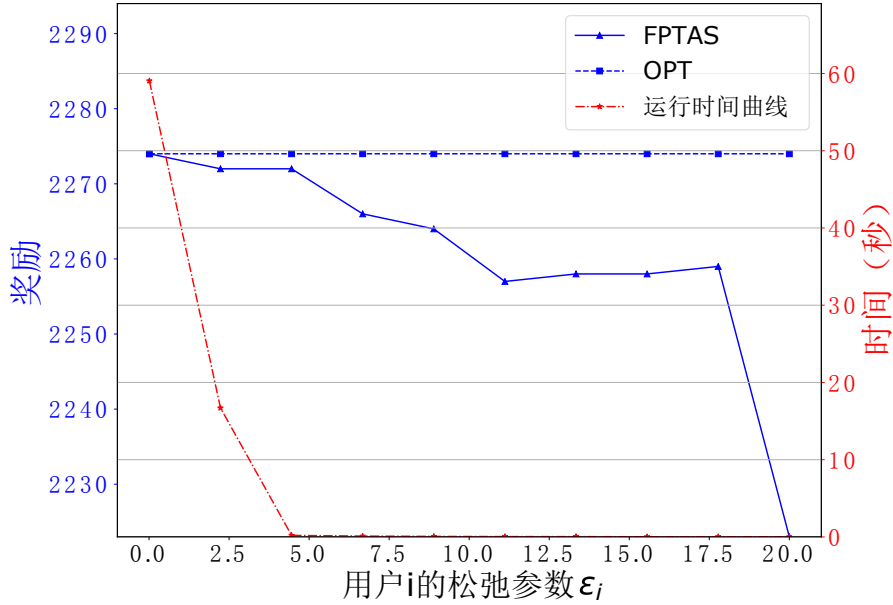


图 4.4 阶段二所提出 FPTAS 的性能

#### 4.4.3 阶段一的实验评估

在这一小结，我们单独验证算法5的性能。我们设置一些相关参数默认值为  $M = 100$ 、 $B = 10000$  和  $d_j^t \sim U(1000, 10000)$ 。实验结果如图4.5，4.6和4.7所示。

图4.5比较了算法5在  $\nu = 10$  和  $\nu = 50$  两种场景下所达到的时间平均效益目标函数，时间平均效益目标函数对应的这两个曲线首先随时间急速增加，然而缓慢趋于稳定的最优值。这是因为算法5一开始直接把首次到达的任务对于的支付费用赋值给奖励决策变量，意味着平台一开始不赚取任何利润，等趋于稳定值时，平台已在最大化群智感知的整体效益和最大化其利润这两个冲突的目标中达到了平衡。值得注意的是，算法5的时间平均效益目标函数曲线变化曲线在波动增长中达到收敛，造成这个现象的原因有三个：1) 算法5使用其收集到了梯度信息进行学习，求得最优解，最终收敛于稳定的最优值；2) 到达平台的任务是随机的，而且支付的费用也是随机变化的；3) 算法5在最大化群智感知的整体效益的同时，必须考虑平台的盈利性，即要维持预算队列  $\widetilde{\mathbf{Z}}(t)$  的稳定性。当平台使用大的控制参数  $\nu$  来做奖励定价决策时，时间




图 4.5 算法5在  $\nu = 10$  和  $\nu = 50$  两种场景下所达到的时间平均效益目标函数的性能比较




图 4.6 算法5在  $\nu = 10$  和  $\nu = 50$  时预算队列  $\mathbf{Z}(t)$  总长度的性能比较




图 4.7 在  $\nu = 10$  和  $\nu = 50$  下所有任务的奖励定价决策曲线和请求者给平台的支付费用曲线

平均效益目标函数会先快速地收敛。但是大控制参数  $\nu$  的场景造成更大的预算队列总



长度，相比于小控制参数  $\nu$  的场景，对比的结果可参见图4.6。这些结果显示了平台在两个冲突的目标函数：最大化群智感知的整体效益和最大化其获得利润，之间进行折中，这个现象符合定理4.2中的结论。图4.7显示了平台给所有任务所定的奖励，在时间平均上都低于请求者为任务所支付的费用，但是大控制参数  $\nu$  的场景下所定的奖励比小控制参数  $\nu$  的场景所定的奖励要大，这是因为大控制参数  $\nu$  的场景下平台优先最大化群智感知的整体效益。图4.7的结果也证明了我们提出的算法算法5让平台在做奖励定价决策来激励用户参与群智感知系统来最大化系统整体效益的同时，还能保证平台在这个过程中保证了平台的长期盈利性。




图 4.8 算法3分别在  $V = 20, 100, 1000$  以及算法5分别在  $\nu = 10, 20, 210$ ，激励机制所对任务所定的奖励性能比较，总时槽为 1000




图 4.9 算法3在  $V = 20, 100, 1000$ ，各自所使用的虚拟队列总长度，对应着公平性约束的保障程度，总时槽为 1000

#### 4.4.4 基于轨迹数据集上部署激励机制的实验评估

在这一小节，我们在一个合成数据集上评估整个激励机制，考虑 1000 个时槽的结果。相关参数的设置如下： $M = 1000$ ,  $|\mathcal{M}_t| = 50$ ,  $p_j^t \sim U(0, 1000)$ ,  $\forall j \in \mathcal{M}_t$ ,  $N = 100$ ,  $|\mathcal{N}_t| \geq 50$ ,  $D_i \sim U(0.2, 0.45)$  和  $\varepsilon_i \sim U(0, 20)$ ,  $\forall i \in \mathcal{N}$ 。实验结果如图4.8, 4.9和4.10所示。

在每个时槽，我们使用算法5为所到达的任务做奖励定价决策，并把决策结果通知给当前活跃用户。之后，每个用户使用算法4来计算他们各自的兴趣集，并将这个兴趣集信息汇报给平台。最后平台根据所得到的兴趣集信息，使用算法3来挑选用户去覆盖任务，让挑选的用户来执行当前任务。在算法3中，我们考虑三种控制参数为  $V = 20, 100, 1000$  的场景；在算法5中，我们考虑三种控制参数为  $\nu = 10, 20, 210$  的场景。激励机制的总体性能展示在图4.8, 4.9和4.10。其中，图4.8显示了平台所定的



奖励随着控制参数  $\nu$  的增加而增加，随着控制参数  $V$  的增大而减小，这是因为根据前面的理论分析，算法5倾向于设置更大的奖励在  $\nu$  值很大的场景下，但是算法3更倾向于选择需要较小的奖励代价的用户在  $V$  很大的场景下。然而，图4.9的结果显示了算法3中所使用的虚拟队列总长度随着  $V$  的增大而增大，图4.10的结果显示了算法5中所使用的预算队列总长度随着  $\nu$  的增大而减小。




图 4.10 算法5在  $\nu = 10, 20, 210$ , 各自所使用的预算队列总长度，对应着平台可以盈利的程度，总时槽为 1000

## 4.5 本章小结

在本章，我们设计了一个激励机制适用于时变群智感知场景。该激励机制由三阶段斯坦克伯格博弈来建模。而且，我们使用了李雅普诺夫优化技术来处理用户的长期公平参与问题和保证平台的时间平均盈利问题。提出的第一阶段在线任务定价算法达到了平台收益和感知系统效益（任务被更多用户的执行）的性能折中  $[\mathcal{O}(1/\nu), \mathcal{O}(\nu)]$ 。提出的第三阶段在线用户选择算法达到了用户公平性保障和平台征募奖励最小化的性能折中  $[\mathcal{O}(1/V), \mathcal{O}(V)]$ 。此外，我们还设计了一个完全多项式时间近似算法 FPTAS 来给用户基于他们各自手持设备的计算能力计算一组  $(1 - \varepsilon)$ -近优任务集作为兴趣集。



## 第 5 章 面向多平台共存的激励机制

随着群智感知的发展,由于大规模感知数据的重要价值,出现多个感知平台的场景是很有可能,因此,现有的激励机制工作很难扩展到这种多平台场景。在本章,我们从两方面来研究面向多平台共存的激励机制设计问题,我们把多平台共存的场景划分为平台间竞争场景和平台间合作场景,并提出相应的激励机制。当平台之间只有竞争关系时候,我们把激励机制建模为两阶段的多主导者-多跟随者斯坦克伯格博弈。在该场景下,每个平台可以根据计算出的最优奖励进行任务定价,每个用户可以选择最好的平台去执行感知任务。平台之间由竞争征募用户产生的冲突关系可以通过合作达到共赢局面。事实上,平台可以通过合作来共享感知数据,使得感知数据得到二次利用。在这种合作中,贡献数据的平台如果不得到一定的奖励,则不会参与合作,因此需要一个合适的激励机制来解决这个问题。我们使用合作博弈中的纳什议价模型来建模多平台合作场景的激励机制,通过分析一对多纳什议价模型的 NP 难解性和指数阶高时间复杂度,进而提出启发式讨价还价解决方案,保证性能的同时达到可扩展性目标。最后,我们在合成数据集和 D4D 数据集上进行仿真实验,实验结果显示了: 1) 在竞争激励机制中平台能通过最优定价来保证它们的收益同时用户能选择到最好的平台; 2) 在合作激励机制中平台可以通过讨价还价模型来决定是否合作共享所获得的感知数据,从而提高各自的收益。

### 5.1 引言

随着移动设备的快速发展与普及,催生了一种基于携带手持设备的移动用户的新型感知模式-群智感知<sup>[5,131-133]</sup>,并在最近几年引起了业界对其的极大关注。由于现代的移动设备都配置了大量丰富多样且感知能力较强的传感器且已在各种感知区域都有大规模移动用户,群智感知旨在利用移动用户的手持设备来参与执行感知任务,并从中收集感知数据。群智感知的强大威力催生了大量使用的应用案例,如:实时交通信息监测的 Waze<sup>[115]</sup>,移动市场调研的 Gigwalk<sup>[116]</sup>,空气质量监测的 U-Air<sup>[117]</sup>和公共信息共享的 FlierMeet<sup>[119]</sup>。

由于执行感知任务需要用户付出一些工作量,从而造成一定量的资源消耗和开销,比如计算资源、存储资源和通信资源,甚至执行感知任务需要分享实时位置从而

暴露隐私。因此,如果用户得不到一定量的奖励来补偿感知代价,那么他们不愿意参与执行感知任务。因此,设计一个合适的激励机制是群智感知的主要研究问题之一<sup>[62]</sup>。已有许多现有研究工作<sup>[26,71,72,82,84,134]</sup>致力于探索和设计合适高效的激励机制来奖励用户,进一步吸引更多用户参与到群智感知中。然而,这些研究工作大部分都假设群智感知系统中只有一个平台,作为中心控制器来协同请求者和移动用户之间的感知数据供应和感知服务请求。但是,随着群智感知的快速发展,其所收集的大规模感知数据将会带来巨大的价值,这吸引了很多个感知平台的成立。从另一方面讲,来自移动用户的感知数据,其模态越来越多样化,而请求者所请求的服务需求越来越异构化,这将使得单一感知平台难以处理请求者和移动用户之间的协同问题,造成中心化感知平台的过度负载。因此,群智感知系统的多平台化将是不可避免的发展趋势。然而,多平台化的趋势使得群智感知系统各方之间的策略交互变得极其复杂,设计一个有效合理的激励机制来处理这些策略交互所带来的挑战是多平台化群智感知亟需解决的问题。

与前面章节(第3章和第4章)考虑的单一平台群智感知不同。在本章,我们将设计面向多平台场景下群智感知的激励机制设计问题。在这种场景中,存在多个感知平台征募用户来执行不同感知任务。我们依据平台间的竞争合作关系把所要研究的场景划分为平台间竞争场景和平台间合作场景。在平台间竞争场景中,我们考虑了用户与平台之间的策略交互,并考虑不同平台之间的策略对其他用户的影响。其主要解决的关键问题是每个平台如何做奖励定价决策问题来吸引用户参与执行相应的感知任务,以及每个用户选择好的平台去参与执行感知任务以获得更高的奖励。在平台间合作场景中,我们考虑了各个平台间关于如何合作的策略交互,即如何确定合作来共享所收集到的感知数据以进行数据的二次利用。其主要解决的关键问题是每个平台间如何确定合作的基础,即以多少价钱进行合作和交换多少数据量。

所提出的激励机制首先关注于平台与用户之间的策略交互。每个平台和每个用户都单独决策来最大化其效益值。对于平台来说,考虑预算和其他平台的影响,每个平台都单独选择合适的奖励值来吸引更多用户来执行任务。对于用户来说,每个用户可以选择得到最高收益的平台,并参与其感知任务,依据贡献的感知工作量来获得收益。然而,平台之间的竞争关系使得各方策略交互变得极其复杂,为了解决这种复杂的策略交互,我们使用多主导者-多跟随者的斯坦克伯格博弈来建模激励机制设计问题。通过求解博弈的斯坦克伯格均衡点,各个平台和用户都可以根据均衡策略来进行决策。

显然，平台间的竞争会影响其征募到用户的数量，进而影响平台从群智感知中所得到的收益。这种竞争关系对于激励机制来说，是一种负的外部性<sup>[40]</sup>，平台数目越多则影响越大。为了解决这种负的外部性，我们设计了基于合作的激励机制来促使平台之间共享所收集到的感知数据以进行数据的二次利用。这个激励机制关注于平台征募用户完成任务后的策略交互，它允许平台之间相互合作来共享从移动用户收集到的感知数据。然而，如果共享感知数据而得不到收益，那么贡献数据的平台则不愿意参与合作。因此，我们需要设计合作场景下的激励机制来解决平台之间的策略交互问题。在合作场景中，一个平台可以从另外一个平台那边购买感知数据，而不是直接征募用户来执行感知任务以获得感知数据。为了最大化效益，每个平台需要在选择哪个平台来进行合作和以多少价钱进行合作上进行最优决策。在本章，我们使用纳什议价理论来解决合作场景下的激励机制设计问题。我们将一对一的纳什议价模型扩展到一对多纳什议价模型，每个平台都运行一对多纳什议价模型来得到关于与哪个平台合作和以多少价钱合作这两个子问题的解（即纳什议价解），进而得到多对多纳什议价模型。

对于本章所设计的激励机制，其主要贡献点的总结如下：

- 面向多平台的新型激励机制。不同于以往面向单平台激励机制的研究工作，我们提出了一个面向多平台群智感知的激励机制。所提出的激励机制即能解决平台与用户之间的策略交互，也可以处理平台之间的合作交互。
- 基于竞争合作激励机制的建模分析。我们对多平台场景下激励机制设计问题进行建模，使用多主导者-多跟随者的斯坦克伯格博弈来建模平台间竞争场景的激励机制设计问题，同时使用纳什议价模型来建模平台间合作场景的激励机制设计问题。
- 针对所提激励机制的仿真实验评估。我们针对多平台对激励机制设计的影响和所提出激励机制性能，在合成数据集和 D4D 数据集上进行实验仿真。实验结果显示了所提出激励机制的高效性。

本章的后续内容将如下组织编排：在5.2节，我们首先概述本章关注群智感知系统的模型，介绍平台和群智工人的模型参数，并定义相应的效益函数。描述竞争场景激励机制设计问题和合作场景激励机制设计问题。在5.3节，我们探索竞争场景下的激励机制设计问题，我们使用两阶段斯坦克伯格博弈来形式化用户和平台的策略交互问题。通过推导斯坦克伯格博弈均衡点来表征用户的工作量确定策略和多个平台竞争奖

表 5.1 第5章多平台激励机制设计中的主要数学符号表

符号	含义
$i, I, \mathcal{I}$	用户索引, 用户数目和用户集
$j, K, \mathcal{K}$	平台索引, 平台数目和平台集
$B_i^U$	用户 $i$ 的工作量上限
$x_{j \leftarrow i}$	用户 $i$ 执行平台 $j$ 的任务所做的工作量值的大小
$c_{j \leftarrow i}$	用户 $i$ 关于平台 $j$ 的感知代价
$r_j$	平台 $j$ 所做的单位奖励定价决策
$B_j^P$	平台 $j$ 的奖励预算
$\Psi_i^u$	用户 $i$ 的效益函数值
$I^j$	平台 $j$ 所征募到的用户集
$\Phi_j$	平台 $j$ 的服务质量值
$\Psi_j^{P-}$	平台 $j$ 在竞争场景下的效益函数值
$\mathcal{B}^j$	和平台 $j$ 进行议价合作的平台集, 其大小为 $N^j$
$b_k^j$	指示平台 $j$ 和平台 $k$ 是否达成议价合作的布尔变量
$p_{k \leftarrow j}$	达成议价合作时平台 $j$ 向平台 $k$ 所支付其共享感知数据的费用
$X_{j \leftarrow k}$	达成议价合作时平台 $k$ 向平台 $j$ 所共享的数据量大小
$E_k$	在议价合作中平台 $k$ 所承受的操作和通信代价
$\Psi_j^{P+}$	平台 $j$ 在合作场景下的效益函数值
$V_k^j$	在和平台 $j$ 议价中平台 $k$ 的效益函数值

励的定价策略。在5.4节, 我们探索合作场景下多平台关于共享感知数据的合作激励机制设计问题, 我们使用纳什议价模型来形式化多平台合作的策略交互问题, 通过推导纳什议价解来标准所有平台的合作议价策略。在5.5节, 我们通过数值仿真实验来评估用户策略、平台的竞争策略和合作策略的性能。最后, 我们在5.6节总结了本章的激励机制研究工作。

## 5.2 系统模型定义和问题描述

我们考虑群智感知系统的运行总时长是  $T_d$ , 我们假设群智感知系统是一个准静态的系统, 这样一些系统参数 (如感知代价、用户和平台的估值函数、用户数目、平台数目和平台的预算等等) 在所考虑的时长范围内稳定不变, 我们将本章所用到的关键数学符号罗列在表5.1。

### 5.2.1 系统概述

大体上, 群智感知系统由请求者、平台和用户组成。在本章, 我们考虑了不同于以往研究工作的多平台场景。在这个场景中, 每个平台可以为请求者的服务请求而发布感知任务并征募用户来执行感知任务。由于请求者一般提交服务请求到平台, 并购






图 5.1 多平台场景下的群智感知激励机制

买感知服务，其交互一般不牵涉策略决定，因此，我们在本章激励机制的设计研究只考虑平台与用户和平台之间的策略交互。具体来说，我们假设群智感知系统中有一组用户，记作  $\mathcal{I} = \{1, 2, \dots, I\}$ ，每个用户都可以执行一个或多个感知任务，我们以用户的工作量（如为感知任务贡献的计算资源、感知时间等等）来计算相应的奖励。此外，群智感知系统有多个平台在云服务器上协调请求者的服务请求和用户的数据收集，平台集记作  $\mathcal{K} = \{1, 2, \dots, K\} (K \geq 2)$ 。所有移动用户分布在各个任务的感知区域内，每个平台在任务的感知区域内招募用户来执行感知任务，并从中收集感知数据。我们假设每个用户在每个时槽内只能在一个平台工作。

当用户  $i$  被平台  $j$  招募时，它贡献的工作量记作  $x_{j \leftarrow i}$ ，之后收到平台  $j$  的奖励  $r_j$ 。由于手持设备电量有限，用户不可能无限地执行感知任务，因此工作量  $x_{j \leftarrow i}$  不能超过一个常量阈值  $B_i^U (\forall i \in \mathcal{I}, \forall j \in \mathcal{K})$ 。用户  $i$  执行来自平台  $j$  的任务时，存在感知代价，记作  $c_{j \leftarrow i}$ ，可以看出，用户执行来自不同平台的任务，其感知代价不一样，需要注意的是  $c_{j \leftarrow i}$  和  $B_i^U$  是用户的私人信息，平台不得而知，尽管如此，平台也可以通过历史交互信息预估出来并用于做奖励定价决策。我们将平台  $n$  招募到的用户集记作  $\mathbf{I}^n$ 。

多平台群智感知激励机制的整个过程如示意图5.1所示。首先，每个平台都向用户宣布感知任务以及对应的奖励策略。针对当然任务及其奖励策略，每个用户选择更好平台的任务来执行以获得更多奖励。当用户执行完任务并提交给任务的所属平台后，平台间进行相互议价来达成合作，并共享所收集到的感知数据，进而补偿到了前一阶段招募用户的竞争带来的损失。在本章，我们假设平台间所收集到的感知数据可以聚



合到各自的任务，即平台间的任务具有相似性，因而可以通过共享感知数据达到完成任务的目标。

### 5.2.2 用户模型

群智感知可以让移动用户执行感知任务并生成感知数据，从而获得收益，因此，大规模移动用户就变成了群智感知，为了叙述方便，本章出现的用户、参与者和工作含义相同。在多平台的场景下，用户  $i$  选择一个平台来执行其感知任务，并获得该平台所提供的单位奖励  $r_j$ 。由于用户具有个体理性特征，每个用户一般都选择提供奖励最多的平台来贡献其感知数据。然而，对于任一的用户和平台 ( $\forall i \in \mathcal{I}, \forall j \in \mathcal{K}$ )，每个用户  $i$  执行平台  $j$  的感知任务需要承受一个感知代价  $c_{j \leftarrow i}$ 。因此，选择提供奖励最多的平台对所有用户来说并不一定是最有选择，因此该平台可能需要使某些用户承受更多感知代价。所以，对于用户来说，其要解决的问题是如何现在一个合适的平台来贡献其感知数据以最大化其效益值。当用户  $i$  为平台  $j$  贡献的工作量为  $x_{j \leftarrow i}$  时，该用户的效益值为：

$$\Psi_i^u(r_j, x_{j \leftarrow i}) = R_i^U(x_{j \leftarrow i}) - C(x_{j \leftarrow i}) = r_j x_{j \leftarrow i} - c_{j \leftarrow i} x_{j \leftarrow i}^2. \quad (5.1)$$

第一项是用户为任务  $j$  执行工作量  $x_{j \leftarrow i}$  时的总奖励  $R_i^U(x_{j \leftarrow i})$ 。当平台提供单位奖励  $r_j$  时，如果用户  $i$  为平台  $j$  贡献  $x_{j \leftarrow i}$  工作量，则用户的所获得的总奖励是  $R_i^U(x_{j \leftarrow i}) = r_j x_{j \leftarrow i}$ 。第二项是用户为任务  $j$  执行工作量  $x_{j \leftarrow i}$  时的总代价  $C(x_{j \leftarrow i})$ 。当用户  $i$  为平台  $j$  贡献  $x_{j \leftarrow i}$  工作量，同时承受一些感知代价，如电量损失、计算和感知资源的消耗。感知代价与工作量  $x_{j \leftarrow i}$  相关。在本章，我们假设感知代价是凸的形式，以此来捕捉的边际效益递减特征：感知代价随工作量  $x_{j \leftarrow i}$  单调增加，但是其边际感知代价随着工作量  $x_{j \leftarrow i}$  单调递减。即关于工作量  $x_{j \leftarrow i}$  的总感知代价为  $C(x_{j \leftarrow i}) = c_{j \leftarrow i} x_{j \leftarrow i}^2$  <sup>[65]</sup>。

### 5.2.3 平台模型

与以往单平台群智感知研究工作相比，本章的激励机制设计研究工作集中于设计面向多平台群智感知激励机制的设计问题。在一定时长范围内，用户数目是固定的，每个平台都尽可能多地征募足够多的用户来参与执行各自的感知任务。由此造成了平台之间的竞争关系。这种平台间通过做奖励定价决策去相互竞争以征募更多的用户，

从而达到其效益最大化。然而，这种竞争关系属于负外部性<sup>[40]</sup>，降低其他平台的效益最大化，且平台数目越多，影响越大。为了克服这种负外部性，平台之间可以合作共享所收集到的感知数据，通过制定合作策略，进而提升平台之间的效益。

### A. 竞争场景下的平台建模

在平台间竞争的场景中，每个平台  $j$  都单独做奖励定价决策  $r_j$  来吸引更多用户执行其感知任务，从而最大化其效益。令  $-j$  表示除了平台  $j$  以外的所有平台， $r_{-j}$  表示除了除了平台  $j$  以外所有平台的奖励定价决策所组成的向量。

每个平台进行奖励定价决策  $r_j$ ，都需要考虑自己的预算，记作  $B_j^P$ 。当通过奖励定价决策  $r_j$  来征募用户时，其征募到的用户集记作  $\mathbf{I}^n$ 。平台收获到的工作量为  $\sum_{i \in \mathbf{I}^j} x_{j \leftarrow i}$  时的效益值为：

$$\Psi_j^{P-}(r_j, \mathbf{x}^j) = \Phi_j(\mathbf{x}^j) - R_j^{P-}(\mathbf{x}^j) = \lambda_j \sum_{i \in \mathbf{I}^j} x_{j \leftarrow i} - \sum_{i \in \mathbf{I}^j} r_j x_{j \leftarrow i}, \quad (5.2)$$

第一项表示平台融合来自用户  $\mathbf{I}^j$  提交的感知数据价值。我们使用公式  $\Phi_j(\mathbf{x}^j) \triangleq \lambda_j \sum_{i \in \mathbf{I}^j} x_{j \leftarrow i}$  表征感知数据价值，其中  $\sum_{i \in \mathbf{I}^j} x_{j \leftarrow i}$  表示平台  $j$  征募到的用户其总工作量，总工作量越大，平台越能融合更多感知数据，提供的感知服务质量就越高，从而增大数据的价值。请求者向平台  $j$  请求服务时需要支付这个数据的价值  $\Phi_j(\mathbf{x}^j)$ 。 $\lambda_j$  是数据价值系数，表示平台  $j$  将感知数据转化为感知服务价值能力值<sup>[26,84]</sup>，由平台  $j$  和请求者达成共识来确定。第二项表示平台为用户集  $\mathbf{I}^j$  支付的总奖励：如果用户  $i$  被平台  $j$  征募，其为感知任务做工作量  $x_{j \leftarrow i} > 0$ ，可以获得奖励为  $r_j x_{j \leftarrow i}$ 。对于所有被平台  $j$  征募到的用户，平台总共支付的奖励是  $R_j^{P-}(\mathbf{x}^j) = \sum_{i \in \mathbf{I}^j} r_j x_{j \leftarrow i}$ 。

我们使用上标符号  $P_-$  表示竞争场景下平台的效益，合作场景下我们使用符号  $P_+$  来代替。

### B. 合作场景下的平台建模

由于上述所提到的负外部性导致多平台的竞争会损害相互间的效益，为了克服负外部性，平台间可以通过合作来共享所收集到的感知数据，以达到数据的二次利用。从另外一方面来看，平台也有动机去相互合作以使得所收集到的数据得到充分利用，进而从中获益，这是因为一个平台可以共享其收集到的感知数据给有需要的平台，并从中收取一定量的费用而得到盈利。这时，每个平台都具有合作的策略交互问题，即如何合作这个问题隐藏着两个子策略问题：与哪个平台合作和以多少价钱进行合作共

享数据。我们借助于合作博弈中的纳什议价模型来建模合作场景下的激励机制设计问题。

在合作场景下，每个平台  $j$  和其他平台  $k \in \mathcal{K}(j \neq k)$  就是否合作共享所收集的感知数据进行协商议价，以达到效益最大化。如果平台  $k$  同意共享感知数据给平台  $j$ ，平台  $j$  需向平台  $k$  支付一定费用以补偿其因共享所收集的感知数据而造成的效益损失。为了导出最优的策略交互，我们使用一对多纳什议价模型来建模平台间的合作交互问题。由于所有平台需要共享其收集到的数据，我们需要为每个平台实施一对多纳什议价，来确定整体议价结果。

为了分析合作场景下平台议价的结果，我们首先定义平台合作场景下的效益函数。令  $\mathcal{B}^j$  表示和平台  $j$  进行议价的平台集，其大小为  $N^j$ 。对于任一平台  $k \in \mathcal{B}^j$ ，令布尔变量  $b_k^j$  表示平台  $k$  是否与平台  $j$  合作并向其共享感知数据（取值 1 表示合作，否则不合作），令变量  $p_{k \leftarrow j}$  表示平台  $j$  向平台  $k$  所支付的费用如果  $b_k^j = 1$ 。当平台  $k$  不与平台  $j$  合作时（即  $b_k^j = 0$ ），费用  $p_{k \leftarrow j} = 0$ 。因此，元组  $(b_k^j, p_{k \leftarrow j})$  表示平台  $j$  和平台  $k$  的议价结果。此外，如果平台  $k$  与平台  $j$  合作（即  $b_k^j = 1$ ），平台  $k$  共享感知数据量为  $X_{j \leftarrow k}$ ，同时承受合作代价  $E_k$ （如操作代价和传输代价）。为了分析平台  $j$  与多个平台的合作议价结果，我们将布尔变量  $b_k^j$  和所支付的合作费用  $p_{k \leftarrow j}$  扩展到关于平台集  $\mathcal{B}^j$  的向量形式  $\mathbf{b}_{\mathcal{B}^j} \triangleq (b_1^j, b_2^j, \dots, b_{N^j}^j)$  和  $\mathbf{p}_{\mathcal{B}^j} \triangleq (p_{1 \leftarrow j}, p_{2 \leftarrow j}, \dots, p_{N^j \leftarrow j})$ 。显然，对平台  $j$  来说，由其他平台共享而获得的感知数据  $\sum_{k \in \mathcal{B}^j} b_k^j X_{j \leftarrow k}$  会增加其效益，而所支付的费用  $\sum_{k \in \mathcal{B}^j} p_{k \leftarrow j}$  会减少其效益，因此，其效益函数可以定义如下：

$$\Psi_j^{P+}(\mathbf{b}_{\mathcal{B}^j}, \mathbf{p}_{\mathcal{B}^j}) = f\left(\sum_{k \in \mathcal{B}^j} b_k^j X_{j \leftarrow k}\right) - \sum_{k \in \mathcal{B}^j} p_{k \leftarrow j}. \quad (5.3)$$

其中，我们选择严格单调递增且非负的上凸函数  $f(\cdot)$  来表征从合作共享得到的全部感知数据  $\sum_{k \in \mathcal{B}^j} b_k^j X_{j \leftarrow k}$  对平台  $j$  产生的服务价值，这个上凸函数满足随自变量单调增加但其增量会单调减少，即满足  $f'(z) > 0$ , and  $f''(z) < 0$ ，且  $f(0) = 0$ 。

而对于其他共享感知数据的平台  $k \in \mathcal{B}^j$  来说，其合作的效益值为：

$$V_k^j(b_k^j, p_{k \leftarrow j}) = p_{k \leftarrow j} - b_k^j E_k X_{j \leftarrow k}. \quad (5.4)$$

第一项为平台  $j$  向平台  $k$  支付的奖励  $p_{k \leftarrow j}$ ，第二项为平台  $k$  共享感知数据而承受的

的总代价  $E_k X_{j \leftarrow k}$ ，比如当  $E_k$  为单位通信费用，则平台  $k$  传输感知数据量  $X_{j \leftarrow k}$  给平台  $j$  需要支付的总通信费用为  $E_k X_{j \leftarrow k}$ 。

#### 5.2.4 问题描述

在本章，我们将解决竞争场景和合作场景下的群智感知激励机制设计问题，其问题的正式定义如下：

**定义 5.1 (CompPricing).** 给定用户集  $\mathcal{I}$ ，竞争场景下激励机制设计问题 **CompPricing** 是关于解决每个平台如何为其感知任务做奖励定价决策  $r_j$  去征募尽可能多的用户来执行相应感知任务，同时，每个用户如何选择好的平台去执行其感知任务以获得奖励。

**定义 5.2 (CoopPricing).** 给定议价平台集  $\mathcal{B}^j$ ，合作场景下激励机制设计问题 **CoopPricing** 是关于解决平台  $j$  如何确定与平台  $k \in \mathcal{B}^j$  合作以获得对方的感知数据，以及用多少价钱  $p_{k \leftarrow j}$  达成合作。

我们将在以下分析章节中形式化地定义问题 **CompPricing** 和问题 **CoopPricing** 为效益最大化问题，进而使用相应的最优化技巧求解出各方的最优策略。

### 5.3 平台间竞争场景的激励机制

在这一节，我们使用多主导者-多跟随者的斯坦克伯格博弈来建模平台间竞争场景的激励机制设计问题，我们通过后向推断法来分析相应博弈的斯坦克伯格均衡来表征每个平台和用户在均衡点下的最优策略。

#### 5.3.1 阶段二：用户选择平台和确定最优工作量策略

在群智感知的激励机制中，用户作为斯坦克伯格博弈的跟随者角色，在阶段二进行最优策略决策，来响应平台所宣布的奖励信息。在这一小节，我们首先分析用户关于某一平台确定最优工作量的策略，然后分析用户选择最优平台的策略来最大化其效益。

##### A. 用户最优工作量的确定策略

假设用户  $i$  被征募到平台  $j$  去参与执行感知任务，当平台  $j$  向用户宣称提供奖励  $r_j$ ，用户需要确定最优工作量  $x_{j \leftarrow i}^*$  去最大化其效益值（如式5.1所示），同时需要考虑

工作量上限  $B_i^U$  的约束，因此，可以把问题 **CompPricing** 关于用户效益最大化策略形式化为：

$$(UOPT) \quad \begin{aligned} \max \quad & \Psi_i^u(r_j, x_{j \leftarrow i}) = r_j x_{j \leftarrow i} - c_{j \leftarrow i} x_{j \leftarrow i}^2 \\ \text{s.t.} \quad & \begin{cases} x_{j \leftarrow i} \leq B_i^U, \\ x_{j \leftarrow i} \geq 0, \\ (\forall j \in \mathcal{K}), \end{cases} \end{aligned}$$

其中，决策变量是工作量  $x_{j \leftarrow i}$ 。每个用户都需求解问题 UOPT 来确定其最优工作量去执行感知任务。由于我们假设了用户执行任务的感知代价为凸的，因此，问题 UOPT 是关于工作量  $x_{j \leftarrow i}$  的凸优化问题，这种形式化有助于我们分析用户的最优策略。在凸优化问题中，其最优解由 Karush-Kuhn-Tucker 条件（简称为 KKT）来表征，即 KKT 条件是最优解的充分必要条件<sup>[123]</sup>。从另外一方面讲，求解 KKT 条件可以得到凸优化问题的闭式解，这也是我们将问题 UOPT 形式化为凸优化问题，以便于分析用户策略以及激励机制设计方案。而且形式化为凸优化问题，得到的解为其非凸形式解的上界<sup>[42]</sup>。通过分析问题 UOPT，我们可以得到其 KKT 条件如下：

$$\begin{cases} r_j - 2c_{j \leftarrow i} x_{j \leftarrow i} + \mu_1^i - \mu_2^i = 0, \forall j \in \mathcal{K}, \\ \mu_1^i (x_{j \leftarrow i} - B_i^U) = 0, \forall j \in \mathcal{K}, \\ -\mu_2^i x_{j \leftarrow i} = 0, \forall j \in \mathcal{K}, \\ \mu_1^i \geq 0, \\ \mu_2^i \geq 0, \end{cases} \quad (5.5)$$

其中， $\mu_1^i$  和  $\mu_2^i$  是关于问题 UOPT 两个约束的 KKT 乘子。通过求解式 5.5 中的 KKT 条件所组成的方程，我们可以求出最优工作量  $x_{j \leftarrow i}^*$ ，我们将用户确定最优工作量的策略总结在以下引理中：

**引理 5.1** (最优工作量确定策略). 当平台  $j$  向用户宣称提供奖励  $r_j$ ，用户  $i$  确定最优工作量  $x_{j \leftarrow i}^*$  的策略是：

$$x_{j \leftarrow i}^* = \min\{B_i^U, \frac{r_j}{2c_{j \leftarrow i}}\} \quad (5.6)$$

## B. 用户关于最好平台的选择策略

假如  $K$  个平台同时宣布其单位奖励信息  $\mathbf{r} = (r_1, r_2, \dots, r_K)$  给所有用户，每个用

户  $i$  的最优策略是选择在一个好的平台  $j_i^*$  以最优工作量  $x_{j_i^* \leftarrow i}^*$  去执行感知任务来最大化其效益。而确定最优工作量  $x_{j_i^* \leftarrow i}^*$  由引理5.1给出，我们接下来分析用户选择最优平台以最大化效益的策略。不失一般性，我们以用户  $i$  作说明。大体上，如果一个平台提供更多奖励且关于用户的感知代价较小时，用户的最优选择策略就是选择该平台。当用户  $i$  面对所有平台的奖励信息  $\mathbf{r} = (r_1, r_2, \dots, r_K)$ ，它可以单独将每个平台  $j$  的奖励  $r_j$  带入问题 UOPT，得到关于  $r_j$  的目标效益值和相应的最优工作量策略  $x_{j \leftarrow i}^*$ 。用户求解所有  $\mathbf{r} = (r_1, r_2, \dots, r_K)$  关于问题 UOPT 的解，即可确定用户关于最好平台的选择策略。我们总结最好平台选择策略如下引理所示：

**引理 5.2 (最好平台选择策略).** 用户  $i$  将选择平台  $j^*$  并以工作量  $x_{j^* \leftarrow i}^*$  去执行其感知任务，其中  $x_{j^* \leftarrow i}^*$  由引理5.1给出， $j^*$  由下式5.7给出：

$$j^* = \arg \max_{j \in \mathcal{K}} x_{j \leftarrow i}^* \quad (5.7)$$

---

**Algorithm 6** 用户最优决策策略的算法

---

**Input:** 平台集  $\mathcal{K}$ , 所有平台奖励信息  $\mathbf{r} = (r_1, r_2, \dots, r_K)$ , 关于所有平台的感知代价  $\{c_{j \leftarrow i}\}_{j \in \mathcal{K}}$  和用户  $i$  的工作量上限  $B_i^U$

**Output:** 最好平台  $j_i^*$  和最优工作量  $x_{j_i^* \leftarrow i}^*$

- 1: 定义临时变量  $tempI = -1$  用于确定最好平台
  - 2: 定义临时变量  $tempX = 0$  用于确定最优工作量
  - 3: **for**  $j \in \mathcal{K}$  **do**
  - 4:   **if**  $\frac{r_j}{2c_{j \leftarrow i}} \geq B_i^U$  **then**
  - 5:     **continue**
  - 6:   **else if**  $tempX < \frac{r_j}{2c_{j \leftarrow i}}$  **then**
  - 7:     令  $tempX \leftarrow \frac{r_j}{2c_{j \leftarrow i}}$ , 令  $tempI \leftarrow j$
  - 8:   **end if**
  - 9: **end for**
  - 10: 令  $j_i^* \leftarrow tempI$ , 令  $x_{j_i^* \leftarrow i}^* \leftarrow tempX$
  - 11: **return**  $j_i^*$  和  $x_{j_i^* \leftarrow i}^*$
- 

引理5.1和引理5.2给出了竞争场景下用户关于给定所有平台奖励信息  $\mathbf{r} = (r_1, r_2, \dots, r_K)$  的最优决策策略：最优工作量的确定和最好平台的选择，从而最大化其效益。我们将用户的最优决策策略用算法6计算，其伪代码如下所示。算法6以平台集  $\mathcal{K}$ ，所有平台奖励信息  $\mathbf{r} = (r_1, r_2, \dots, r_K)$ ，关于所有平台的感知代价  $\{c_{j \leftarrow i}\}_{j \in \mathcal{K}}$  和用户  $i$  的工作量上限  $B_i^U$  作为输入，输出关于用户  $i$  的最好平台  $j_i^*$  和最优工作量  $x_{j_i^* \leftarrow i}^*$ 。在第1–2行定义两个临时变量  $tempI = 0$  和  $tempX = 0$ ，分别用于确定最好平台和最优



工作量。在第 4–5 行，我们检查用户  $i$  关于平台  $j$  的最优工作量（由引理 5.1 给出）是否大于工作量上限  $B_i^U$ ，如果是则跳过该平台去考察下一个平台，否则进入第 6–9 行进一步考察，并用  $tempX$  记录关于当前考察平台的最优工作量，用  $tempI$  记录当前平台索引。最后，在第 11–13 行， $tempI$  和  $tempX$  以保存全局最优解，并返回。如果  $tempI$  和  $tempX$  在最后值没发生变化（分别为初值  $-1$  和  $0$ ），表示没有一个适合的平台使得用户可以通过执行任务来最大化其效益。算法 6 只有一个“for”循环，执行  $|\mathcal{K}|$  次，所以算法 6 的时间复杂度为  $\mathcal{O}(|\mathcal{K}|)$ 。值得注意的是，每个用户分布式地使用算法 6 来计算其最优决策策略，算法可以在多项式时间内导出最优策略，所以用户可以对平台宣布的奖励信息做出实时响应，向相应的最优平台汇报其决策结果并执行其感知任务。

### 5.3.2 阶段一：平台奖励定价策略

在群智感知的激励机制中，平台作为斯坦克伯格博弈的主导者角色，针对阶段二用户的预期决策，在阶段一进行最优策略决策。正如问题 **CompPricing** 所述，在竞争场景下每个平台  $j$  需要单独做奖励定价决策  $r_j$  去吸引用户来参与执行其感知任务，从而最大化其效益（如式 5.2 所定义的效益函数）。基于前述定义的数学符号和效益函数，我们可以将平台效益最大化问题形式化为：

$$\begin{aligned}
 & \max \Psi_j^P(r_j, \mathbf{x}^j) = \lambda_j \sum_{i \in \mathbf{I}^j} x_{j \leftarrow i} - \sum_{i \in \mathbf{I}^j} r_j x_{j \leftarrow i} \\
 (CompOPT1) \quad & s.t. \quad \begin{cases} r_j \leq B_j^P, \\ r_j \geq 0, \end{cases}
 \end{aligned}$$

其中， $B_j^P$  是平台  $j$  的奖励预算， $\mathbf{x}^j$  是所有被平台  $j$  征募到的用户  $i$  ( $\forall i \in \mathbf{I}^j$ ) 所付出的工作量去执行平台  $j$  的任务， $r_j$  是平台  $j$  关于问题 CompOPT1 的决策变量。第一个约束确保单位奖励定价决策  $r_j$  不超过预算  $B_j^P$ 。

每个平台平台  $j$  通过求解问题 CompOPT1 得到最优奖励定价策略  $r_j^*$ 。然而，问题 CompOPT1 是线性规划，直接求解得出的最优解存在一些挑战。这是因为：1) 每个平台  $j$  是在阶段一求解问题 CompOPT1，用户工作量信息  $\mathbf{x}^j$  不是预先知道的；2) 即使假设  $\mathbf{x}^j$  是给定的，问题 CompOPT1 关于决策变量  $r_j$  不是凸的，求出的最优解不符合实际情况 ( $r_j^* = 0$ )。尽管用户  $i$  工作量信息  $x_{j \leftarrow i}$  ( $\forall i \in \mathbf{I}^j$ ) 在阶段一是未知



的，但由引理5.1可知，用户的最优工作量  $x_{j \leftarrow i}^*$  与平台的奖励定价决策  $r_j$  有关，即  $x_{j \leftarrow i}^* = \frac{r_j}{2c_{j \leftarrow i}}$ 。因此，我们可以使用最优工作量来作为用户工作量信息  $\mathbf{x}^j$  的预测，带入到问题 CompOPT1，则可以重新形式化为：

$$(CompOPT2) \quad \begin{aligned} \max \quad & \lambda_j \sum_{i \in I^j} \frac{r_j}{2c_{j \leftarrow i}} - \sum_{i \in I^j} \frac{r_j^2}{2c_{j \leftarrow i}} \\ \text{s.t.} \quad & \begin{cases} r_j \leq B_j^P, \\ r_j \geq 0. \end{cases} \end{aligned}$$

显然，问题 CompOPT2 是凸优化问题，尽管经过代入变化，用户的感知代价  $c_{j \leftarrow i}$  对平台  $j$  来说也是未知的，但是接下来使用 KKT 条件分析，我们将会发现平台的最优奖励定价策略与用户感知代价无关。关于问题 CompOPT2 的 KKT 条件如下：

$$\begin{cases} \frac{\lambda_j}{\sum_{i \in I^j} 2c_{j \leftarrow i}} - \frac{r_j}{\sum_{i \in I^j} c_{j \leftarrow i}} + \mu_1^j - \mu_2^j = 0, \\ \mu_1^j(r_j - B_j^P) = 0, \\ -\mu_2^j r_j = 0, \\ \mu_1^j \geq 0, \\ \mu_2^j \geq 0. \end{cases} \quad (5.8)$$

每个平台  $j$  通过求解式5.8中的 KKT 条件所组成的方程可以得出其最优奖励定价决策  $r_j^*$ ，我们将在以下引理总结平台的最优奖励定价策略：

**引理 5.3.** 在竞争场景下，每个平台  $j$  根据以下最优奖励定价策略来征募用户来执行感知任务：

$$r_j^* = \min\{B_j^P, \frac{\lambda_j}{2}\} \quad (5.9)$$

由引理5.3可知，竞争场景下平台的最优奖励定价策略与其奖励预算和服务价值系数  $\lambda_j$  有关。每个平台都单独通过引理5.3的策略来进行决策，而不管其他平台的策略，因此，达到了一个非合作均衡点。下一节，我们将分析平台间的合作策略来克服非合作决策的负外部性，并进一步提高平台间的效益。

## 5.4 平台间合作场景的激励机制

在这一节，我们来分析平台间合作场景的激励机制设计问题。正如问题 **CoopPricing** 一样，平台间合作场景的激励机制设计问题牵涉到如何解决一个平台选择哪个平台合作，并以多少价钱购买其共享的感知数据。我们首先考虑平台  $j$  和平台集  $\mathcal{B}^j$  的合作情况，并把它们关于问题 **CoopPricing** 建模为一对多纳什议价模型<sup>[135]</sup>，通过求解一对多纳什议价模型的纳什议价解，即平台间在纳什议价解达成合作，进而可以得到平台间的合作策略。需要值得注意的是，平台间的合作并不是指的平台间相互交换数据，而是平台从另外一个达成合作的平台中购买感知数据。而为了得到所有平台的合作策略，我们需要分析每个平台的一对多纳什议价模型，进而得到全部平台的合作策略，这可以视为多对多纳什议价模型。

当议价  $\mathcal{B}^j$  中的平台多于一时（即  $N^j > 1$ ），分析一对多纳什议价模型的首要问题是确定议价协议：顺序议价和同时议价<sup>[136]</sup>。在顺序议价中，平台  $j$  以某个确切的顺序与  $\mathcal{B}^j$  中的平台一个接着一个进行一对一议价来确定合作策略。而在同时议价中，平台  $j$  同时与  $\mathcal{B}^j$  中所有平台同时议价，进而得到合作策略。虽然同时议价可以快速得到合作策略，但是需要复杂的同步技术来进行协调。而顺序议价从算法设计的角度来看有着优良的结构特征，同时也能捕捉到最优值和最优解。顺序议价的分析可以扩展到同时议价中，因为同时议价在最坏情况下所达到整体平台的效益等价于的顺序议价的效果。我们关注于平台间合作策略的算法设计，因此考虑一对多纳什顺序议价模型。接下来，我们首先证明一对多纳什顺序议价模型的 NP 难解性，然而分析对应精准议价方式，达到最优的合作策略和平台间的整体效益最大化。最后我们提出启示式议价可以允许平台间在保证计算时间下一定程度上得到一个近优合作策略。

### 5.4.1 精准议价

假设平台  $j$  以给定顺序  $\mathbf{L}^j[1 : N^j] = (l_1^j, l_2^j, \dots, l_{N^j}^j)$  与所有平台  $k \in \mathcal{B}^j$  进行议价来确定合作策略。类似于斯坦克伯格博弈的分析方法，我们使用后向推断法来求解关于平台  $j$  和  $\mathcal{B}^j$  的一对多纳什议价模型的纳什议价解，即以顺序  $\mathbf{L}^j[1 : N^j]$  的倒序，从  $l_{N^j}^j$  到  $l_1^j$  逐一分析对应的一对一纳什议价模型。将在顺序  $\mathbf{L}^j[1 : N^j]$  的前  $s$  个议价结果记作  $(b_h^j, p_{h \leftarrow j})$  ( $\forall h \in \mathbf{L}^j[1 : s]$ )。由于在分析第  $s$  步议价结果时， $s+1$  之后的议价结果（即  $(b_g^{*j}, p_{g \leftarrow j}^{*j})$  ( $\forall g \in \mathbf{L}^j[s+1 : N^j]$ )）已经被推导完而事先已知，因此，我们可以使用一对一

纳什议价求解方法来计算第  $s$  步议价结果  $(b_{l_s^j}^j(\mathbf{b}_{l[1:s-1]}^j), p_{l_s^j \leftarrow j}^j(\mathbf{b}_{l[1:s-1]}^j))$ , 其中,  $\mathbf{b}_{l[1:s]}^j = (b_{l_1^j}^j, b_{l_2^j}^j, \dots, b_{l_s^j}^j)$ 。为了叙述简便, 我们定义新符号  $\mathbf{p}_{l[1:s] \leftarrow j} = (p_{1 \leftarrow j}, p_{2 \leftarrow j}, \dots, p_{s \leftarrow j})$  表示平台  $j$  与所有平台  $\mathcal{B}^j$  的议价价钱。

现在, 我们来推导在给定议价排序前面和后面的议价结果下平台  $j$  与平台  $s \in \mathcal{B}^j$  的议价结果  $(b_{l_s^j}^j(\mathbf{b}_{l[1:s-1]}^j), p_{l_s^j \leftarrow j}^j(\mathbf{b}_{l[1:s-1]}^j))$ 。其中, 每个第  $k$  ( $k > s$ ) 步议价结果  $b_{l_k^j}^{*j} \in \mathbf{b}_{l[s+1:N^j]}^{*j}(\mathbf{b}_{l_s^j}^j)$  都依赖前  $k-1$  步的信息。

当平台  $j$  与平台  $l_s^j \in \mathcal{B}^j$  达不成合作时, 根据式5.3和5.4, 它们的效益值分别为:

$$\begin{aligned} & \Psi_j^{P+} \left( \left( \mathbf{b}_{l[1:s-1]}^j, 0, \mathbf{b}_{l[s+1:N^j]}^{*j}(0) \right), \left( \mathbf{p}_{l[1:s-1] \leftarrow j}, 0, \mathbf{p}_{l[s+1:N^j] \leftarrow j}^*(0) \right) \right) = \\ & f \left( \sum_{b_k^j \in (\mathbf{b}_{l[1:s-1]}^j, \mathbf{b}_{l[s+1:N^j]}^{*j}(0))} b_k^j X_{j \leftarrow k} \right) - \sum_{k \in (\mathbf{p}_{l[1:s-1] \leftarrow j}, \mathbf{p}_{l[s+1:N^j] \leftarrow j}^*(0))} k, \end{aligned} \quad (5.10)$$

和

$$V_{l_s^j}^j(0, 0) = 0. \quad (5.11)$$

当平台  $j$  与平台  $l_s^j \in \mathcal{B}^j$  达成合作时, 根据式5.3和5.4, 它们的效益值分别为:

$$\begin{aligned} & \Psi_j^{P+} \left( \left( \mathbf{b}_{l[1:s-1]}^j, 1, \mathbf{b}_{l[s+1:N^j]}^{*j}(1) \right), \left( \mathbf{p}_{l[1:s-1] \leftarrow j}, p_{l_s^j \leftarrow j}^*(\mathbf{b}_{l[1:s-1]}^j), \mathbf{p}_{l[s+1:N^j] \leftarrow j}^*(1) \right) \right) = \\ & f(X_{j \leftarrow l_s^j} + \sum_{b_k^j \in (\mathbf{b}_{l[1:s-1]}^j, \mathbf{b}_{l[s+1:N^j]}^{*j}(1))} b_k^j X_{j \leftarrow k}) - p_{l_s^j \leftarrow j}^*(\mathbf{b}_{l[1:s-1]}^j) - \sum_{k \in (\mathbf{p}_{l[1:s-1] \leftarrow j}, \mathbf{p}_{l[s+1:N^j] \leftarrow j}^*(1))} k, \end{aligned} \quad (5.12)$$

和

$$V_{l_s^j}^j \left( 1, p_{l_s^j \leftarrow j}^*(\mathbf{b}_{l[1:s-1]}^j) \right) = p_{l_s^j \leftarrow j}^*(\mathbf{b}_{l[1:s-1]}^j) - E_{l_s^j}^j X_{j \leftarrow l_s^j}. \quad (5.13)$$

为了便于分析, 我们将式5.10和5.12的左边分别记作  $\Psi_j^{P+}(0, 0) \Big|_{(\mathbf{b}_{l[1:s-1]}^j, \mathbf{b}_{l[s+1:N^j]}^{*j}(0))}^{\mathbf{p}_{l[1:s-1] \leftarrow j}, \mathbf{p}_{l[s+1:N^j] \leftarrow j}^*}$  和  $\Psi_j^{P+} \left( 1, p_{l_s^j \leftarrow j}^*(\mathbf{b}_{l[1:s-1]}^j) \right) \Big|_{(\mathbf{b}_{l[1:s-1]}^j, \mathbf{b}_{l[s+1:N^j]}^{*j}(1))}^{\mathbf{p}_{l[1:s-1] \leftarrow j}, \mathbf{p}_{l[s+1:N^j] \leftarrow j}^*}$ 。

根据纳什议价理论, 纳什议价解  $(b_{l_s^j}^{*j}(\mathbf{b}_{l[1:s-1]}^j), p_{l_s^j \leftarrow j}^*(\mathbf{b}_{l[1:s-1]}^j))$  是关于以下最优化问题 (问题 **CoopPricing** 的形式化) 的解, 即最大化目标函数为两项差的乘积, 第

一项为式5.12和式5.10的差，第二项为式5.13和式5.11：

$$\begin{aligned}
 \max \quad & \left( \Psi_j^{P+} \left( 1, p_{l_s^j \leftarrow j}(\mathbf{b}_{l[1:s-1]}^j) \right) \Big|_{(\mathbf{b}_{l[1:s-1]}^j, \mathbf{b}_{l[s+1:N^j]}^{*j})}^{p_{l[1:s-1] \leftarrow j}, p_{l[s+1:N^j] \leftarrow j}^*} - \Psi_j^{P+}(0, 0) \Big|_{(\mathbf{b}_{l[1:s-1]}^j, \mathbf{b}_{l[s+1:N^j]}^{*j})}^{p_{l[1:s-1] \leftarrow j}, p_{l[s+1:N^j] \leftarrow j}^*} \right) \\
 & \times \left( V_{l_s^j}^j \left( 1, p_{l_s^j \leftarrow j}(\mathbf{b}_{l[1:s-1]}^j) \right) - V_{l_s^j}^j(0, 0) \right) \\
 s.t. \quad & \begin{cases} \Psi_j^{P+} \left( 1, p_{l_s^j \leftarrow j}(\mathbf{b}_{l[1:s-1]}^j) \right) \Big|_{(\mathbf{b}_{l[1:s-1]}^j, \mathbf{b}_{l[s+1:N^j]}^{*j})}^{p_{l[1:s-1] \leftarrow j}, p_{l[s+1:N^j] \leftarrow j}^*} - \Psi_j^{P+}(0, 0) \Big|_{(\mathbf{b}_{l[1:s-1]}^j, \mathbf{b}_{l[s+1:N^j]}^{*j})}^{p_{l[1:s-1] \leftarrow j}, p_{l[s+1:N^j] \leftarrow j}^*} \geq 0, \\ V_{l_s^j}^j \left( 1, p_{l_s^j \leftarrow j}(\mathbf{b}_{l[1:s-1]}^j) \right) \geq 0, \\ p_{l_s^j \leftarrow j}(\mathbf{b}_{l[1:s-1]}^j) \leq r_j^*. \end{cases}
 \end{aligned} \tag{5.14}$$

在问题 (5.14) 中， $\left( \Psi_j^{P+}(0, 0) \Big|_{(\mathbf{b}_{l[1:s-1]}^j, \mathbf{b}_{l[s+1:N^j]}^{*j})}^{p_{l[1:s-1] \leftarrow j}, p_{l[s+1:N^j] \leftarrow j}^*}, V_{l_s^j}^j(0, 0) \right)$  是非合作点，即平台  $j$  与平台  $l_s^j \in \mathcal{B}^j$  达不成合作的议价结果<sup>[135]</sup>。第一个约束和第二个约束确保合作点的纳什议价结果对应的议价双方其效益应该不低于非合作点的纳什议价结果的效益值。第三个约束揭示了平台  $j$  给平台  $l_s^j \in \mathcal{B}^j$  所支付的费用应小于在竞争场景下平台  $j$  直接征募用户来收集感知数据所支付的奖励费用。

显然，问题 (5.14) 是凸优化问题，使用求解其 KKT 条件可以求解其纳什议价闭式解。我们将由求解 KKT 条件得到的纳什议价闭式解总结于以下引理：

**引理 5.4.** 当平台  $j$  按给定顺序  $\mathbf{L}^j[1:N^j]$  与平台  $l_s^j \in \mathcal{B}^j$  议价进行合作时，平台  $j$  和平台  $l_s^j$  的纳什议价结果  $\left( b_{l_s^j}^{*j}(\mathbf{b}_{l[1:s-1]}^j), p_{l_s^j \leftarrow j}^*(\mathbf{b}_{l[1:s-1]}^j) \right)$ （为了便于分析，记作  $(b_{l_s^j}^{*j}, p_{l_s^j \leftarrow j}^*)$ ）的确定准则：

- 当  $0 \leq p_{l_s^j \leftarrow j}^* \leq \min\{r_j^*, \Omega_s\}$  且  $E_{l_s^j} X_{j \leftarrow l_s^j} \leq \Omega_s$  成立时， $b_{l_s^j}^{*j} = 1$ ；
- 否则， $b_{l_s^j}^{*j} = 0$ 。

其中， $p_{l_s^j \leftarrow j}^*$  根据下式计算：

$$p_{l_s^j \leftarrow j}^* = \frac{\alpha_s - \beta_s + \gamma_s + E_{l_s^j} X_{j \leftarrow l_s^j}}{2}, \tag{5.15}$$

中间变量  $\alpha_s$ 、 $\beta_s$ 、 $\gamma_s$  和  $\Omega_s$  的计算如下：

$$\begin{cases} \alpha_s = f(X_{j \leftarrow l_s^j} + \sum_{b_k^j \in (b_{l[1:s-1]}^j, b_{l[s+1:N^j]}^{*j})^{(1)}} b_k^j X_{j \leftarrow k}), \\ \beta_s = f(\sum_{b_k^j \in (b_{l[1:s-1]}^j, b_{l[s+1:N^j]}^{*j})^{(0)}} b_k^j X_{j \leftarrow k}), \\ \gamma_s = \sum_{k \in p_{l[s+1:N^j] \leftarrow j}^{*j}(0)} k - \sum_{k \in p_{l[s+1:N^j] \leftarrow j}^{*j}(1)} k, \\ \Omega_s = \alpha_s - \beta_s + \gamma_s. \end{cases} \quad (5.16)$$

在引理5.4中，我们可以看到，如果平台  $j$  支付给平台  $l_s^j$  的价钱  $p_{l_s^j \leftarrow j}^*$  少于其直接征募用户来收集感知数据的奖励费用  $r_j^*$  但多于平台  $l_s^j$  的共享数据代价  $E_{l_s^j} X_{j \leftarrow l_s^j}$  时，它们将会达成合作。由于  $E_{l_s^j} X_{j \leftarrow l_s^j} \leq \Omega_s$ ，我们把中间变量  $\Omega_s$  解释为平台  $l_s^j$  的最大共享数据代价。从式5.15可知，一对多的纳什议价闭式解是递归形式，即在第  $s$  步和平台  $l_s^j$  的议价结果依赖于前后的议价信息。为此，我们设计一个递归算法，求解任意  $s$  步的议价结果，伪代码如算法7所示。

算法7以递归深度  $s$ ，前  $s$  的议价结果  $b_{l[1:s-1]}^j$  和议价顺序  $\mathbf{L}^j[1:N^j] = (l_1^j, l_2^j, \dots, l_{N^j}^j)$  作为输入，输出第  $s$  步平台  $j$  与平台  $l_s^j \in \mathcal{B}^j$  的议价结果。在第1-4行，算法首先判断平台  $j$  是否与顺序  $\mathbf{L}^j[1:N^j]$  的最后一个平台  $l_N^j$  议价，如果是的话，使用引理5.4计算议价结果  $(b_{l_N^j}^{*j}, p_{l_N^j \leftarrow j}^*)$  并结束递归返回结果，否则进入后面代码进行以递归的方式分别计算  $b_{l_s^j}^{*j} = 0$  和  $b_{l_s^j}^{*j} = 1$  的议价子问题，最后进行比对两个子问题的双方效益是否提高从而得到在第  $s$  步平台  $j$  与平台  $l_s^j \in \mathcal{B}^j$  的议价结果。在第5行定义一些用于递归计算的临时变量，其中变量  $h_0$  用于计算式5.16中  $\beta_s$  值（第14行），变量  $h_1$  用于计算计算式5.16中  $\alpha_s$  值（第13行），变量  $C$  用于计算5.16中  $\gamma_s$  值（第15行），变量  $pre_0$  用于构造给定前  $s-1$  议价结果  $b_{l[1:s-1]}^j$  时  $s$  步平台  $j$  与平台  $l_s^j \in \mathcal{B}^j$  达不成合作的议价结果（第8行），变量  $pre_1$  用于构造给定前  $s-1$  议价结果  $b_{l[1:s-1]}^j$  时  $s$  步平台  $j$  与平台  $l_s^j \in \mathcal{B}^j$  达成合作的议价结果（第10行）。第6-12行用于递归计算平台  $j$  与排序  $s$  步以后平台的议价结果，其中第7行为第  $s$  步议价达不成合作的结果，第8行分别更新临时变量  $h_0$  和  $pre_0$ 。第9行为第  $s$  步议价达成合作的结果，第10行分别更新临时变量  $h_1$  和  $pre_1$ 。第11行更新变量  $C$ 。第13-16行计算议价结果关于价钱  $p_{l_s^j \leftarrow j}^*$  的值。第17-21行使用引理5.4的条件进一步判断有效的  $p_{l_s^j \leftarrow j}^*$ ，并返回议价结果。

**Algorithm 7** 顺序精准议价算法, SeqBargaining( $s, \mathbf{b}_{l[1:s-1]}^j$ )**Input:** 递归深度  $s$ , 前  $s$  的议价结果  $\mathbf{b}_{l[1:s-1]}^j$ , 议价顺序  $\mathbf{L}^j[1 : N^j] = (l_1^j, l_2^j, \dots, l_{N^j}^j)$ **Output:** 第  $s$  步议价结果  $(b_{l_s^j}^{*j}, p_{l_s^j \leftarrow j}^{*j})$ 

```

1: if  $s = N^j$  then
2:   基于引理5.4计算  $(b_{l_s^j}^{*j}, p_{l_s^j \leftarrow j}^{*j})$ 
3:   return  $(b_{l_s^j}^{*j}, p_{l_s^j \leftarrow j}^{*j})$ 
4: end if
5: 定义变量  $h_0 = 0, h_1 = 0, C = 0, pre_0 = (\mathbf{b}_{l[1:s-1]}^j, 0), pre_1 = (\mathbf{b}_{l[1:s-1]}^j, 1)$ 
6: for  $(i = s + 1; i \leq N^j; i++)$  do
7:   定义结果变量  $temp_0 = \text{SeqBargaining}(i, pre_0)$ 
8:   令  $pre_0 = (pre_0, temp_0[0])$ , 令  $h_0 = temp_0[0]X_{j \leftarrow l_i^j} + h_0$ 
9:   定义结果变量  $temp_1 = \text{SeqBargaining}(i, pre_1)$ 
10:  令  $pre_1 = (pre_1, temp_1[0])$ , 令  $h_1 = temp_1[0]X_{j \leftarrow l_i^j} + h_1$ 
11:  令  $C = temp_0[1] - temp_1[1] + C$ 
12: end for
13: 令  $A = f(\sum_{i=1}^{s-1} b_{l_i^j}^j X_{j \leftarrow l_i^j} + X_{j \leftarrow l_s^j} + h_1)$ 
14: 令  $B = f(\sum_{i=1}^{s-1} b_{l_i^j}^j X_{j \leftarrow l_i^j} + h_0)$ 
15: 令  $\Omega = A - B + C$ 
16: 根据式5.15计算  $p_{l_s^j \leftarrow j}^{*j}$ 
17: if  $0 \leq p_{l_s^j \leftarrow j}^{*j} \leq \min\{r_j^*, \Omega\}$  且  $E_{l_s^j} \leq \frac{\Omega}{X_{j \leftarrow l_s^j}}$  then
18:   return  $(1, p_{l_s^j \leftarrow j}^{*j})$ 
19: else
20:   return  $(0, 0)$ 
21: end if

```

接下来我们分析算法7的时间复杂度，我们将会发现该算法具有指数阶时间复杂度。算法7的时间复杂度由算法的递归部分（第8–16行）所决定，这部分的时间复杂度记作  $T(s)$ ，则  $T(s)$  可以表示为以下递推式：

$$T(s) = \begin{cases} \mathcal{O}(1) & s = N^j, \\ \sum_{i=s+1}^{N^j} 2T(i) + \mathcal{O}(1) & s < N^j. \end{cases} \quad (5.17)$$

通过求解式5.17的递推式，我们可以求得  $T(s) = (3^{N^j-1} - 1)(\frac{1}{3})^{s-1}$ 。由于我们需要使用算法7计算给定顺序下所有平台  $s \in \mathbf{L}^j[1 : N^j]$  的议价结果，因此，总的时间复杂是  $\sum_{i=1}^{N^j} T(i) = \frac{(3^{N^j-1} - 1)(1 - (\frac{1}{3})^{N^j})}{1 - \frac{1}{3}} = \mathcal{O}(3^{N^j})$ 。由此可见，算法7是一个关于指数阶  $\mathcal{O}(3^{N^j})$  时间复杂度的算法，当要议价的平台数目很大的时候，算法的效率急剧下降。事实上，

精准议价是一个 NP 难问题，不存在多项式时间内找到纳什议价解。而算法7高时间复杂度的主要原因是一些子问题的数目多，具有  $\sum_{i=1}^{N^j-1} i = \frac{N^j(N^j-1)}{2}$ ，而且一些子问题是重叠的，被重复计算多次。

为了克服重叠子问题被重复计算，我们将使用备忘录的方式来修改算法7并得到其变体，将算法遇到的所有子问题对应的解存储备份，下次遇到重叠子问题时候，可以直接使用该子问题的解和对应的最优值，而不用递归计算重叠子问题。尽管如此，算法的时间复杂度还仍然是指数阶的。为此，我们将在下一小节探索启发式议价来求解议价结果。

### 5.4.2 启发式议价

在上一小节最后，我们分析了精准议价对应的算法具有指数阶高时间复杂度，在本章，我们提出启发式议价。而在算法7推导第  $s$  步纳什议价解时，需要假定  $b_{l[1:s-1]}^j$  的议价结果已知，然后递归求解  $s$  步以后的议价结果，最后判断第  $s$  步的议价结果。随着顺序议价的进行， $s$  的递进造成了多个重叠子问题。即我们在顺序议价中推导  $s$  步的议价结果时，即需要历史信息（给定  $s$  步以前的议价结果）和未来信息（递归推导  $s$  步以后的议价结果）。捕捉到这个问题特征，我们提出的启发式议价只考虑历史信息来推导当前的议价结果，而不考虑未来信息。这将会得到一个近优算法，而且具有多项式时间复杂度。

为了叙述启发式议价，我们定义一个变量集合  $C^j$ ，表示平台  $j$  将会与集合  $C^j$  里的平台达成议价合作。由于不考虑未来信息，式5.16可以进一步修改为：

$$\begin{cases} \tilde{\alpha}_s = f(X_{j \leftarrow l_s^j} + \sum_{l_k^j \in C^j \setminus l_s^j} X_{j \leftarrow l_k^j}), \\ \tilde{\beta}_s = f(\sum_{l_k^j \in C^j \setminus l_s^j} X_{j \leftarrow l_k^j}), \\ \widetilde{\Omega}_s = \tilde{\alpha}_s - \tilde{\beta}_s. \end{cases} \quad (5.18)$$

基于上式5.18，我们可以设计启发式议价算法，其伪代码如算法8所示。算法8以与平台  $j$  进行议价的平台集  $B^j$ ，议价平台  $s$  所拥有的数据量  $X_{j \leftarrow s}$  和议价平台  $s$  的合作代价  $E_s$  ( $\forall s \in B^j$ ) 作为输入，输出与平台  $j$  达成议价合作的平台集  $C^j$ 。第一行遍历平台集  $B^j$  中的每一个平台  $l_s^j \in B^j$ ，考察他们与平台  $j$  议价的情况，在第2行，我们像



**Algorithm 8** 启发式议价算法

**Input:** 与平台  $j$  进行议价的平台集  $\mathcal{B}^j$ , 议价平台  $s$  所拥有的数据量  $X_{j \leftarrow s}$ , 议价平台  $s$  的合作代价  $E_s (\forall s \in \mathcal{B}^j)$

**Output:** 与平台  $j$  达成议价合作的议价结果集  $\mathcal{C}^j$

```

1: for  $l_s^j \in \mathcal{B}^j$  do
2:   根据式5.18计算变量  $\widetilde{A}, \widetilde{B}$  和  $\widetilde{\Omega}$ 
3:   根据引理5.4计算  $(\widetilde{b_{l_s^j}^{*j}}, \widetilde{p_{l_s^j \leftarrow j}^{*j}})$ 
4:   if  $\widetilde{b_{l_s^j}^{*j}} = 1$  then
5:     更新  $\mathcal{C}^j = \mathcal{C}^j \cup \{(\widetilde{l_s^j}, \widetilde{p_{l_s^j \leftarrow j}^{*j}})\}$ 
6:   end if
7: end for
8: return  $\mathcal{C}^j$ 

```

算法7使用式5.18计算中间变量来进一步计算议价结果（第3行）。第4–6行判定是否把当前议价的平台加入到结果集合中。当遍历完平台集  $\mathcal{B}^j$  后返回结果集作为达成合作的变量，并记录利用引理5.4计算的对应价钱  $\widetilde{p_{l_s^j \leftarrow j}^{*j}}$ 。整个算法只遍历一遍“for”循环，只需  $\mathcal{O}(N^j)$  的时间复杂度。算法8和算法7的联系在于都是基于引理5.4计算当前议价结果，不同在于算法7使用递推式5.16来计算议价结果的中间变量，而算法8使用式5.18计算议价结果的中间变量，此中间变量相比于算法7的中间是松弛版的中间变量。

### 5.4.3 所有平台的合作策略

前面两节揭示了一个平台与其他平台进行合作的策略，根据这个策略，该平台可以选择与一组其他平台进行合作，并支付它们对应的纳什议价解中的价钱，从并合作平台那里购买它们所收集到的感知数据。然而，这种数据交换是单向的，因为每个平台所收集到的数据是异构的，不同平台对数据的需求不一样，且每个平台的数据价值不一样，因此每个平台与其他平台的合作策略不一样。为了获得所有平台的合作情况，我们需要为每个平台运行一对多纳什议价模型来获得所有平台的议价结果，进而得到所有平台的合作策略。总得来说，计算所有平台的合作策略的基本过程为：

- 1) 针对平台  $j$ ，确定其议价平台集  $\mathcal{B}^j$ ；
- 2) 执行一对多议价模型得到平台  $j$  的合作情况。

重复上面过程直到所有平台的合作策略得到确定。当我们使用算法7的精准议价算法

表 5.2 第5章仿真实验关键参数

参数	取值
竞争场景	感知代价 $c_{j \leftarrow i}$ 工作量上限 $B_i^U$ 服务价值系数 $\lambda_j$ 平台预算 $B_j^P$
合作场景	共享数据量 $X_{j \leftarrow k}$ 平台 $k$ 的共享代价 $E_k$ 直接征募的单位奖励 $r_j^*$
用户数	$I$
平台数	$K$

来实现平台  $j$  的一对多议价模型时，需要的计算时间复杂度为  $\mathcal{O}(K3^{N^j})$ ，并且得到最优纳什议价解。而当我们使用算法8的启发式议价来实现平台  $j$  的一对多议价模型时，需要的计算时间复杂度为  $\mathcal{O}(KN^j)$ ，得到启发式近优解来表征议价结果。

## 5.5 仿真实验

### 5.5.1 实验设置

在本节，我们执行仿真实验来验证本章所针对竞争场景和合作场景提出的多平台激励机制性能。本章所牵涉的算法都是基于 Python 语言实现的。我们将一些关键参数的取值罗列在表5.2，其中  $U[\cdot]$  表示均匀分布。

我们在合成数据集和 D4D 数据集上进行仿真实验<sup>[137]</sup>。对于合成数据集，我们分别随机生成两个关于竞争场景和合作场景的子数据集，关于竞争场景的子数据集，我们在每个时槽  $t$  随机生成一对平台和用户序对，表示平台-用户的征募关系。关于合作场景的子数据集，我们在每个时槽  $t$  随机生成一对平台和平台序对，表示平台-平台的议价关系。总时长为  $T_d = 24 * 60 * 60$ 。在 D4D 数据集中，我们挑选了两个数据子集（SET1 和 SET2）来分别仿真竞争场景下的激励机制和合作场景下的激励机制。其中，SET1 的每行数据表示基站对基站的通信过程，还有通信次数和每次通信时长。我们将基站映射为平台，通信次数和通信时长分别映射议价平台的数据量  $X_{j \leftarrow k}$  和共享代价  $E_k$ 。因此，SET1 用于仿真合作场景下的激励机制。SET2 中的每一行表示用户和基站的打电话记录，基站映射为平台。由于 SET2 没有用户感知代价和平台奖励预算信息，因此，我们还需要随机生成感知代价和预算信息。D4D 数据集的跨越时长为 3600 小时（从 2011 年 12 月 1 日到 2012 年 4 月 28 日）。用户数超过 50000，基站

数超过 1000 个。但是在实验中，为了和合成数据集保持一致，我们随机选取了 30 个用户的信息和 1000 个基站的信息。

### 5.5.2 实验结果

我们首先针对竞争场景下多平台激励机制的用户策略和平台策略（节 3.3 的分析）进行仿真实验。用户的策略是关于用户可以选择最好的平台  $j_i^*$  去执行感知任务以及和最优工作量  $x_{j^* \leftarrow i}^*$ 。我们评估最优工作量  $x_{j^* \leftarrow i}^*$  如何被平台奖励  $r_j$ 、感知代价  $c_{j \leftarrow i}$  和工作量上限  $B_i^U$  影响。关键参数  $r_j$ 、 $B_i^U$  和  $c_{j \leftarrow i}$  根据表 5.2 取值。根据引理 5.1 可以描绘最优工作量  $x_{j^* \leftarrow i}^*$  的曲线，如图 5.2 所示的等值线图描述奖励和感知代价对最优工作量  $x_{j^* \leftarrow i}^*$  的影响。图 5.3 的结果显示最优工作量  $x_{j^* \leftarrow i}^*$  随着平台奖励  $r_j$  的上升而增加，随着感知代价  $c_{j \leftarrow i}$  的增加而减少，最优工作量  $x_{j^* \leftarrow i}^*$  截止于工作量上限  $B_i^U$ 。




图 5.2 平台的奖励  $r_j$  对工作量上限  $B_i^U$  和感知代价  $c_{j \leftarrow i}$  不同用户的最优工作量策略  $x_{j^* \leftarrow i}^*$  的影响




图 5.3 最优工作量策略  $x_{j^* \leftarrow i}^*$  关于平台奖励  $r_j$  和感知代价  $c_{j \leftarrow i}$  的等值线图




图 5.4 奖励定价策略  $r_j^*$  在不同预算  $B_j^P$  关于服务价值系数  $\lambda_j$  的影响

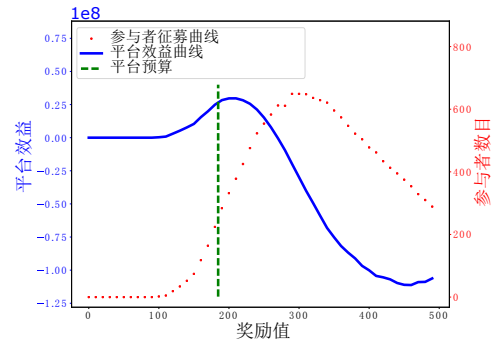


图 5.5 平台奖励和用户参与数目在一定预算  $B_j^P$  下关于奖励定价决策的变化曲线

接下来，我们选取某个平台作为考察对象来评估平台竞争场景下平台的奖励定价策略  $r_j^*$ 。根据引理5.3，奖励定价策略  $r_j^*$  与平台预算  $B_j^P$  和服务价值系数  $\lambda_j$  有关。我们根据表5.2为参数  $B_j^P$  和  $\lambda_j$  取值，并根据引理5.3将平台的奖励定价策略  $r_j^*$  在不同预算  $B_j^P$  关于服务价值系数  $\lambda_j$  的变化曲线描绘在图5.4。从图5.4中可知，当奖励定价策略  $r_j^*$  随着服务价值系数  $\lambda_j$  的增加而增加，随着预算  $B_j^P$  的减少而减少，预算的不同不会改变平台间奖励定价策略的边际效应（关于  $\lambda_j$  的变化率）。

我们选取某个平台作为考察对象来评估竞争场景下平台的奖励定价策略  $r_j^*$  对平台的效益和其所能征募到用户数目的影响。结果如图5.5所示。蓝线代表平台效益值关于奖励定价策略  $r_j^*$  的变化曲线，在初始阶段，平台效益值随着支付的奖励越多而增大，这是因为单位奖励  $r_j^*$  定得越多，可以征募更多用户来执行感知任务而提高了该平台的服务价值  $\Phi_j(\mathbf{x}^j)$ ；然而随着单位奖励  $r_j^*$  的增多，平台效益值反而下降，则是因为尽管奖励越多吸引的用户越多，但是对平台来说，所支付的奖励代价就越大，抵消了服务价值  $\Phi_j(\mathbf{x}^j)$ 。由此可以看出，平台效益值关于奖励定价策略  $r_j^*$  是上凸的，这也符合问题 CompOPT2 的目标函数。绿线表示平台的预算  $B_j^P$ ，作为奖励定价策略  $r_j^*$  的上限，因此平台能否通过奖励定价策略  $r_j^*$  最大化效益取决于其预算  $B_j^P$ 。红线代表平台征募的用户数关于奖励定价策略  $r_j^*$  的变化曲线，其变化趋势和效益一样，先增后减，存在一个最优的奖励定价策略去最大化所征募到的用户数目。然而，该曲线不和效益曲线重合，这意味着最大化效益的奖励定价策略和最大化征募用户数的奖励定价策略取值不一样。

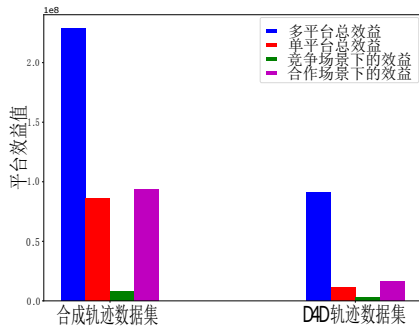


图 5.6 奖励定价策略  $r_j^*$  在不同预算  $B_j^P$  关于服务价值系数  $\lambda_j$  的影响




图 5.7 合作场景下某一平台议价的结果

在图5.6，我们评估了本章提出的激励机制在合成轨迹数据集和 D4D 数据集上平台的效益性能。在合成数据集中，我们在每一时槽随机生成用户与平台和平台与平台的交互接触记录；在 D4D 数据集中，我们使用用户与基站和基站与基站的通话记录

作为群智感知中用户和平台的交互接触记录。我们在这些数据集上部署了本章提出的激励机制，同时展示了多平台的总效益、单一平台的效益、以及多平台在竞争场景和合作场景下的效益。在合成数据集和 D4D 数据集上的结果都揭示了多平台的总效益大于单一平台的，平台之间的合作可以带来更多的效益提升。最后，我们选择平台  $j$  作为考察对象来评估合作场景下一对多纳什议价的结果。我们选取  $N^j = 20$  个议价平台，并根据表 5.2 为每个议价平台的参数取值（共享数据量  $X_{j \leftarrow k}$  和共享代价  $E_k$ ），我们根据算法 8 的启发式议价来计算议价结果，并把结果描绘成散列图的形式，如图 5.7。由图中可见，如果共享代价  $E_k$  越小，共享数据量  $X_{j \leftarrow k}$  越大，议价平台更倾向于和  $j$  达成合作，以提升双方的效益，达到双赢的局面。

## 5.6 本章小节

在本章，我们研究多平台竞争合作激励机制设计问题。对于竞争场景下的激励机制，我们将平台与用户和平台间的策略交互建模为多主导者-多跟随者的斯坦克伯格博弈，通过推导斯坦克伯格均衡，我们可以表征用户和平台的最优策略。对于合作场景下的激励机制，我们将平台与平台的策略交互建模为纳什议价模型，我们首先探讨了一对多纳什精准顺序议价方法，并分析它的 NP 难解性和指数阶高复杂度，进而提出一对多纳什启发式议价方法。通过议价结果，我们表征了平台间的合作策略，并通过该策略实现数据二次利用而达到双赢局面。最后，我们通过仿真实验验证了本章所研究的激励机制方法的有效性。

## 第 6 章 结论与展望

### 6.1 工作总结

近年来,人工智能和大数据挖掘技术的发展使得传统各行各业发生了翻天覆地的变化。为了抢占发展制高点,各国政府纷纷推出各大战略,包括中国“制造 2025”、美国“工业互联网”、德国“工业 4.0”和日本“社会 5.0”。然而,数据在这些信息化战略中具有举足轻重的地位,离开数据的支持将会使得智能化的发展战略落空。物联网技术的发展推动着大数据时代的到来,填补了人们日常生活中的数据空白,缓解了信息化智能发展对数据需求的压力。万物互联越来越成为社会生活的新常态,物联网在感知区域部署各式各样的传感器来获取多模态感知数据,并通过存储-转发模式将数据汇聚到数据中心,从而支撑了基于数据服务与应用的发展。然而这种通过部署传感器组成无线传感网的数据收集方式是建立在巨大的部署成本之上,部署的专用传感器使得无线传感网可维护性差,互操作性不强和可扩展性低。固定位置的部署使得无线传感网不具备移动性,造成了感知系统的低灵活性,对数据需求的弹性响应弱。

随着移动智能设备的日益普及,人们的日常生活越来越离不开移动智能设备。移动智能设备的强大功能开始革新各行各业的发展。一方面,以集成电路为代表的微电子技术的进展使得移动智能设备拥有越来越强大的计算和存储能力,以 5G 为代表的通信技术赋予了移动智能设备高速的通信能力。另外一方面,移动智能设备自身配备了大量丰富的传感器,从移动智能设备中获得多模态感知数据成为可能,因此移动智能设备又具有强大的感知能力。

随着分布式解决问题和发现创业的众包模式在其他领域获得的成功,将其引入物联网的感知任务中,并结合移动智能设备的特点,从而形式了以人为中心的感知计算模式——**群智感知**。群智感知以携带移动智能设备作为基本感知单元,通过感知平台分发任务给用户,让用户利用其移动智能设备的传感器来收集与其自身或周边相关的多模态感知数据,并上传给感知平台。群智感知这种感知模式弥补了无线传感网自身的缺陷,群智感知不再部署大规模专业传感器而极大地节约了部署成本,用户的移动性和自主性使得群智感知维护性好,互操作性强、可扩展性和灵活性高。这些优势是无线传感网所无法比拟的,使得群智感知成为不可或缺的新型感知模式。

尽管群智感知颠覆了传统的无线传感网,但其自身的特点使得群智感知面临诸多

新的问题。其中的关键问题之一是理性用户存在自私性，得不到奖励则不愿意参与执行感知任务，贡献感知数据。一方面，用户执行感知任务，不可避免地消耗自身设备的电量、存储和计算等资源，传输感知数据又引入额外的通信费用；另一方面，感知任务往往与位置相关，执行任务存在暴露用户位置隐私等安全问题。这些问题在一定程度上增加了用户参与群智感知的门槛，降低了用户的参与热情。因此，设计合适的激励机制保证用户为群智感知贡献感知数据的同时获得实际收益，用合理的奖励获得优质的感知数据，实现群智感知系统“人人为我，我为人人”的良性循环，是群智感知研究的核心问题之一。

激励机制通常使用博弈论的方法来进行设计，通过设计博弈规则使得用户参与执行感知任务成为其占优策略，同时满足关于请求者和用户的特定约束下最大化感知系统的整体效益。然而，在不同场景下存在的挑战各有不同，激励机制的设计目标需要重新调整和考虑新的因素，例如预算有限、用户参与不足、用户挑选的公平性要求、平台的盈利目标和多平台竞争合作的共存问题。针对这些提炼的挑战，本文在不同场景下采用以斯坦克伯格博弈为代表的动态博弈来设计了相应的激励机制，取得了如下的成果：

1. **第三方应用协助的用户征募激励机制。**针对用户参与率不足的问题，我们将第三方应用的协助考虑到群智感知的激励机制设计当中，并使用三阶段斯坦克伯格博弈来建模这种第三方应用协助下的激励机制设计问题。我们系统分析了三阶段斯坦克伯格博弈的均衡策略，在第一阶段第三方应用先确定兴趣点标记的价格来最大化自己的效益，在第二阶段感知平台在得知标记价格的基础上，确定如何选择一组任务作为兴趣点让第三方应用标记，从而增加任务的参与者，在第三阶段，普通用户和 App 用户决定是否要执行感知任务，以及要选择哪个最优任务来执行。最后，我们通过实验仿真来评估第三方应用协助对激励机制的作用，以及揭示该激励机制在定价奖励上的合理性和在协助征募用户上的高效性。
2. **盈利性和公平性保障的长期激励机制。**为了防止用户流失和保障平台从协调请求者与用户之间盈利，我们设计了激励机制来保障这两个目标。我们使用三阶段斯坦克伯格来建模该激励机制，解决 1) 如何保证用户公平地被选为工作者，从而保障了用户长期参与到群智感知；2) 如何根据用户的计算能力来计算用户对任务子集的兴趣信息；3) 和如何确保感知平台在时间平均协调上是盈利的，



以此确保群智感知系统的可持续发展。我们在每一轮策略交互中系统分析了三阶段斯坦克伯格博弈的均衡策略，在第一阶段，我们结合了 Zinkevich 在线梯度学习方法和李雅普诺夫优化的 drift-plus-penalty 技术来设计在线任务定价算法，该算法达到了平台收益和感知系统效益（任务被更多用户的执行）的性能折中  $[\mathcal{O}(1/\nu), \mathcal{O}(\nu)]$ ；在第二阶段我们设计一个完全多项式近似算法为每个计算能力不同的用户计算出一组  $(1 - \varepsilon)$ -近优任务集作为自己的兴趣信息提交给平台；在第三阶段平台根据用户汇报的兴趣信息，通过结合集合多覆盖的近似算法和李雅普诺夫优化技术来设计在线用户选择算法，该算法达到了用户公平性保障和平台征募奖励最小化的性能折中  $[\mathcal{O}(1/V), \mathcal{O}(V)]$ 。最后，我们对该激励机制进行仿真实验来验证其在定价的合理性和用户选择的公平性与有效性的性能。

3. **面向多平台共存的激励机制。**针对多平台群智感知系统，我们提炼了设计面向多平台共存激励机制的挑战，并把多平台共存划分为竞争关系和合作关系。对于平台间的竞争关系，我们把激励机制建模为多主导者-多跟随者的斯坦克伯格博弈。通过推导斯坦克伯格均衡，每个平台可以根据计算出的最优奖励进行任务定价，每个用户可以选择最好的平台去执行感知任务。对于平台间的合作关系，我们使用合作博弈中的纳什议价模型来建模多平台合作场景的激励机制，通过先证明一对多纳什议价模型的 NP 难解性，进而提出启发式议价解决方案。推导纳什议价解揭示了平台间如何合作共享感知数据以及以多少奖励进行合作，使得感知数据得到二次利用。最后，我们通过实验仿真来评估所提出的激励机制在激励多平台共存上的性能，验证了该激励机制不仅能解决平台和参与者之间的策略交互，而且可以解决平台之间的策略交互。

## 6.2 研究展望

群智感知自诞生到现在已收到学术界和工业界的广泛关注。在各方的努力研究下诞生了大量的优秀研究成果和实际应用系统。未来，群智感知能够在大范围内长期稳定收集大量多模态感知数据，成为大数据时代最主要的数据来源。然而，群智感知的发展尚属于起步阶段，许多新问题挑战层出不穷，推动群智感知的进一步发展需要广大研究人员的共同努力。在这个背景下，结合本文在基于群智感知的激励机制研究工作，从以下几个方面总结未来可以继续完善的地方以启发关于群智感知更广泛深入研究的开展：

1. **多博弈模型融合激励机制。**群智感知中现有的激励机制研究工作大都采用某一博弈模型来建模请求者、平台和用户之间的策略交互问题。这些博弈模型包括斯坦克伯格博弈、拍卖论、纳什议价和契约论等等。不同的博弈模型存在自身的特点，解决不同的挑战，这造成了所设计的激励机制基本原理不同，得到不同运营方式的群智感知系统。为了综合考虑群智感知实际的运行环境中各种挑战因素的影响，设计融合多种博弈模型的激励机制，同时解决群智感知中出现的各种问题，得到适应不同场景的通用群智感知激励机制是一个非常重要的研究方向。
2. **无模型博弈均衡点的求解方法。**现有的很多基于博弈模型激励机制研究工作往往假设平台和用户的凸效益函数模型，从而推导得到唯一的均衡点交互策略。然而，在实际情况中，通过预定效益函数模型而推导得到的均衡点并不能实际反映激励机制的最优策略。群智感知应用的不同领域可能具有不同形式的效益函数，博弈模型中的常数参数不一定是已知的。因此如何研究更加通用的无模型博弈是群智感知激励机制设计的一项重要挑战。随着以监督学习、强化学习和非监督学习为代表的机器学习算法为解决这种无模型博弈均衡的求解方法提供了一些启发，也成为激励机制研究工作的一个有意义研究方向。
3. **基于面向实际具体应用的群智感知激励机制。**群智感知的思想来源于物联网的实际具体应用（环境监测、室内定位、噪声感知和智能交通），其研究应以具体应用为落脚点。然后在群智感知中，激励机制的研究和基于群智感知的应用研究界限明显，毫无交叉融合。这使得理论研究脱离实际情况，和实际应用又忽略理论支撑，造成了群智感知的发展无法向前迈进。如何结合激励机制的研究和实际具体应用，设计高效的群智感知系统，将是一个有实际意义的研究方向。
4. **基于区块链的新型群智感知架构激励机制。**在实际情况中，隐私安全性的保障问题关系着激励机制是否真正可行。首先，激励机制的主要思想是通过奖励来补偿用户的隐私代价，并没有真正做到保护用户的隐私数据，这个问题限制了群智感知应用于安全性要求较高的场景。其次，群智感知系统的架构往往依赖于驻扎在云服务器的平台，作为中心组织协调请求者和用户之间数据的供需关系，而这种平台对任务的集中式分配和奖励的集中定价存在可扩展性问题，当请求者数目过多，任务大量到达时会过度给平台造成大量的负载。最后，激励

机制需要假设平台与用户和平台与请求者之间存在信任，请求者宣布支付的费用和平台确定的奖励在得到感知数据后必须兑现交易，这种相互信任的假设在实际情况并不完全成立。随着区块链技术的诞生和发展，上述的挑战可以得到解决。区块链技术是融合了对等通信协议、共识机制、非对称加密、块链结构和智能合约等多种技术而达到过程可信和去中心化目标的新型分布式“记账”数据库。过程可信是指操作不可篡改、可追溯且数据由多方共同维护，从而使得网络多方以低成本的方式建立信任。去中心化意味着没有单一协调者维护网络中多方的数据及动作的同步，网络的各个节点完全依靠对等通信技术和共识机制达到数据和动作同步。在区块链中，数据以非对称加密进行传输来达到隐私保护的目标，而智能合约通过事件触发可信地完成了对块中数据的操作，随后在网络节点中由共识机制同步区块链的操作。然而，基于区块链的群智感知的系统架构与传统群智感知相比，具有显著区别。去中心化的特征使得平台作用可有可无，任务的发布、数据的收集和奖励的交易全部在区块链上进行，智能合约成为协同请求者和用户之间的数据供需关系成为操作的主要执行者。这种新型交互方式使得原有的激励机制不在适用，如何设计适用于新架构下的激励机制，加速感知数据的收集，是基于区块链的群智感知重要研究问题之一。



## 参考文献

- [1] 刘云浩. 群智感知计算[J]. 中国计算机学会通讯, 2012, 8(10): 38–41.
- [2] 刘驰. 群智感知中激励机制实验综述及展望[J]. 中兴通讯技术, 2015, 21(6): 10–13.
- [3] 童咏昕, 袁野, 成雨蓉, 等. 时空众包数据管理技术研究综述[J]. 软件学报, 2017, 28(1): 35–58.
- [4] Howe J. The rise of crowdsourcing[J]. Wired magazine, 2006, 14(6): 1–4.
- [5] Ganti R K, Ye F, Lei H. Mobile crowdsensing: current state and future challenges[J]. IEEE communications Magazine, 2011, 49(11): 32–39.
- [6] Lane N D, Miluzzo E, Lu H, et al. A survey of mobile phone sensing[J]. IEEE Communications magazine, 2010, 48(9): 140–150.
- [7] 赵东, 马华东. 群智感知网络的发展及挑战[J]. 信息通信技术, 2014(5): 66–70.
- [8] Pu L, Chen X, Xu J, et al. Crowdlet: Optimal worker recruitment for self-organized mobile crowdsourcing[C]. IEEE Proceedings of the 35th International Conference on Computer Communications (INFOCOM). San Francisco, CA, USA: IEEE, 2016: 1–9.
- [9] Nawaz S, Efstratiou C, Mascolo C. Parksense: A smartphone based sensing system for on-street parking[C]. ACM Proceedings of the 19th International Conference on Mobile Computing and Networking (MobiCom). Miami, FL, USA: ACM, 2013: 75–86.
- [10] Berkeley U, Nokia/NAVTEQ. Mobile millennium[EB/OL]. <https://traffic.berkeley.edu/>.
- [11] Rana R K, Chou C T, Kanhere S S, et al. Ear-phone: an end-to-end participatory urban noise mapping system[C]. ACM/IEEE Proceedings of the 9th International Conference on Information Processing in Sensor Networks (IPSN). Stockholm, Swede: ACM, 2010: 105–116.
- [12] Kim S, Robson C, Zimmerman T, et al. Creek watch: pairing usefulness and usability for successful citizen science[C]. ACM Proceedings of the International Conference on Human Factors in Computing Systems (CHI). Vancouver, BC, Canada: ACM, 2011: 2125–2134.
- [13] Simoens P, Xiao Y, Pillai P, et al. Scalable crowd-sourcing of video from mobile devices[C]. ACM Proceeding of the 11th International Conference on Mobile Systems, Applications, and Services (MobiSys). Taipei, Taiwan, China: ACM, 2013: 139–152.
- [14] Sensorly. Sensorly[EB/OL]. <http://www.sensorly.com>.
- [15] Gao R, Zhao M, Ye T, et al. Jigsaw: Indoor floor plan reconstruction via mobile crowdsensing[C]. ACM Proceedings of the 20th International Conference on Mobile Computing and Networking (MobiCom). Maui, HI, USA: ACM, 2014: 249–260.

- [16] 於志文, 於志勇, 周兴社. 社会感知计算: 概念、问题及其研究进展[J]. 计算机学报, 2012, 35(01): 16–26.
- [17] Cardone G, Foschini L, Bellavista P, et al. Fostering participation in smart cities: a geo-social crowdsensing platform[J]. IEEE Communications Magazine, 2013, 51(6): 112–119.
- [18] Tong Y, She J, Ding B, et al. Online mobile micro-task allocation in spatial crowdsourcing[C]. IEEE Proceedings of the 32nd International Conference on Data Engineering (ICDE). Helsinki, Finland: IEEE, 2016: 49–60.
- [19] Liu Y, Guo B, Wang Y, et al. Taskme: Multi-task allocation in mobile crowd sensing[C]. ACM Proceedings of International Joint Conference on Pervasive and Ubiquitous Computing (UbiComp). Heidelberg, Germany: ACM, 2016: 403–414.
- [20] Karger D R, Oh S, Shah D. Budget-optimal task allocation for reliable crowdsourcing systems[J]. Operations Research, 2014, 62(1): 1–24.
- [21] Li H, Li T, Wang W, et al. Dynamic participant selection for large-scale mobile crowd sensing[J]. IEEE Transactions on Mobile Computing (TMC), 2018, 18(12): 2842–2855.
- [22] Li H, Li T, Li F, et al. Multi-expertise aware participant selection in mobile crowd sensing via online learning[C]. IEEE Proceedings of the 15th International Conference on Mobile Ad Hoc and Sensor Systems (MASS). Chengdu, China: IEEE, 2018: 433–441.
- [23] Lee J S, Hoh B. Dynamic pricing incentive for participatory sensing[J]. Pervasive and Mobile Computing, 2010, 6(6): 693–708.
- [24] Jaimes L G, Vergara-Laurens I, Labrador M A. A location-based incentive mechanism for participatory sensing systems with budget constraints[C]. IEEE Proceedings of International Conference on Pervasive Computing and Communications (PerCom). Lugano, Switzerland: IEEE, 2012: 103–108.
- [25] Duan L, Kubo T, Sugiyama K, et al. Incentive mechanisms for smartphone collaboration in data acquisition and distributed computing[C]. IEEE Proceedings of the 31th International Conference on Computer Communications (INFOCOM). Orlando, FL, USA: IEEE, 2012: 1701–1709.
- [26] Yang D, Xue G, Fang X, et al. Crowdsourcing to smartphones: incentive mechanism design for mobile phone sensing[C]. ACM Proceedings of the 18th International Conference on Mobile Computing and Networking (MobiCom). Istanbul, Turkey: ACM, 2012: 173–184.
- [27] Yang D, Xue G, Fang X, et al. Incentive mechanisms for crowdsensing: Crowdsourcing with smartphones[J]. IEEE/ACM transactions on networking (ToN), 2015, 24(3): 1732–1744.
- [28] Singla A, Krause A. Truthful incentives in crowdsourcing tasks using regret minimization mechanisms[C]. ACM Proceedings of the 22nd International Conference on World Wide Web (WWW).

- Rio de Janeiro,Brazil: ACM, 2013: 1167–1178.
- [29] Subramanian A, Kanth G S, Moharir S, et al. Online incentive mechanism design for smartphone crowd-sourcing[C]. IEEE Proceedings of the 13th International Symposium on Modeling and Optimization in Mobile, Ad Hoc, and Wireless Networks (WiOpt). Mumbai, India: IEEE, 2015: 403–410.
  - [30] Krontiris I, Albers A. Monetary incentives in participatory sensing using multi-attributive auctions [J]. International Journal of Parallel, Emergent and Distributed Systems, 2012, 27(4): 317–336.
  - [31] Koutsopoulos I. Optimal incentive-driven design of participatory sensing systems[C]. IEEE Proceedings of the 32th International Conference on Computer Communications (INFOCOM). Turin, Italy: IEEE, 2013: 1402–1410.
  - [32] Bhat S, Nath S, Gujar S, et al. A mechanism to optimally balance cost and quality of labeling tasks outsourced to strategic agents[C]. ACM International Conference on Autonomous Agents and Multi-Agent Systems (AAMAS). Paris, France: ACM, 2014: 917–924.
  - [33] Reddy S, Estrin D, Hansen M, et al. Examining micro-payments for participatory sensing data collections[C]. ACM Proceedings of the 12th ACM international conference on Ubiquitous computing (UbiComp). Copenhagen, Denmark: ACM, 2010: 33–36.
  - [34] Musthag M, Raij A, Ganesan D, et al. Exploring micro-incentive strategies for participant compensation in high-burden studies[C]. ACM Proceedings of the 13th international conference on Ubiquitous computing (UbiComp). Beijing, China: ACM, 2011: 435–444.
  - [35] Li T, Jung T, Qiu Z, et al. Scalable privacy-preserving participant selection for mobile crowdsensing systems: Participant grouping and secure group bidding[J]. IEEE Transactions on Network Science and Engineering, 2018.
  - [36] Chen H, Li F, Hei X, et al. Crowdx: Enhancing automatic construction of indoor floorplan with opportunistic encounters[J]. Proceedings of the ACM on Interactive, Mobile, Wearable and Ubiquitous Technologies, 2018, 2(4): 1–21.
  - [37] Tong Y, Cao C C, Chen L. Tcs: efficient topic discovery over crowd-oriented service data[C]. ACM SIGKDD Proceedings of the 20th International Conference on Knowledge Discovery and Data Mining (KDD). New York, NY, USA: ACM, 2014: 861–870.
  - [38] Fudenberg D, Tirole J. Game theory[R]. [S.l.]: The MIT press, 1991.
  - [39] Nisan N, Roughgarden T, Tardos E, et al. Algorithmic game theory.-cambridge university press [M]. [S.l.]: Cambridge, 2007.
  - [40] Easley D, Kleinberg J. Networks, crowds, and markets: Reasoning about a highly connected world [M]. [S.l.]: Cambridge University Press, 2010.



- [41] Jošilo S, Dán G. Wireless and computing resource allocation for selfish computation offloading in edge computing[C]. IEEE Proceedings of the 38th International Conference on Computer Communications (INFOCOM). Paris, France: IEEE, 2019: 2467–2475.
- [42] Boyd S, Boyd S P, Vandenberghe L. Convex optimization[M]. [S.l.]: Cambridge university press, 2004.
- [43] Neely M J. Stochastic network optimization with application to communication and queueing systems[J]. Synthesis Lectures on Communication Networks, 2010, 3(1): 1–211.
- [44] Berry R A, Gallager R G. Communication over fading channels with delay constraints[J]. IEEE Transactions on Information theory, 2002, 48(5): 1135–1149.
- [45] Neely M J. Super-fast delay tradeoffs for utility optimal fair scheduling in wireless networks[J]. IEEE Journal on Selected Areas in Communications (JSAC), 2006, 24(8): 1489–1501.
- [46] Neely M J. Optimal energy and delay tradeoffs for multiuser wireless downlinks[J]. IEEE Transactions on Information Theory, 2007, 53(9): 3095–3113.
- [47] Neely M J. Intelligent packet dropping for optimal energy-delay tradeoffs in wireless downlinks[J]. IEEE Transactions on Automatic Control, 2009, 54(3): 565–579.
- [48] Mohan P, Padmanabhan V N, Ramjee R. Nericell: rich monitoring of road and traffic conditions using mobile smartphones[C]. ACM Proceedings of the 6th International Conference on Embedded Networked Sensor Systems (SenSys). Raleigh, NC, USA: ACM, 2008: 323–336.
- [49] Thiagarajan A, Ravindranath L, LaCurts K, et al. Vtrack: accurate, energy-aware road traffic delay estimation using mobile phones[C]. ACM Proceedings of the 7th International Conference on Embedded Networked Sensor Systems (SenSys). Berkeley, California, USA: ACM, 2009: 85–98.
- [50] Mun M, Reddy S, Shilton K, et al. Peir, the personal environmental impact report, as a platform for participatory sensing systems research[C]. ACM Proceeding of the 7th International Conference on Mobile Systems, Applications, and Services (MobiSys). Kraków, Poland: ACM, 2009: 55–68.
- [51] 郭斌, 於志文. 群智融合计算[J]. 中国计算机学会通讯, 2018, 14(11): 41–45.
- [52] 陈翔, 徐佳, 吴敏, 等. 基于社会行为分析的群智感知数据收集研究[J]. 计算机应用研究, 2015, 32(12): 3534–3541.
- [53] 刘媛妮, 李慧聪, 关鑫, 等. 移动群智感知激励机制研究综述[J]. 重庆邮电大学学报 (自然科学版), 2018, 30(2): 147–158.
- [54] 熊永平, 刘伟, 刘卓华. 机会群智感知网络关键技术[J]. 中兴通讯技术, 2015, 21(6): 19–22.
- [55] Chen Y Y, Lv P, Guo D K, et al. A survey on task and participant matching in mobile crowd sensing [J]. Journal of Computer Science and Technology, 2018, 33(4): 768–791.

- [56] Chittilappilly A I, Chen L, Amer-Yahia S. A survey of general-purpose crowdsourcing techniques [J]. IEEE Transactions on Knowledge and Data Engineering (TKDE), 2016, 28(9): 2246–2266.
- [57] Jaimes L G, Vergara-Laurens I J, Raji A. A survey of incentive techniques for mobile crowd sensing [J]. IEEE Internet of Things Journal, 2015, 2(5): 370–380.
- [58] Louta M, Mpanti K, Karetsos G, et al. Mobile crowd sensing architectural frameworks: a comprehensive survey[C]. IEEE Proceedings of the 7th International Conference on Information, Intelligence, Systems & Applications (IISA). Chalkidiki, Greece: IEEE, 2016: 1–7.
- [59] Restuccia F, Das S K, Payton J. Incentive mechanisms for participatory sensing: Survey and research challenges[J]. ACM Transactions on Sensor Networks (TOSN), 2016, 12(2): 13.
- [60] Wang Y, Jia X, Jin Q, et al. Mobile crowdsourcing: framework, challenges, and solutions[J]. Concurrency and Computation: Practice and experience, 2017, 29(3): e3789.
- [61] Yuen M C, King I, Leung K S. A survey of crowdsourcing systems[C]. IEEE 3rd International Conference on Privacy, Security, Risk and Trust (PASSAT) and IEEE 3rd International Conference on Social Computing (SocialCom). Boston, MA, USA: IEEE, 2011: 766–773.
- [62] Zhang X, Yang Z, Sun W, et al. Incentives for mobile crowd sensing: A survey[J]. IEEE Communications Surveys & Tutorials, 2016, 18(1): 54–67.
- [63] Liu Y, Kong L, Chen G. Data-oriented mobile crowdsensing: A comprehensive survey[J]. IEEE Communications Surveys and Tutorials, 2019, 21(3): 2849–2885.
- [64] Nie J, Xiong Z, Niyato D, et al. A socially-aware incentive mechanism for mobile crowdsensing service market[J]. arXiv preprint arXiv:1711.01050, 2017.
- [65] Cheung M H, Hou F, Huang J. Make a difference: Diversity-driven social mobile crowdsensing [C]. IEEE Proceedings of the 36th International Conference on Computer Communications (INFOCOM). Atlanta, GA, USA: IEEE, 2017: 1–9.
- [66] Xiao L, Li Y, Han G, et al. A secure mobile crowdsensing game with deep reinforcement learning [J]. IEEE Transactions on Information Forensics and Security (TIFS), 2018, 13(1): 35–47.
- [67] Feng Z, Zhu Y, Zhang Q, et al. Trac: Truthful auction for location-aware collaborative sensing in mobile crowdsourcing[C]. IEEE Proceedings of the 33th International Conference on Computer Communications (INFOCOM). Toronto, Canada: IEEE, 2014: 1231–1239.
- [68] Feng Z, Zhu Y, Cai H, et al. Optimal distributed auction for mobile crowd sensing[J]. The Computer Journal, 2017.
- [69] Zhang X, Xue G, Yu R, et al. Truthful incentive mechanisms for crowdsourcing[C]. IEEE Proceedings of the 34th International Conference on Computer Communications (INFOCOM). Kowloon, Hong Kong: IEEE, 2015: 2830–2838.

- [70] Chen K, Gupta V, Huang Y F. On auction design for crowd sensing[C]. IEEE Proceedings of the 19th International Conference on Information Fusion (FUSION). Heidelberg, German: IEEE, 2016: 334–339.
- [71] Hu C, Xiao M, Huang L, et al. Truthful incentive mechanism for vehicle-based nondeterministic crowdsensing[C]. IEEE/ACM Proceedings of the 24th International Symposium on Quality of Service (IWQoS). Beijing, China: IEEE, 2016: 1–10.
- [72] Gao L, Hou F, Huang J. Providing long-term participation incentive in participatory sensing[C]. IEEE Proceedings of the 34th International Conference on Computer Communications (INFOCOM). Kowloon, Hong Kong: IEEE, 2015: 2803–2811.
- [73] Wen Y, Shi J, Zhang Q, et al. Quality-driven auction-based incentive mechanism for mobile crowd sensing[J]. IEEE Transactions on Vehicular Technology (TVT), 2015, 64(9): 4203–4214.
- [74] Zheng Z, Peng Y, Wu F, et al. Trading data in the crowd: Profit-driven data acquisition for mobile crowdsensing[J]. IEEE Journal on Selected Areas in Communications (JSAC), 2017, 35(2): 486–501.
- [75] DiPalantino D, Vojnovic M. Crowdsourcing and all-pay auctions[C]. ACM Proceedings of the 10th ACM conference on Electronic commerce (EC). Stanford, California, USA: ACM, 2009: 119–128.
- [76] Luo T, Tan H P, Xia L. Profit-maximizing incentive for participatory sensing[C]. IEEE Proceedings of the 33th International Conference on Computer Communications (INFOCOM). Toronto, Canada: ACM, 2014: 127–135.
- [77] Luo T, Das S K, Tan H P, et al. Incentive mechanism design for crowdsourcing: An all-pay auction approach[J]. ACM Transactions on Intelligent Systems and Technology (TIST), 2016, 7(3): 35.
- [78] Luo T, Kanhere S S, Das S K, et al. Optimal prizes for all-pay contests in heterogeneous crowdsourcing[C]. IEEE Proceedings of the 11th International Conference on Mobile Ad Hoc and Sensor Systems (MASS). Philadelphia, PA, USA: IEEE, 2014: 136–144.
- [79] Wei Y, Zhu Y, Zhu H, et al. Truthful online double auctions for dynamic mobile crowdsourcing [C]. IEEE Proceedings of the 34th International Conference on Computer Communications (INFOCOM). Kowloon, Hong Kong: IEEE, 2015: 2074–2082.
- [80] Huang H, Xin Y, Sun Y E, et al. A truthful double auction mechanism for crowdsensing systems with max-min fairness[C]. IEEE Wireless Communications and Networking Conference (WCNC). San Francisco, CA, USA: IEEE, 2017: 1–6.
- [81] Zhang H, Liu B, Susanto H, et al. Incentive mechanism for proximity-based mobile crowd service systems[C]. IEEE Proceedings of the 35th International Conference on Computer Communications (INFOCOM). San Francisco, CA, USA: IEEE, 2016: 1–9.

- [82] Jin H, Su L, Nahrstedt K. Centurion: Incentivizing multi-requester mobile crowd sensing[C]. IEEE INFOCOM. Atlanta, GA, USA: IEEE, IEEE Proceedings of the 36th International Conference on Computer Communications (INFOCOM): 1–9.
- [83] Zhai Y, Huang L, Chen L, et al. Coustic: Combinatorial double auction for task assignment in device-to-device clouds[J]. arXiv preprint arXiv:1810.10697, 2018.
- [84] Chen Y, Li B, Zhang Q. Incentivizing crowdsourcing systems with network effects[C]. IEEE Proceedings of the 35th International Conference on Computer Communications (INFOCOM). San Francisco, CA, USA: IEEE, 2016: 1–9.
- [85] Tarable A, Nordio A, Leonardi E, et al. The importance of being earnest in crowdsourcing systems[C]. IEEE Proceedings of the 34th International Conference on Computer Communications (INFOCOM). Kowloon, Hong Kong: IEEE, 2015: 2821–2829.
- [86] Ma X, Ma J, Li H, et al. Rtrc: a reputation-based incentive game model for trustworthy crowdsourcing service[J]. China Communications, 2016, 13(12): 199–215.
- [87] Bhattacharjee S, Ghosh N, Shah V K, et al. Qnq: A reputation model to secure mobile crowdsourcing applications from incentive losses[C]. IEEE Conference on Communications and Network Security (CNS). Las Vegas, NV, USA: IEEE, 2017: 1–9.
- [88] Dobakhshari D G, Naghizadeh P, Liu M, et al. A reputation-based contract for repeated crowdsensing with costly verification[C]. American Control Conference (ACC), 2017. Seattle, WA, USA: IEEE, 2017: 5243–5248.
- [89] He S, Shin D H, Zhang J, et al. Toward optimal allocation of location dependent tasks in crowdsensing[C]. IEEE Proceedings of the 33th International Conference on Computer Communications (INFOCOM). Toronto, Canada: IEEE, 2014: 745–753.
- [90] Zhan Y, Xia Y, Zhang J. Incentive mechanism in platform-centric mobile crowdsensing: A one-to-many bargaining approach[J]. Computer Networks, 2018, 132: 40–52.
- [91] Zhan Y, Xia Y, Liu Y, et al. Incentive-aware time-sensitive data collection in mobile opportunistic crowdsensing[J]. IEEE Transactions on Vehicular Technology (TVT), 2017, 66(9): 7849–7861.
- [92] Zhan Y, Xia Y, Zhang J, et al. Incentive mechanism design in mobile opportunistic data collection with time sensitivity[J]. IEEE Internet of Things Journal, 2018, 5(1): 246–256.
- [93] Zhao N, Fan M, Tian C, et al. Contract-based incentive mechanism for mobile crowdsourcing networks[J]. Algorithms, 2017, 10(3): 104.
- [94] Zhang Y, Gu Y, Pan M, et al. Multi-dimensional incentive mechanism in mobile crowdsourcing with moral hazard[J]. IEEE Transactions on Mobile Computing (TMC), 2018, 17(3): 604–616.
- [95] Li M, Lin J, Yang D, et al. Quac: quality-aware contract-based incentive mechanisms for crowd-

- p sensing[C]. IEEE Proceedings of the 14th International Conference on Mobile Ad Hoc and Sensor Systems (MASS). Orlando, FL, USA: IEEE, 2017: 72–80.
- [96] Zhang Z, He S, Chen J, et al. Reap: An efficient incentive mechanism for reconciling aggregation accuracy and individual privacy in crowdsensing[J]. IEEE Transactions on Information Forensics and Security (TIFS), 2018, 13(12): 2995–3007.
- [97] Wang J, Wang Y, Zhang D, et al. Learning-assisted optimization in mobile crowd sensing: A survey [J]. IEEE Transactions on Industrial Informatics (TII), 2018, 15(1): 15–22.
- [98] Wang D, Peng Y, Ma X, et al. Adaptive wireless video streaming based on edge computing: Opportunities and approaches[J]. IEEE Transactions on services Computing, 2018, 12(5): 685–697.
- [99] Zhou Z, Chen X, Li E, et al. Edge intelligence: Paving the last mile of artificial intelligence with edge computing[J]. Proceedings of the IEEE, 2019, 107(8): 1738–1762.
- [100] Marjanović M, Antić A, Žarko I P. Edge computing architecture for mobile crowdsensing[J]. IEEE Access, 2018, 6: 10662–10674.
- [101] Li T, Qiu Z, Cao L, et al. Participant grouping for privacy preservation in mobile crowdsensing over hierarchical edge clouds[C]. IEEE Proceedings of the 37th International Performance Computing and Communications Conference (IPCCC). Orlando, FL, USA: IEEE, 2018: 1–8.
- [102] Zhou Z, Liao H, Gu B, et al. Robust mobile crowd sensing: When deep learning meets edge computing[J]. IEEE Network, 2018, 32(4): 54–60.
- [103] Zhang X, Yang Z, Sun W, et al. Incentives for mobile crowd sensing: A survey[J]. IEEE Communications Surveys & Tutorials, 2015, 18(1): 54–67.
- [104] Guo B, Liu Y, Wang L, et al. Task allocation in spatial crowdsourcing: Current state and future directions[J]. IEEE Internet of Things Journal, 2018, 5(3): 1749–1764.
- [105] Wang L, Yu Z, Zhang D, et al. Heterogeneous multi-task assignment in mobile crowdsensing using spatiotemporal correlation[J]. IEEE Transactions on Mobile Computing (TMC), 2018, 18(1): 84–97.
- [106] Colley A, Thebault-Spieker J, Lin A Y, et al. The geography of pokémon go: beneficial and problematic effects on places and movement[C]. ACM Proceedings of the International Conference on Human Factors in Computing Systems (CHI). Denver, CO, USA: ACM, 2017: 1179–1192.
- [107] Yu H, Iosifidis G, Shou B, et al. Market your venue with mobile applications: Collaboration of on-line and offline businesses[C]. IEEE Proceedings of the 37th International Conference on Computer Communications (INFOCOM). Honolulu, HI, USA: IEEE, 2018: 1934–1942.
- [108] Gong X, Duan L, Chen X, et al. When social network effect meets congestion effect in wireless networks: Data usage equilibrium and optimal pricing[J]. IEEE Journal on Selected Areas in Com-

- plications (JSAC), 2017, 35(2): 449–462.
- [109] Hendler J, Golbeck J. Metcalfe’s law, web 2.0, and the semantic web[J]. *Journal of Web Semantics*, 2008, 6(1): 14–20.
  - [110] Guo B, Liu Y, Wu W, et al. Activecrowd: A framework for optimized multitask allocation in mobile crowdsensing systems[J]. *IEEE Transactions on Human-Machine Systems*, 2016, 47(3): 392–403.
  - [111] Yu H, Cheung M H, Gao L, et al. Economics of public wi-fi monetization and advertising[C]. *IEEE Proceedings of the 35th International Conference on Computer Communications (INFOCOM)*. San Francisco, CA, USA: IEEE, 2016: 1–9.
  - [112] Lawler E L. *Combinatorial optimization: networks and matroids*[M]. [S.l.]: Courier Corporation, 1976.
  - [113] Yu H, Neely M J. A new backpressure algorithm for joint rate control and routing with vanishing utility optimality gaps and finite queue lengths[J]. *IEEE/ACM Transactions on Networking (ToN)*, 2018, 26(4): 1605–1618.
  - [114] Gilmore P C, Gomory R E. A linear programming approach to the cutting-stock problem[J]. *Operations research*, 1961, 9(6): 849–859.
  - [115] Waze. *Waze*[EB/OL]. <https://www.waze.com>.
  - [116] Gigwalk. *Gigwalk*[EB/OL]. <http://gigwalk.com>.
  - [117] Zheng Y, Liu F, Hsieh H P. U-air: When urban air quality inference meets big data[C]. *ACM SIGKDD Proceedings of the 19th International Conference on Knowledge Discovery and Data Mining (KDD)*. Chicago, IL, USA: ACM, 2013: 1436–1444.
  - [118] Wang L, Zhang D, Pathak A, et al. Ccs-ta: quality-guaranteed online task allocation in compressive crowdsensing[C]. *ACM Proceedings of International Joint Conference on Pervasive and Ubiquitous Computing (UbiComp)*. Osaka, Japan: ACM, 2015: 683–694.
  - [119] Guo B, Chen H, Yu Z, et al. Fliermeet: a mobile crowdsensing system for cross-space public information reposting, tagging, and sharing[J]. *IEEE Transactions on Mobile Computing (TMC)*, 2015, 14(10): 2020–2033.
  - [120] Yang D, Xue G, Fang X, et al. Incentive mechanisms for crowdsensing: Crowdsourcing with smartphones[J]. *IEEE/ACM transactions on networking (ToN)*, 2016, 24(3): 1732–1744.
  - [121] Karaliopoulos M, Koutsopoulos I, Spiliopoulos L. Optimal user choice engineering in mobile crowdsensing with bounded rational users[C]. *IEEE Proceedings of the 38th International Conference on Computer Communications (INFOCOM)*. Paris, France: IEEE, 2019: 1054–1062.
  - [122] Duan Z, Li W, Cai Z. Mutual-preference driven truthful auction mechanism in mobile crowdsensing

- [C]. IEEE Proceedings of the 39th International Conference on Distributed Computing Systems (ICDCS). Dallas, TX, US: IEEE, 2019: 1233–1242.
- [123] Chong E K, Zak S H. An introduction to optimization: volume 76[M]. [S.l.]: John Wiley & Sons, 2013.
- [124] Li F, Liu J, Ji B. Combinatorial sleeping bandits with fairness constraints[C]. IEEE Proceedings of the 38th International Conference on Computer Communications (INFOCOM). Paris, France: IEEE, 2019: 1702–1710.
- [125] Sun L, Pang H, Gao L. Joint sponsor scheduling in cellular and edge caching networks for mobile video delivery[J]. IEEE Transactions on Multimedia (TMM), 2018, 20(12): 3414–3427.
- [126] Vazirani V V. Approximation algorithms[M]. [S.l.]: Springer Science & Business Media, 2013.
- [127] Zinkevich M. Online convex programming and generalized infinitesimal gradient ascent[C]. Proceedings of the 20th International Conference on Machine Learning (ICML). Washington, DC, USA: ACM, 2003: 928–936.
- [128] Yu H, Neely M, Wei X. Online convex optimization with stochastic constraints[C]. Advances in Neural Information Processing Systems (NeurIPS). Long Beach, CA, USA: MIT press, 2017: 1428–1438.
- [129] Neely M J, Yu H. Online convex optimization with time-varying constraints[J]. arXiv preprint arXiv:1702.04783, 2017.
- [130] Yu H, Neely M J. Learning aided optimization for energy harvesting devices with outdated state information[C]. IEEE Proceedings of the 37th International Conference on Computer Communications (INFOCOM). Honolulu, HI, USA: IEEE, 2018: 1853–1861.
- [131] Guo B, Wang Z, Yu Z, et al. Mobile crowd sensing and computing: The review of an emerging human-powered sensing paradigm[J]. ACM Computing Surveys (CSUR), 2015, 48(1): 7.
- [132] Wang Y, Jia X, Jin Q, et al. Mobile crowdsourcing: framework, challenges, and solutions[J]. Concurrency and Computation: Practice and Experience, 2016.
- [133] Jarrett J, Blake M B, Saleh I. Crowdsourcing, mixed elastic systems and human-enhanced computing—a survey[J]. IEEE Transactions on Services Computing, 2018, 11(1): 202–214.
- [134] Xie H, Lui J C. Incentive mechanism and rating system design for crowdsourcing systems: Analysis, tradeoffs and inference[J]. IEEE Transactions on Services Computing, 2016.
- [135] Yu H, Cheung M H, Huang J. Cooperative Wi-Fi deployment: A one-to-many bargaining framework[J]. IEEE Transactions on Mobile Computing (TMC), 2017, 16(6): 1559–1572.
- [136] Gao L, Iosifidis G, Huang J, et al. Bargaining-based mobile data offloading[J]. IEEE Journal on



Selected Areas in Communications (JSAC), 2014, 32(6): 1114–1125.

- [137] Blondel V D, Esch M, Chan C, et al. Data for development: the D4D challenge on mobile phone data[J]. arXiv preprint arXiv:1210.0137, 2012.



## 攻读学位期间发表论文与研究成果清单

### (一) 发表的学术论文

- [1] 第一作者, PTASIM: Incentivizing Crowdsensing with POI-tagging cooperation over Edge Clouds, IEEE Transactions on Industrial Informatics, Volume: 16, Issue: 7, Pages: 4823 - 4831, July 2020. (SCI 一区期刊, IF=6.524, 本论文第三章)
- [2] 第一作者, MP-Coopetition: Competitive and Cooperative Mechanism for Multiple Platforms in Mobile Crowd Sensing, IEEE Transactions on Services Computing, May 2019, DOI: 10.1109/TSC.2019.2916315. (SCI 一区期刊, IF=4.548, CCF-B 类期刊, 本论文第六章)
- [3] 第五作者, CondioSense: High-quality Context-aware Service for Audio Sensing System via Active Sonar, Personal and Ubiquitous Computing, Volume: 21, Issue: 1, Pages: 17-29, February 2017. (SCI 三区期刊, 影响因子 2.018)

### (二) 在投的学术论文

- [1] 第一作者, Three-stage Stackelberg long-term incentive mechanism and monetization for Mobile Crowdsensing: An Online Learning Approach. (本论文第四章)

### (三) 申请专利

- [1] 第三发明人. 基于线性调频音频信号的非接触式手掌移动轨迹追踪方法. 中国发明专利, 公开号: CN107102737A, 公开期: 2017.08.29
- [2] 第二发明人(导师第一发明人). 一种基于商用设备的免携带设备手掌定位人机交互方法. 中国发明专利, 授权号: CN106339081B, 公开期: 2019.01.25

### (四) 参与的科研项目

- [1] 国家自然科学基金面上项目, 群智感知系统中数据质量保证关键技术研究 (No.61772077), 2018.1-2021.12, 参与
- [2] 北京市自然科学基金面上项目, 面向群智感知系统的位置感知数据筛选关键技术研究 (No.4192051), 2019.1-2021.12, 参与
- [3] 国家自然科学基金青年项目, 网络功能虚拟化环境下资源优化调度问题研究 (No.61802018), 2019.1-2021.12, 参与